

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
Факультет програмних систем та прикладної математики
Кафедра прикладної математики

ЗВІТ
з лабораторної роботи №1
на тему: «Розвідковий аналіз даних»

Виконали: студенти групи
КМ-33, команда №4
Сивоконь В. В., Сусяк В. Р.,
Ткаченко Є. В.

ЗМІСТ

ВСТУП.....	3
1.1 Мета аналізу	3
1.2 Дослідницькі питання та гіпотези	3
ОПИС ДАНИХ	4
2.1 Походження даних та їх опис (оригінальний набір даних).....	4
2.2 Опис очищення набору даних	5
2.3 Дескриптивні статистики очищеного набору даних	7
EDA.....	7
3.1 Розподіли змінних	7
3.2 Матриця кореляцій (Спірмен)	22
3.3 Графіки до дослідницьких питань та гіпотез.....	24
ВИСНОВКИ	55
ВИКОРИСТАНІ ДЖЕРЕЛА.....	57

ВСТУП

1.1 Мета аналізу

Метою даного дослідження є проведення розвідкового аналізу даних (EDA) масштабного музичного каталогу для виявлення прихованих закономірностей, структурних особливостей та ключових аудіо-метрик, що визначають характеристики сучасного аудіоконтенту. Аналіз спрямований на розуміння того, як об'єктивні технічні параметри композицій формують загальний ландшафт музичної індустрії, яка музика набирає популярності та що для неї є характерним.

1.2 Дослідницькі питання та гіпотези

1) Як розподіляється популярність треків у різних жанрах?

При дослідженні питання була мета дізнатись чи відрізняється популярність пісень між різними жанрами. Очікується, що «новіші» (Hip-hop, Pop, Rock) жанри будуть більш популярні в порівнянні з більш «старими» (Classical, Folk).

2) Як розподіляється тривалість треків у різних жанрах?

3) Чи впливає explicit-контент на популярність треків.

При дослідженні була мета дізнатись чи грає explicit-контент хоч якусь роль в популярності пісень. Якщо так, то очікувалось, що він збільшує популярність в таких жанрах Hip-Hop і Rock і зменшує цю популярність в жанрах Classical і Jazz.

4) Які жанри мають вищу середню energy, danceability та loudness?

Очікувалось, що жанри Hip-Hop, Rock, Electronic мають більші значення цих показників, а жанри Classical і Jazz навпаки меншу.

5) Які специфічні жанри мають найбільшу кількість пісень? Які вони мають середню танцювальність, енергійність та популярність?

6) Яку частку explicit-треків мають найбільші за кількістю специфічні (нішеві) жанри? Які специфічні жанри мають найвищу частку explicit-треків?

- 7) Які жанри мають найбільш контрастні аудіо-профілі? І чи справді популярні треки схожі між собою?
- 8) Які аудіо-характеристики найбільше корелюють з популярністю у різних жанрах?
- 9) Пісні в мінорі звучать сумніше, ніж у мажорі?
- 10) Зменшення впливу фан-бази після певного порогу: Чи однаково зростає популярність треків у малих і великих артистів?
- 11) Як розподіляється популярність треків усередині найпопулярніших музичних альбомів? Чи є альбоми-шедеври без «прохідних» пісень?
- 12) Як виглядають альбоми-представники синдрому «Одного хіта»?
- 13) Яке співвідношення альбомів за успіхом?
- 14) Еволюція музики: Як змінювалися ключові аудіо-характеристики з роками?

ОПИС ДАНИХ

2.1 Походження даних та їх опис (оригінальний набір даних)

id (ідентифікатор): Унікальний Spotify ID треку.

name (назва): Назва пісні.

album_name (назва альбому): Назва альбому, до якого належить пісня.

artists (виконавці): Список виконавців, які виконують пісню.

danceability (танцювальність): Міра того, наскільки трек підходить для танців (0.0–1.0).

energy (енергійність): Перцептивна міра інтенсивності та активності (0.0–1.0).

key (тональність): Тональність треку (ціле число відповідно до стандартної нотації висоти звуку).

loudness (гучність): Загальна гучність треку в децибелах (дБ).

mode (лад): Лад треку (1 = мажор, 0 = мінор).

speechiness (мовленнєвість): Наявність розмовної мови у треку.

acousticness (акустичність): Ймовірність того, що трек є акустичним (0.0–1.0).

instrumentalness (інструментальність): Ймовірність того, що трек не містить

вокалу.

liveness (живість): Визначає наявність аудиторії в записі.

valence (емоційна позитивність): Музична «позитивність» треку (0.0–1.0).

tempo (темп): Оцінений темп треку в ударах за хвилину (BPM).

duration_ms (тривалість у мс): Тривалість треку в мілісекундах.

lyrics (текст пісні): Повний текст пісні (отриманий з LRCLIB).

year (рік випуску): Рік випуску треку.

genre (жанр): Основний жанр (один із 10 стандартних категорій).

popularity (популярність): Рейтинг популярності Spotify (0–100).

total_artist_followers (загальна кількість підписників виконавців): Сумарна кількість підписників усіх виконавців треку.

avg_artist_popularity (середня популярність виконавців): Середній рейтинг популярності всіх виконавців треку.

artist_ids (ідентифікатори виконавців): Список Spotify ID виконавців.

niche_genres (нішеві жанри): Специфічні піджанри, пов'язані з треком або виконавцем.

2.2 Опис очищення набору даних

Початковий незмінений файл (songs.csv) складався з 550 622 спостережень (рядків) та 24 змінних (стовпців). Дані містили як числові аудіо-характеристики треків, так і текстові метадані (назви, виконавці, тексти пісень).

Під час первинного огляду структури датасету було виявлено низку проблем, які вимагали попередньої підготовки (data cleaning) для приведення датасету до формату охайних даних (Tidy Data).

Перед початком трансформації було проведено базову перевірку на наявність пропусків та дублікатів:

Аналіз пропущених значень (NA): В оригінальному наборі було виявлено явні пропуски у змінних `name` (3 пропуски) та `album_name` (20 пропусків).

Аналіз дублікатів: За комбінацією змінних `name` (назва треку) та `artists` (виконавець) було знайдено 53 617 потенційних дублікатів, що є типовим для музичних платформ (наприклад, випуск одного треку як синглу та у складі альбому).

Процес очищення складався з декількох послідовних кроків, реалізованих за допомогою функцій пакету `dplyr` та `stringr` (мова R):

1. Видалення дублікатів та логічних аномалій:

Залишено лише унікальні комбінації треків та виконавців.

Перевірка на наявність аномалій показало, що в датасеті відсутні пісні з нульовою тривалістю та нульовим темпом.

2. Оптимізація розмірності:

Видалено змінні `id` та `artist_ids`, оскільки вони є системними ідентифікаторами бази даних Spotify і не несуть цінності для статистичного аналізу, але при цьому споживають оперативну пам'ять.

3. Стандартизація пропущених значень:

Для дотримання стандартів роботи з пропусками, в усіх текстових змінних було видалено зайві пробіли на початку та в кінці рядків. Усі порожні рядки ("") були програмно замінені на стандартизоване системне значення NA.

4. Приведення до формату "Tidy Data" (Охайні дані):

Змінні `artists` та `niche_genres` початково містили дані у форматі масивів (наприклад, ['Rock', 'Pop']), що порушує правило "одне значення — одна комірка". За допомогою регулярних виразів (Regex) (`?<=[\"]\).*?(?=[\"])`) з цих масивів було витягнуто лише перше (головне) значення для кожного спостереження.

5. Конструювання нової ознаки:

Створено нову змінну `explicit`. За допомогою регулярних виразів тексти пісень (`lyrics`) були перевірені на наявність нецензурної лексики (за визначенням словника маркерних слів). Треки отримали мітку "Explicit" або "Clean".

6. Перетворення типів даних (Data Typing):

Категорійні змінні (`genre`, `niche_genres`, `key`, `mode`, `explicit`) були перетворені на факторний тип.

2.3 Дескриптивні статистики очищеного набору даних

Після очищення фінальний розмір набору даних склав 477 565 спостережень та 23 змінні. Основні характеристики числових змінних наведено у таблиці нижче:

Змінна	Мінімум	Медіана	Середнє	Максимум	Ст. відхилення
acousticness	0.000	0.068	0.238	0.996	0.307
avg_artist_popularity	0.000	47.000	46.628	100.000	19.111
danceability	0.046	0.526	0.523	0.988	0.173
duration_ms	15027.000	223359.000	238259.669	4995315.000	97845.367
energy	0.000	0.724	0.677	1.000	0.246
instrumentalness	0.000	0.000	0.113	0.998	0.245
liveness	0.007	0.142	0.226	1.000	0.199
loudness	-44.868	-6.947	-7.803	0.000	3.856
popularity	0.000	14.000	17.371	98.000	16.845
speechiness	0.022	0.050	0.087	0.966	0.095
tempo	30.946	121.982	123.013	245.941	29.460
total_artist_followers	0.000	225797.000	2207518.338	295181900.000	8346439.186
valence	0.000	0.437	0.457	0.996	0.248
year	1900.000	2010.000	2007.463	2025.000	13.203

Очищений набір даних був збережений у форматах CSV (для звітності) та RDS (для збереження структури факторів у середовищі R) під назвою `songs_clean`.

EDA


3.1 Розподіли змінних

Для початку розглянемо розподіли змінних. Окрім того, що необхідно розуміти дані, з якими будемо працювати, наступні графіки вже на цьому етапі можуть показати певні тенденції та закономірності.

1) Популярність:

Розподіл популярності треків

Важливо: 25.8% усіх треків у датасеті мають популярність 0 і виключені з графіка.




Цікаво, що «мертві» пісні, або пісні з нульовою популярністю, складають 25.8% від усього набору даних. Їх було виключено з графіку розподілу в цілях кращої читабельності.

Спостерігаємо чітку правосторонню асиметрію. Абсолютна більшість композицій концентрується в зоні низької популярності (від 1 до 30 балів). Зі зростанням рейтингу кількість пісень різко падає, формуючи довгий правий хвіст. Треки з показником вище 80 балів (світові хіти) є статистичною рідкістю. Це ілюструє жорстку реальність музичної індустрії, принцип «переможець отримує все»: величезна маса контенту залишається малопомітною для широкої аудиторії, тоді як левову частку прослуховувань збирає вузька група топ-артистів.

2) Танцювальність

Розподіл танцювальності пісень (Danceability)

Нормальний розподіл. Червоний пунктир вказує на медіану, зелений - на середнє




Графік ілюструє нормальний (або максимально наближений до нього) розподіл показника танцювальності. На відміну від попереднього, сильно скошеного графіка популярності, тут ми спостерігаємо класичну симетричну дзвоноподібну форму. Головним статистичним підтвердженням нормальності цього розподілу є те, що медіана та середнє арифметичне значення практично повністю збігаються (маркери накладаються один на одного в центрі).

З точки зору музичної індустрії це свідчить про те, що абсолютна більшість пісень створюється з помірним, універсальним ритмом (із показником близько 0.5–0.6). Індустрія масово уникає крайнощів: як надмірної складності для танцю (0.0), так і екстремальних, вузькоспрямованих клубних ритмів (1.0).

3) Енергійність

Розподіл енергійності пісень (Energy)

Лівостороння асиметрія. Позначено медіану сірим та середнє зеленим.




Графік демонструє яскраво виражену лівосторонню асиметрію. На відміну від нормального розподілу, тут спостерігається класична статистична закономірність для скошених даних: наявність довгого лівого хвоста (треків із низькою енергійністю) «зміщує» середнє арифметичне (зелена лінія) вліво, роблячи його меншим за медіану (сіра лінія). Основна маса пісень у датасеті має високі показники енергійності, з медіаною, що знаходиться ближче до позначки 0.7. Такий розподіл є цілком логічним для сучасної музичної індустрії: більшість популярних жанрів (поп, хіп-хоп, EDM, рок) створюються з використанням синтезаторів, щільних басів та гучного мастерингу, щоб звучати максимально інтенсивно. Натомість треки з низькою енергією (0.0 - 0.3), такі як акустичні балади, класична музика чи ембієнт, складають абсолютну меншість у загальному каталозі.

4) Тональність

Розподіл музичних тональностей пісень (Key)

Найпопулярнішими є зручні для гри G (Соль), C (До) та D (Ре)




Розподіл категорійної змінної Key (тональність) демонструє виражену нерівномірність у виборі музичних ключів. Найбільша кількість композицій у датасеті написана в тональностях G (Соль-мажор/мінор), C (До-мажор/мінор) та D (Ре-мажор/мінор).

З точки зору музичної теорії та практики, це абсолютно закономірний результат: саме ці тональності є найзручнішими та «найбільш відкритими» для гри на гітарі (використання базових відкритих акордів) та клавішних інструментах (мінімальна кількість чорних клавіш). Натомість складніші для виконання тональності з великою кількістю дієзів чи бемолів (наприклад, D# або G#) є найменш популярними серед масових виконавців. Це наштовхнуло на думку перевірити відношення тональностей з плином часу.

5) Гучність

Розподіл гучності треків (Loudness)

Графік наближено до діапазону [-25, 0] dB. Червоний пунктир — медіана; зелений — середнє




Основна маса музики живе в діапазоні від -15 dB до 0 dB. Але в датасеті є аномальні треки з гучністю -40 або -60 dB (це може бути шум вітру, ASMR, аудіокниги тощо).

На графіку розподілу гучності ми спостерігаємо сильну лівосторонню асиметрію з яскраво вираженим піком у зоні від -7 до -4 dB. Це є прямим наслідком так званої «Війни гучностей» (Loudness War) у музичній індустрії: тенденції мастеринг-інженерів максимізувати гучність треків майже до межі спотворення (0 dB), щоб пісня звучала агресивніше та виділялася на фоні інших під час ротації на радіо чи у плейлистах.

6) Мовленнєвість

Розподіл розмовної мови (Speechiness)



Spotify має офіційну документацію для speechiness, і там є чіткі пороги:


- Менше 0.33: Звичайна музика.
- 0.33 - 0.66: Музика з великою кількістю тексту (переважно реп).
- Більше 0.66: Виключно розмовний контент (подкасти, вірші).

Музики з відносно невеликою кількістю слів набагато більше.


7) Акустичність, інструментальність, живість та емоційна позитивність

Розподіл специфічних акустичних характеристик

Вісь Y логарифмована




Розподіл емоційної окраси пісень (Valence)



8) Темп

Розподіл темпу музики (BPM)

Мультимодальний розподіл: піки відповідають стандартам популярних жанрів



Графік демонструє мультимодальний розподіл. На відміну від нормального розподілу, де значення групуються навколо єдиного центру, тут ми спостерігаємо одразу кілька виражених локальних максимумів. Хоча середнє значення та медіана знаходяться на рівні 120 BPM, вони не повною мірою описують структуру даних, оскільки темп жорстко диктується жанровими стандартами:

Глобальний максимум (120-130 BPM): Формує найбільший кластер треків. Це індустріальний золотий стандарт для поп-музики, хаусу, диско та радіо-хітів (темп, що найкраще синхронізується з активним кроком та базовою танцювальною ритмікою).

Лівий локальний пік (90-100 BPM): Відповідає класичним стандартам хіп-хопу, R&B та реггетону — жанрам, які орієнтовані на більш повільний ритм.


Правий локальний пік (140-150 BPM): Відображає кластер високоінтенсивної музики, що включає як гітарні жанри (швидкий рок, панк), так і агресивні напрямки електронної музики (дабстеп, треп).

Таким чином, темп не є випадковою величиною, а слугує чітким маркером жанрової приналежності композиції.

9) Тривалість

Розподіл тривалості пісень

Графік наближено до 10 хвилин (відкинуто екстремальні викиди)



Аналіз тривалості композицій виявив жорстку стандартизацію у сучасній музичній індустрії. Через наявність екстремальних викидів (треки тривалістю понад 60-80 хвилин) для коректної візуалізації діапазон графіка було обмежено до 10 хвилин.


Розподіл має яскраво виражену правосторонню асиметрію з абсолютним піком у діапазоні 3–4 хвилин. Це підтверджує вплив класичного «радіоформату», а також сучасних алгоритмів стримінгових платформ, які економічно

стимулюють артистів створювати коротші треки (близько 3 хвилин) для збільшення загальної кількості прослуховувань.

10) Рік випуску

Історичний розподіл музики на Spotify


Логарифмічна шкала (Y) демонструє експоненційне зростання каталогу



Графік побудовано з використанням логарифмічної шкали, оскільки на лінійній шкалі репрезентація ранніх років (до 1950-х) була б візуально нульовою через колосальну різницю в обсягах. Окрім очікуваного історичного зростання каталогу, візуалізація виявляє різкий структурний зсув (стрибок) на межі 1999 та 2000 років. Це не є відображенням реального музичного буму, а свідчить про методологію формування самого датасету: алгоритм збору даних явно віддавав пріоритет цифровій епосі та релізам XXI століття, тоді як музика XX століття представлена значно вужчою вибіркою.

Різке падіння кількості треків у правому краю графіка є артефактом збору даних: подальший аналіз виявив, що за 2024-2025 роки представлено лише 3 треки.

11) Загальна кількість підписників виконавців



Оскільки вісь X має логарифмічну шкалу, і на ній дані утворюють симетричну форму «дзвона», це означає, що реальні дані екстремально скошені вправо. Це типова картина для індустрії розваг: величезна кількість нішевих виконавців із невеликою аудиторією та мала кількість мегазірок із десятками чи сотнями мільйонів підписників.


12) Середня популярність виконавців



Середня популярність артистів демонструє схожий на класичний нормальний розподіл із центром біля позначки 45-50 балів. Дуже цікаво порівняти цей графік із розподілом популярності окремих треків. Якщо серед окремих пісень спостерігається величезна кількість композицій із нульовою популярністю, то агрегація на рівні артистів згладжує ці екстремуми. Це свідчить про те, що абсолютна більшість музикантів у датасеті є стабільними «середняками», які завдяки наявності хоча б кількох успішних релізів підтримують свій загальний рейтинг на адекватному рівні, уникаючи падіння в абсолютний нуль.

13) Лад


Розподіл пісень за музичним ладом (Mode)



Музичний лад демонструє стабільну перевагу мажорних композицій над мінорними. Це відображає загальну орієнтацію масової музичної індустрії на створення позитивного, легкого для сприйняття контенту. Незважаючи на те, що мінорні тональності активно використовуються в специфічних жанрах та ліричних композиціях, мажор залишається індустріальним стандартом для радіо-хітів та танцювальної музики.


14) Відвертий контент

Наявність нецензурної лексики (Explicit Content)



Розподіл змінної Explicit показує, що абсолютна більшість каталогу Spotify складається з треків, придатних для трансляції (radio-friendly) без вікових обмежень. Частка треків із позначкою Explicit є значно меншою, що пояснюється жорсткими правилами радіостанцій та цензурою в рекламних кампаніях. Переважно ця позначка концентрується у специфічних жанрах, таких як хіп-хоп та сучасний реп. Важливо зазначити, що ця змінна створювалася з використанням наданого тексту до пісень. Створений словник нецензурної лексики є обмеженим, тому допускається, що деяку частку пісень хибно вважаємо чистими.


15) Жанр



Змінна Genre (узагальнені жанри) відображає структуру музичного каталогу за кількістю випущених треків. Графік демонструє, які саме жанри є найбільш масовими у виробництві. Rock, Electronic та Pop формують найбільшу частку датасету, що свідчить про високу продуктивність артистів у цих напрямках. Важливо зазначити, що цей розподіл ілюструє виключно обсяг створеного контенту (пропозицію на ринку), а не рівень його прослуховувань чи комерційного успіху.

3.2 Матриця кореляцій (Спірмен)

Для обчислення матриці кореляцій було обрано ранговий коефіцієнт кореляції Спірмена, а не стандартний коефіцієнт Пірсона. Це зумовлено природою даних: багато змінних (наприклад, total_artist_followers або popularity) мають яскраво виражені викиди та нелінійний розподіл. Коефіцієнт Спірмана є робастним (стійким) до таких аномалій і краще виявляє загальні монотонні залежності між аудіо-характеристиками.



З теплової діаграми видно, що найсильніша позитивна кореляція спостерігається між `avg_artist_popularity` та `total_artist_followers` (0.92). Це логічно, оскільки популярність артиста напряму пов'язана з розміром його аудиторії: більше підписників → вища середня популярність треків.


Серед аудіо характеристик найбільша позитивна кореляція, між `energy` та `loudness` (0.76), що також очікувано, адже більш енергійні треки зазвичай мають вищу гучність.

Найсильніша негативна кореляція спостерігається між `acousticness` та `energy` (-0.74): акустичні треки зазвичай менш енергійні.


Водночас важливо, що популярність треків (`popularity`) не має сильної кореляції з жодною з аудіо характеристик, всі значення близькі до нуля. Натомість вона помірно корелює лише з кількістю підписників артиста (0.33).

3.3 Графіки до дослідницьких питань та гіпотез

1) Як розподіляється популярність треків у різних жанрах?




Перше, що було створено це вусата скринька з популярності за жанрами. З графіку можна побачити, що двома найпопулярнішими жанрами є Нір-Нор та R&B. Найменш популярним є жанр Blues, а всі інші жанри загалом знаходяться на одному рівні популярності. Також було створено скрипковий графік, щоб зрозуміти щільність пісень у жанрі.



Скрипковий графік є доволі передбачуваним. У всіх жанрах є висока кількість пісень з низькою популярністю, а зі збільшенням популярності кількість пісень зменшується.

Далі було проведено аналіз саме для популярних пісень (popularity ≥ 50). Перше, що потрібно дізнатись, це те, скільки пісень перетнули відмітку популярності у 50 значень.





Аналіз популярності в розрізі жанрів виявляє цікавий статистичний парадокс, який демонструє різницю між відносною та абсолютною успішністю музичних напрямків.

Діаграма розмаху (Boxplot) показує, що найбільш стабільно популярними (за медіаною) є жанри Нір-Нор та R&B. Натомість медіана жанру Rock є однією з найнижчих (12). Однак при фільтрації датасету та виділенні лише об'єктивно успішних треків (із популярністю 50+ балів), абсолютним лідером за кількістю хітів стає саме Rock.

Цей феномен пояснюється розміром самого каталогу. Жанр Rock представлений у датасеті найбільшою вибіркою (понад 174 тис. композицій). Гігантська кількість маловідомих або старих рок-треків зміщує загальну медіану жанру вниз. Проте завдяки масштабам виробництва, навіть невелика частка успішних рок-композицій в абсолютних значеннях (5569 треків) перевищує кількість хітів у жанрі Нір-Нор (4522 треки), чий каталог уп'ятеро менший. Таким чином, Нір-Нор має вищу «конверсію» в успіх, тоді як Rock домінує в топі завдяки історичному обсягу створеного контенту.

Далі було зроблено вусату скриньку та скрипковий графік для пісень з популярністю 50 і більше:






Скрипковий графік дозволяє детально оцінити не лише медіанні значення, але й щільність розподілу всередині цього сегмента. Усі жанри без винятку демонструють «важкий низ» (максимальну концентрацію треків у діапазоні 50-60 балів) та довгі хвости в напрямку максимальних значень. Це ілюструє жорстку конкуренцію в індустрії: навіть серед об'єктивно популярної музики абсолютна більшість композицій має помірний успіх, тоді як світові мега-хіти (80-100 балів) залишаються рідкісними статистичними викидами незалежно від жанру.

Щодо міжжанрової ієрархії, загальні лідери зберігають позиції (Нір-Нор та R&B мають найвищу медіану — 57 балів). Однак варто відзначити феномен жанру Rock: якщо в загальному (нефільтрованому) каталозі за медіаною він займав останні позиції, то в сегменті хітів він демонструє потужну динаміку, впевнено закріпившись у п'ятірці лідерів (медіана 56).

Останнє, що було зроблено для дослідження цього питання, це еволюція медіанної популярності по рокам, від 1955 до 2023. Пісні до 1955 було відкинуто, адже їх є не дуже багато, а саме 1265 (0.26% від всього датасету) і їхнє врахування погіршило би читабельність графіка.




Неочікуваною тенденцією, яку можна побачити з графіків, є те, що жанри збільшували свою популярність та досягали свого піку між 1970 і 1990 роками, після чого популярність почала спадати у 2000-х роках і знову зростати у 2010-х.

З цього з'являється гіпотеза щодо її походження. Можливо це не старі пісні є більш популярними в цілому, а просто до Spotify-ю було додано лише популярні, а інші просто забулись і загубились, не потрапивши до нашого датасету. Це приклад статистичного спотворення «упередження виживання» (Survivorship Bias).

2) Як розподіляється тривалість треків у різних жанрах?

Для того, щоб дати відповідь на це питання, було використано скрипковий графік. Проте через те, що в датасеті є пісні з тривалістю до 90 хвилин, було вирішено побудувати графік лише для пісень до 10 хвилин. Всього було відкинуто 3804 пісні (0.8% від всього датасету).




Жанри з графіку можна поділити на дві групи за значенням медіани: з більшою (R&B, Electronic, Rock, Blues) і меншою (Hip-Hop, Pop, Folk, Jazz, Classical, Country) тривалістю.

Пісні у жанрах Rock, Folk, Jazz, Classical мають великий діапазон тривалості пісень, тоді як пісні у жанрах Hip-Hop, Pop, Country загалом приймають значення від 2.5 хв до 5 хв, а жанри R&B, Blues, Electronic мають тенденцію бути саме довгими в порівнянні з іншими жанрами.


3) Чи впливає explicit-контент на популярність треків?

Для перевірки цієї гіпотези спочатку було побудовано вусату скриньку розподілу популярності за наявністю explicit content для всього датасету:



З графіка видно, що медіана популярності еxPLICIT пісень дорівнює 18, тоді як для clean пісень вона становить 13. Це вказує на загальну тенденцію до вищої популярності треків із позначкою explicit. Цей факт викликав гіпотезу, що це пов'язано з найбільшою часткою explicit пісень саме в жанрі Нір-Нор, який є найпопулярнішим в нашому датасеті. Тому зробимо графік популярності за наявністю explicit content по жанрах.

Розподіл популярності за жанрами та наявністю матів



З графіку можна побачити, що для всіх жанрів пісні з explicit-content-ом є більш популярними. Найбільша різниця є в жанрах R&B, Hip-Hop, Country, Classical та Pop.

Задля цікавості було проведено більш детальний аналіз для explicit пісень в жанрі Classical. Розглянемо 15 найпопулярніших explicit пісень в цьому жанрі. Більшість з них належать до альбому «Hamilton (Original Broadway Cast Recording)», пісні в якому мають жанри Hip-Hop, R&B, Pop. Проте сам альбом є мюзиклом і був записаний для театру, через що, ймовірно, був класифікованим як Classical.

```
> print(explicit_classical, n = 20)
```

A tibble: 857 x 4


name	artists	album_name	popularity
<chr>	<chr>	<chr>	<dbl>
1 The Other Side	Hugh Jackman	The Greatest Showman (Original Motion Picture So...	74
2 My Shot	Lin-Manuel Miranda	Hamilton (Original Broadway Cast Recording)	73
3 Say No to This	Jasmine Cephas-Jones	Hamilton (Original Broadway Cast Recording)	70
4 Right Hand Man	Lin-Manuel Miranda	Hamilton (Original Broadway Cast Recording)	69
5 Yorktown (The World Turned Upside Down)	Original Broadway Cast of Hamilton	Hamilton (Original Broadway Cast Recording)	69
6 What'd I Miss	Daveed Diggs	Hamilton (Original Broadway Cast Recording)	68
7 Your Obedient Servant	Leslie Odom Jr.	Hamilton (Original Broadway Cast Recording)	68
8 Cabinet Battle #1	Christopher Jackson	Hamilton (Original Broadway Cast Recording)	67
9 Stay Alive	Original Broadway Cast of Hamilton	Hamilton (Original Broadway Cast Recording)	67
10 The Reynolds Pamphlet	Original Broadway Cast of Hamilton	Hamilton (Original Broadway Cast Recording)	67
11 The Story of Tonight - Reprise	Okieriete Onaodowan	Hamilton (Original Broadway Cast Recording)	67
12 Washington on Your Side	Leslie Odom Jr.	Hamilton (Original Broadway Cast Recording)	67
13 The Election of 1800	Daveed Diggs	Hamilton (Original Broadway Cast Recording)	66
14 Sweet Dreams, TN	The Last Shadow Puppets	Everything You've Come To Expect (Deluxe Edition)	65
15 The Adams Administration	Original Broadway Cast of Hamilton	Hamilton (Original Broadway Cast Recording)	64
16 Blow Us All Away	Ariana DeBose	Hamilton (Original Broadway Cast Recording)	63
17 Candy Store	Jessica Keenan Wynn	Heathers: The Musical (World Premiere Cast Recor...	63
18 Dead Girl Walking	Barrett Wilbert Weed	Heathers: The Musical (World Premiere Cast Recor...	63
19 Greased Lightnin' - From "Grease"	John Travolta	Grease (The Original Motion Picture Soundtrack)	63
20 Meant to Be Yours	Ryan McCartan	Heathers: The Musical (World Premiere Cast Recor...	63

i 837 more rows

Це наводить на думку, що в інших жанрах, для яких explicit-content загалом не є характерним і які представлені невеликою вибіркою, пісні з explicit content часто перебувають на межі кількох жанрів. Імовірно, їхня вища популярність може пояснюватися тим, що за своїми ознаками їх також можна віднести до жанру Нір-Нор.

Розподіл популярності нішевих жанрів (Classical)

Відсортовано за медіаною. Справа вказано розмір вибірки (n) для кожної ніші



Декомпозиція макро-жанру Classical на нішеві піджанри виявляє серйозні структурні аномалії в датасеті. Діаграма розмаху демонструє глибоку поляризацію всередині категорії:


1. *Традиційна класика vs. Комерційний контент*: традиційний академічний репертуар (ніші classical, chamber music, baroque, contemporary classical) формує низ рейтингу з медіанною популярністю, що наближається до нуля. Натомість успіх макро-жанру майже повністю тримається на кінематографічному та театральному контенті: лідерські позиції займають score (інструментальна музика до кіно/ігор), soundtrack та musicals (куди входить виявлений раніше «Hamilton»). Значний розмір вибірки мюзиклів (n=4793) доводить, що це масивний і стабільно популярний кластер, а не статистична випадковість.

2. *Алгоритмічна міскласифікація*: найціннішим інсайтом цієї візуалізації є емпіричне доведення недосконалості системи тегування Spotify. Графік фіксує наявність усередині класичної музики абсолютно нерелевантних ніш: east coast hip hop (n=29), alternative metal (n=38), acid rock (n=51) та alt country (n=20). Імовірно, наявність оркестрових семплів, акустичних вступів або специфічних кросвер-колаборацій змушує алгоритми платформи хибно відносити важкий метал чи реп до академічної музики. Цей факт підкреслює необхідність критичного ставлення до агрегованих категорійних даних при роботі з музичними базами.

4) Які жанри мають вищу середню energy, danceability та loudness?

Для відповіді на це питання, було вирішено зробити стовпчикові діаграми з середнім значенням:


Середня енергійність за жанрами



Графік підтверджує очікування: найенергійнішими жанрами є Rock, Electronic, Hip-Hop. Це логічно пояснюється тим, що ці жанри спираються на щільний бас, гучні барабанні партії та інтенсивне електронне чи гітарне звучання.


На противагу їм, найменш енергійними виявилися Classical та Jazz. Ці жанри є переважно акустичними, відзначаються спокійною динамікою та відсутністю агресивного ритмічного звуку.

Середня танцювальність за жанрами



Наступним кроком було досліджено показник танцювальності (danceability) за допомогою відповідного стовпчикового графіка. Лідером є Нір-Нор, за ним йдуть R&B та Electronic. Цей результат є абсолютно закономірним, оскільки ці жанри історично створювалися з акцентом на виражений біт, що стимулює до ритмічних рухів.


Найменш танцювальними жанрами є Rock та Classical. Хоча Rock є дуже енергійним, його метрика танцювальності низька, оскільки цей жанр більше орієнтований на драйв, складну інструментальну частину та концертне прослуховування, а не на стандартний танцювальний ритм.



Найгучнішими жанрами є Rock, Electronic та Нір-Нор. Це передбачувано, адже ці жанри створюються щоб звучали максимально щільно та агресивно. Найбільш тихими жанрами є Classical та Jazz. Для цих стилів критично важливо зберегти природний і широкий динамічний діапазон живих інструментів, тому їх намагаються не піддавати сильній компресії.

5) Які специфічні жанри мають найбільшу кількість пісень? Які вони мають середню танцювальність, енергійність та популярність?

Для відповіді на це питання було відібрано Топ-15 наймасовіших нішевих жанрів та побудовано діаграму розсіювання, яка формує їхній акустичний профіль:



Абсолютна більшість наймасовіших ніш є піджанрами макро-категорії Rock (що є наслідком того факту, що Rock складає понад 36% усього датасету). Можна виділити структурні патерни:


- Верхній лівий кут: Тут згруповані найменш популярні ніші (death metal, black metal, doom metal), які характеризуються високою енергійністю, але вкрай низькою танцювальністю.
- Права частина графіка (масовий кластер): Абсолютна більшість наймасовіших ніш концентрується в зоні з помірною або вищою за середню танцювальністю. Загалом вони демонструють рівень популярності середнього сегмента.
- Лідери популярності: Три найуспішніші ніші серед масових (alternative metal, classic rock та country) виділяються з-поміж інших: окрім помірної танцювальності, вони мають стабільно високу енергійність.

Підсумок: наймасовіші нішеві жанри музичної індустрії, як правило, підпорядковуються єдиному акустичному стандарту — вони мають середню танцювальність (близько 0.5) та високу енергійність (від 0.6 і вище).

Також варто звернути увагу на жанр musicals, який належить до Classical і є лідером за масованістю. Це може свідчити про те, що мюзикли ближчі до масової аудиторії та потенційно можуть включати більш сучасні або змішані за стилем композиції, зокрема такі, що містять explicit-контент.

6) Яку частку explicit-треків мають найбільші за кількістю специфічні (нішеві) жанри? Які специфічні жанри мають найвищу частку explicit-треків?

Спершу було відібрано топ-15 найбільших за кількістю пісень нішевих жанрів датасету. Як було доведено раніше, ці позиції переважно займають піджанри макро-категорії Rock.




З графіка видно, що частка explicit-контенту значно відрізняється між нішевими жанрами. Найвищу частку explicit-треків мають піджанри року,

зокрема alternative metal, death metal, emo та black metal, що відповідає очікуванням, оскільки ці жанри часто містять більш агресивну або емоційно насичену тематику.

Водночас жанри, пов'язані з Jazz, Blues та близькими до них напрямками (наприклад, ccm, classic soul, classical country), майже не містять explicit-контенту. Хоча musicals формально належить до класичного напрямку, у ньому уже спостерігається помітна частка explicit-треків, що підтверджує минулу гіпотезу.

Проте картина кардинально змінюється, якщо змінити фокус дослідження: а саме відкинути прив'язку до масовості та знайти жанри з найвищою абсолютною концентрацією:



Для кращої репрезентації були обрані ті нішеві жанри, які мають принаймні 50 треків у каталозі. Хіп-хоп (який в цьому наборі даних також включає в себе Rap) є монополістом на нецензурну лексику в музичній індустрії. Це перевертується з попереднім графіком на сторінці 30: тільки в цьому жанрі відсоток пісень з наявністю explicit-контенту перевищує 76% (8 584 проти 27 838).

7) Які жанри мають найбільш контрастні аудіо-профілі? І чи справді популярні треки схожі між собою?

Жанрові аудіо-профілі за ключовими характеристиками

Використанні медіани аудіо-характеристик

Жанр	acousticness	danceability	energy	instrumentalness	liveness	loudness	speechiness	tempo	valence
Rock	0	0.43	0.88	0	0.17	-5.92	0.06	124.81	0.36
R&B	0.23	0.64	0.59	0	0.13	-7.67	0.06	111.4	0.56
Pop	0.16	0.55	0.65	0	0.13	-7.42	0.04	120.9	0.5
Jazz	0.81	0.54	0.3	0	0.12	-12.59	0.04	110.52	0.45
Hip-Hop	0.09	0.71	0.69	0	0.14	-6.54	0.22	109.86	0.53
Folk	0.34	0.58	0.54	0	0.12	-8.55	0.04	117.01	0.54
Electronic	0.03	0.62	0.79	0.01	0.13	-6.38	0.05	126.99	0.39
Country	0.37	0.56	0.54	0	0.13	-8.3	0.03	119.76	0.52
Classical	0.73	0.46	0.38	0	0.13	-10.72	0.04	113.42	0.34
Blues	0.38	0.55	0.56	0	0.14	-8.84	0.04	115.79	0.59


З графіка видно, що різні жанри чітко відрізняються за своїми аудіо-профілями, і ці відмінності добре узгоджуються з їхньою природою.

Наприклад, Hip-Hop та Electronic характеризуються високою енергійністю та танцювальністю, що робить їх більш придатними для масового прослуховування. Jazz і Classical мають вищу акустичність і нижчу енергію, що відображає їхню більш інструментальну та “живу” природу.

Важливо, що instrumentalness залишається низьким для всіх жанрів, що підтверджує домінування вокалу в датасеті.


Варто відзначити показник speechiness (мовленнєвість): він майже повністю сконцентрований у жанрі Hip-Hop, що є очікуваним, оскільки цей жанр базується на репі та ритмічному мовленні. В інших жанрах цей показник залишається на дуже низькому рівні.

Порівняння жанрів за аудіо-профілями





Тепер потрібно порахувати які жанри найбільш відрізняються за аудіо характеристиками. Візьмемо топ-5 жанрів за кількістю представників та використаємо евклідову відстань між ознаками "danceability", "energy", "loudness", "speechiness", "acousticness", "instrumentalness", "liveness", "valence", "tempo" (щоб ознаки loudness і tempo не сильно впливали стандартизуємо їх від 0 до 1).


Примітно, що Country та Folk мають дуже подібні профілі. Це також видно з попереднього графіку. Не дивлячись на їх схожість, Country має більшу популярність з меншою кількістю представників в даному датасеті. Те саме можна сказати про Electronic та Rock з єдиною помітною різницею по danceability.



Матриця відстаней показує, що жанри справді мають помітно різні аудіо-профілі. Найменші відстані спостерігаються між жанрами, які мають схожі характеристики звучання, тоді як найбільші — між жанрами з найбільш контрастними профілями. За графіком видно, що Rock є одним із найбільш відмінних жанрів: його відстані до більшості інших жанрів вищі, ніж у багатьох інших пар. Особливо сильна відмінність спостерігається між Rock і Jazz, а також між Rock і Hip-Hop / R&B.

Тепер подивимося чи буде зменшуватися відстань між треками зі збільшенням популярності, чи насправді популярні треки схожі (візьмемо жанри з найбільшою відстанню з попереднього графіку):






Щоб перевірити гіпотезу про те, що комерційний успіх вимагає уніфікації звучання, було проаналізовано динаміку акустичної відстані між найконтрастнішими жанрами у розрізі децилів популярності (від найменш популярних 10% до топ-10% хітів).


Графік емпірично доводить явище «акустичної гомогенізації» (homogenization of popular music) масової музики. У децилях 1–4 популярності жанри зберігають свою унікальну ідентичність, а математична дистанція між ними навіть зростає. Проте, при переході до децилів 7–10, відстань стрімко скорочується. Це свідчить про існування негласного «поп-стандарту»: для того, щоб стати глобальним хітом, трек повинен оптимізуватися під масового слухача. Як наслідок, об'єктивно різні за своєю природою рок- та джаз-композиції на вершинах чартів починають звучати статистично схоже.


Використання децилів замість абсолютних значень популярності на осі X дозволило уникнути статистичного шуму (проблеми малих вибірок) для високопопулярних треків. Оскільки кожен дециль містить рівно 10% вибірки, усі точки на графіку мають однакову статистичну вагу, що гарантує надійність виявленого тренду гомогенізації.


8) Які аудіо-характеристики найбільше пов'язані з популярністю у різних жанрах і чи правдиві стереотипи жанрової музики?



Як ми бачимо, суттєвих різниць в кореляціях нема. Для наочності подивимося їх bubble scatter plot для танцювальності і енергійності:








Популярність треків більше залежить від танцювальності, ніж від енергійності, але сила цього ефекту суттєво різниться між жанрами: від дуже сильної (Hip-Hop, Pop) до майже відсутньої (Classical, Jazz).

9) Пісні в мінорі звучать сумніше, ніж у мажорі?

Змінна *valence* відповідає за "щастя" треку (ближче до 1 — радісні, до 0 — депресивні). Побудуємо графіки щільності (Density plots), щоб порівняти їхній розподіл.




З графіка видно, що розподіли показника valence для мінорного та мажорного ладів значною мірою перекриваються. Треки у мінорі частіше зосереджені ближче до «сумних» емоцій, тоді як мажорні композиції мають більшу частку значень у більш «позитивному» та «світлому» настрої.

Водночас різниця не є радикальною: значне перекриття розподілів показує, що емоційне забарвлення треків не визначається лише музичним ладом.

10) Зменшення впливу фан-бази після певного порогу: Чи однаково зростає популярність треків у малих і великих артистів?

Спочатку подивимося на розподіл popularity у різних розмірах фан-бази:



Бачимо очікуване збільшення популярності треків зі збільшенням фан-бази, але чомусь навіть у артистів, у яких більше 100 млн підписників, є частка треків з популярністю 0 (149 штук – 14%).


Перша гіпотеза: це якісь приховані треки чи помилка датасету, але після перевірки ми дізналися, що це просто не найпопулярніші треки з не найпопулярніших альбомів артистів або ремікси, які все одно мають 100 млн прослуховувань, тобто значення популярності визначається складніше, ніж просто за кількістю прослуховувань.

Справа в тому, що метрика popularity у Spotify - це не кількість прослуховувань за весь час. Це динамічна метрика, яка має вбудоване знецінення

часом. Якщо пісня Тейлор Свіфт вийшла 10 років тому, зібрала 100 мільйонів прослуховувань, але прямо зараз її ніхто не слухає, то її popularity впаде до нуля. Алгоритм оцінює лише поточний хайп.

Чи зменшується вплив фан-бази після певного порогу?


Показано лише артистів із кількістю підписників до 100 млн



З графіка видно, що популярність треків зростає разом із кількістю підписників артиста, однак цей зв'язок є нелінійним.

На малих значеннях фан-бази популярність зростає особливо різко, однак у міру подальшого збільшення аудиторії темп цього зростання поступово сповільнюється. Отже, найбільший приріст популярності спостерігається саме на нижчих і середніх рівнях фан-бази, тоді як для дуже великих артистів додаткове збільшення кількості підписників дає вже менший приріст popularity.

11) Як розподіляється популярність треків усередині найпопулярніших музичних альбомів? Чи є альбоми-шедеври без «прохідних» пісень?




Топ-10 найуспішніших альбомів датасету розкриває цікаву закономірність: статус легендарного альбому не гарантує рівномірного успіху всіх його композицій. Більшість релізів демонструють високу дисперсію, хоча в порівнянні з наступним графіком, далеко не найвищу.

Проте існують винятки: наприклад, альбом «AM» (Arctic Monkeys) має екстремально високу медіану та щільний розподіл, претендуючи на статус рідкісного «no-skip» альбому. Іншим цікавим кейсом є мюзикл «Hamilton», який було вже згадано. Його щільний кластер популярності пояснюється специфікою споживання: слухачі зазвичай відтворюють театральні саундтреки лінійно, від початку до кінця, не виділяючи окремі сингли.

12) Як виглядають альбоми-представники синдрому «Одного хіта»?

Тобто альбоми, де є один супер-хіт (наприклад, популярність > 75), але решта альбому практично або взагалі невідома (величезний розрив між медіаною та максимумом).




Для дослідження феномену одного хіта було застосовано евристичний фільтр: відібрано альбоми, де присутній глобальний хіт (popularity > 75), але медіана решти композицій наближається до нуля. Діаграма розмаху яскраво візуалізує цю аномалію: на графіку (наприклад, альбом «Gangsta's Paradise») ми бачимо єдиний викид-хіт на позначці 80+, тоді як весь інший матеріал біля нульової відмітки. Це свідчить про те, що в цих випадках альбом як формат не спрацював, він став лише фізичним/цифровим контейнером для дистрибуції однієї пісні, не зумівши перетворити аудиторію хіта в прихильників артиста.

13) Яке співвідношення різновидів альбомів за успіхом?

Візьмемо всі повноцінні альбоми (від 6 пісень), де є хоча б один супер-хіт (популярність > 75). Поділимо їх на 3 категорії:

1. Альбоми-бестселери (Усі пісні хіти): Медіана популярності > 55 (тобто більшість пісень в альбомі дуже популярні).
2. Синдром Одного Хіта: Медіана популярності < 30 (є одна супер-пісня, але більше половини альбому майже ніхто не слухає).
3. Середина: Медіана від 30 до 55 (є супер-хіт і ще кілька непоганих пісень).




Результати спростовують стереотип про домінування альбомів «одного хіта», на них припадає лише 16% ринку. Абсолютна більшість (49%) представляє збалансований сценарій: супер-хіт працює як маркетинговий гачок, який успішно затягує слухача, змушуючи його споживати й інші, помірно популярні треки релізу. Ще 35% становлять альбоми-бестселери, де майже кожен трек стає самостійним хітом (висока медіана).

Висновки: Що таке успішний альбом з точки зору даних?

Спираючись на проведений аналіз, можна стверджувати, що справжнє мірило успішності альбому не його пікові показники найкращої пісні, а його внутрішня конверсія. Успішний альбом - це продукт, здатний трансформувати випадкового слухача одного супер-хіта в лояльного споживача всього каталогу (що математично виражається у високій медіані та низькій дисперсії). Якщо ж хіт існує в ізоляції від решти треків, це успіх конкретної пісні, але маркетинговий провал альбому як формату.

14) Еволюція музики: Як змінювалися ключові аудіо-характеристики з роками?

Для більш правильного відображення графіків будемо брати інтервал років, де представлено достатню кількість пісень (1924-2023):




Графік яскраво ілюструє технологічний зсув. Спостерігається сильна зворотна залежність у часі між acousticsness та energy. У першій половині XX століття (акустична ера) музика мала екстремально високі показники акустичності та низьку енергійність. Починаючи з 1950-х років (поява електрогітар, а згодом синтезаторів та цифрового мастерингу), тренд кардинально змінюється: акустичність стрімко знижується, поступаючись місцем інтенсивному, високоенергійному звучанню, яке домінує й досі.

Побудуємо графік зміни гучності, акустичності та розподілу energy з роками:


Еволюція музики: 1960 - 2023

Занепад живої акустики та зростання загальної гучності




По-перше, спостерігається стрімкий занепад чистої акустики, яка витісняється електронними інструментами, синтезаторами та комп'ютерним продакшеном (падіння середнього показника з 0.7 до 0.2). По-друге, паралельне зростання графіка гучності є відбитком «Війни гучностей» (або ж Loudness War) - індустріальної гонки за максимальним рівнем звукового тиску в комерційній музиці.

Як змінювався розподіл енергії з роками




У першій половині XX століття (це епоха джазу, блюзу та раннього свінгу) медіана розподілу знаходилася в зоні низької енергії (0.2 - 0.4). Однак, починаючи з 1960-х років (це є розквітом рок-музики) і до сьогодні, «центр мас» невпинно зміщується вправо. Це доводить, що високоінтенсивне, агресивне звучання стало абсолютним стандартом для сучасного масового слухача.

Тепер розглянемо чи є якісь цікаві тенденції в зміні ладів і тональностей з роками. Для аналізу з датасету було виключено композиції, випущені до 1950 року. Це рішення зумовлене недостатнім обсягом вибірки в ранні періоди звукозапису, що створювало високий шум.



З графіка видно, що історично мажор домінував (приблизно 70–80% треків), однак з часом частка мінору поступово зростає. Особливо після 2000-х видно стабільний тренд: музика стає більш «мінорною», тобто емоційно темнішою або меланхолійнішою.



Побудована візуалізація динаміки тональностей за період 1950-2023 років дозволяє зробити висновок про те, що попри появу нових жанрів (наприклад, перехід від класичного року до електронної танцювальної музики та хіп-хопу), пропорції використання базових тональностей залишаються відносно незмінними. «Зручні» для виконання G, C, D зберігають своє домінування протягом усіх десятиліть. Це підтверджує гіпотезу про те, що фундаментальні принципи композиції та гармонії, орієнтовані на масового слухача, є стійкими до плину часу та технологічних змін у звукозаписі.

ВИСНОВКИ

I. Глобальні тренди та еволюція звучання

Сучасна музика стала менш акустичною, поступаючись місцем високій енергійності, електронному продакшену та підвищеній гучності. Це говорить про занепад акустики та «Війну гучностей».

Акустична гомогенізація поп-музики: різні макро-жанри (наприклад, Rock та Jazz) мають фундаментально різні аудіо-профілі. Проте зі зростанням комерційного успіху треків ця відстань стрімко скорочується. Це свідчить про

існування індустріального «поп-стандарту», під який адаптується масова музика незалежно від жанру.

Хоча треки в мінорі статистично мають нижчий показник валентності (valence), ніж мажорні, розподіли цих величин сильно перекриваються. Це доводить, що музичний лад не є єдиним чинником, що визначає «сумний» чи «веселий» настрій композиції.

II. Механіки популярності та споживання контенту

Розмір фан-бази пов'язаний із популярністю треків нелінійно. На нижчих значеннях кількості підписників популярність зростає особливо швидко, однак із подальшим розширенням аудиторії темп цього приросту поступово слабшає. Отже, найбільший приріст popularity спостерігається саме на малих і середніх масштабах фан-бази, тоді як для дуже великих артистів додаткове збільшення кількості підписників уже не дає такого самого ефекту.

Про специфіку метрики Popularity: наявність треків із нульовою популярністю навіть у мегазірок (понад 100 млн підписників) доводить, що алгоритми Spotify оцінюють поточний хайп (тобто recent streams), а не історичні накопичення прослуховувань.

Аналіз форматів споживання показав, що ринок тяжіє до збалансованих релізів. Альбоми з «синдромом одного хіта» становлять меншість (16%), тоді як успішні артисти здатні конвертувати увагу від головного синглу в прослуховування всього альбому.

Треки з нецензурною лексикою (близько 21% вибірки) демонструють вищу медіанну популярність, ніж чисті (Clean) пісні. Однак це не причинно-наслідковий зв'язок: explicit-маркування є стилістичною нормою для жанрів, що домінують у сучасному стримінгу (зокрема Hip-Hop).

III. Якість даних та обмеження датасету

Аудіо-характеристики не генерують успіх. Кореляційний аналіз спростував гіпотезу про існування ідеального рецепта хіта. Метрика popularity не має сильної прямої кореляції з жодною окремою аудіо-ознакою, а головним драйвером успіху виступає кількість підписників артиста.

Було виявлено аномалії в системі тегування стримінгової платформи. Наявність explicit-мюзиклів (наприклад, «Hamilton») або агресивних піджанрів металу в консервативній категорії Classical свідчить про високу умовність агрегованої жанрової класифікації в масових датасетах. Також понад 30% усього каталогу становить макро-жанр Rock. Це створює статистичне зміщення загальних середніх показників датасету в бік високої енергійності та впливає на репрезентативність глобальних оцінок.

ВИКОРИСТАНІ ДЖЕРЕЛА

1. Тавров Д. Ю. Аналіз даних: Лекція 1. EDA
2. Офіційна документація Spotify API:
<https://developer.spotify.com/documentation/web-api/reference/get-audio-features>
3. Джерело даних: <https://www.kaggle.com/datasets/serkantysz/550k-spotify-songs-audio-lyrics-and-genres?select=songs.csv>
4. Офіційний сайт ggplot2: <https://ggplot2.tidyverse.org/reference/>
5. Ідеї для графіків: <https://r-graph-gallery.com/>