




РОЗВІДКОВИЙ АНАЛІЗ ДАНИХ

Лабораторна робота №1 з дисципліни “Аналіз даних”

Команда №4

Сивоконь Валерія, Сусяк Владислав,
Ткаченко Євгеній.



Зміст презентації

1

Матриця кореляцій
змінних

2

Як розподіляється
популярність треків у різних
жанрах?

3

Чи впливає explicit-контент на
популярність треків?

4

Як розподіляється тривалість
треків у різних жанрах?

5

Які специфічні жанри мають
найбільшу кількість пісень?
Які вони мають середню
танцювальність, енергійність та
популярність?

6

Які жанри мають найбільш
контрастні аудіо-профілі? І чи
справді популярні треки схожі
між собою?

7

Які аудіо-характеристики
найбільше пов'язані з
популярністю у різних жанрах?

8

Зменшення впливу фан-бази
після певного порогу: Чи
однаково зростає популярність
треків у малих і великих
артистів?

9


Як розподіляється
популярність треків усередині
різних видів музичних
альбомів?

10

Еволюція музики: Як
змінювалися ключові аудіо-
характеристики з роками?

11

Висновки



Опис датасету

1

550K Spotify Songs: Audio, Lyrics & Genres - це велика та розширена база даних музичних треків зі Spotify.

2

Він є "реконструйованою" версією старіших наборів даних тут виправлено невідповідності у форматах, оброблено аномальні значення в аудіохарактеристиках та відновлено відсутні дані за допомогою ID Spotify.

3

Особливістю цього датасету є наявність стовпців lyrics, niche_genres, main_genre, які відсутні в інших датасетах.

4

Оригінальний датасет має **550 тисяч рядків** та **24 змінних**.

1

Видалення дублікатів та логічних аномалій

За комбінацією змінних name та artists було знайдено **53 617** потенційних дублікатів. Їх було видалено з датасету

3

Стандартизація пропущених значень:

в усіх текстових змінних було видалено зайві пробіли на початку та в кінці рядків. Усі порожні рядки ("") були програмно замінені на стандартизоване системне значення NA.

5

Перетворення типів даних (Data Typing):

Категорійні змінні (genre, niche_genres, key, mode, explicit) були перетворені на факторний тип.

2

Оптимізація розмірності

Видалено змінні id та artist_ids, оскільки вони є системними ідентифікаторами бази даних Spotify і не несуть цінності для аналізу

4

Конструювання нової ознаки

Створено нову змінну explicit. Тексти пісень були перевірені на наявність нецензурної лексики. **84016 треків** отримали мітку "Explicit" та **393549 треків** отримали мітку "Clean".

6

Приведення до формату "Tidy Data" (Охайні дані):


Змінні artists та niche_genres початково містили дані у форматі масивів, що порушує правило "одне значення — одна комірка". Було витягнуто лише перше (головне) значення для кожного спостереження.

Змінна	Мінімум	Медіана	Середнє	Максимум	Ст. відхилення
acousticness	0.000	0.068	0.238	0.996	0.307
avg_artist_popularity	0.000	47.000	46.628	100.000	19.111
danceability	0.046	0.526	0.523	0.988	0.173
duration_ms	15027.000	223359.000	238259.669	4995315.000	97845.367
energy	0.000	0.724	0.677	1.000	0.246
instrumentalness	0.000	0.000	0.113	0.998	0.245
liveness	0.007	0.142	0.226	1.000	0.199
loudness	-44.868	-6.947	-7.803	0.000	3.856
popularity	0.000	14.000	17.371	98.000	16.845
speechiness	0.022	0.050	0.087	0.966	0.095
tempo	30.946	121.982	123.013	245.941	29.460
total_artist_followers	0.000	225797.000	2207518.338	295181900.000	8346439.186
valence	0.000	0.437	0.457	0.996	0.248
year	1900.000	2010.000	2007.463	2025.000	13.203


Дескриптивні статистики очищеного набору даних

- Медіана popularity становить лише 14 зі 100. Більшість треків у датасеті - це маловідомі або нішеві композиції.
- Сильний перекис у бік музики XXI століття та епохи стримінгів: медіана year - 2010.
- Середньостатистична пісня ідеально підігнана під радіо-формат, бо її медіанна тривалість складає ~3 хвилини 43 секунди (223 тис. мс), а темп чітко потрапляє в танцювальний поп-стандарт у 122 BPM.

Матриця кореляцій змінних




- Для обчислення матриці кореляцій було обрано ранговий коефіцієнт кореляції Спірмена.
- **Найсильніша позитивна** кореляція спостерігається між **avg_artist_popularity** та **total_artist_followers** (0.92).
- Серед аудіо характеристик найбільша **позитивна кореляція**, між **energy** та **loudness** (0.76).
- **Найсильніша негативна** кореляція спостерігається між **acousticness** та **energy** (−0.74).



Дослідницьке питання 1

Як розподіляється популярність треків у різних жанрах?




Розподіл змінної genre

- **Значна частина** пісень належить до жанру **Rock**.
- **Середніми** за кількістю є пісні з жанрами **Electronic, Pop, Folk, Country, Hip-Hop**.
- **Найрідкішими** є пісні з жанрами **R&B, Jazz, Blues, Classical**.

Розподіл популярності треків

Важливо: 25.8% усіх треків у датасеті мають популярність 0 і виключені з графіка.




Розподіл змінної popularity

- Пісні з нульовою популярністю, складають **25.8%** від усього набору даних.
- Серед решти треків розподіл має чітку **правобічну асиметрію**: більшість пісень мають низьку популярність (від 1 до 30).
- Справжні **хіти** (популярність > 75) є **рідкісними**.

Розподіл темпу музики (BPM)

Розподіл темпу музики (BPM)

Мультимодальний розподіл: піки відповідають стандартам популярних жанрів




Спостерігаємо одразу кілька виражених локальних максимумів.

Глобальний максимум (120-130 BPM): це індустріальний золотий стандарт для поп-музики, хаусу, диско та радіо-хітів (темп, що найкраще синхронізується з активним кроком та базовою танцювальною ритмікою).

Лівий локальний пік (90-100 BPM): Відповідає класичним стандартам хіп-хопу, R&B та реггетону — жанрам, які орієнтовані на більш повільний ритм.

Правий локальний пік (140-150 BPM): Відображає кластер високоінтенсивної музики, що включає як гітарні жанри (швидкий рок, панк), так і агресивні напрямки електронної музики (як дабстеп, треп).


Розподіл популярності за жанрами




- Найпопулярнішими жанрами є **Hip-Hop** та **R&B**.
- Найнепопулярнішим є жанр **Blues**
- Всі інші жанри загалом знаходяться на **одному рівні** популярності.

Розподіл популярності за жанрами



Чорною лінією позначено медіану



- Всі жанри мають **високу кількість пісень з низькою популярністю**, а зі збільшенням популярності кількість пісень зменшується.




- Жанри можна поділити на **3 групи** за кількістю пісень.
- **Найбільше** пісень є у жанрах Rock, Hip-Hop, Pop.
- **Середня** кількість пісень для жанрів Electronic, Country, R&B, Folk.
- **Найменше** пісень є у жанрах Jazz, Classical, Blues.
- Жанр Rock представлений у датасеті найбільшою вибіркою. Гігантська кількість маловідомих рок-треків зміщує загальну медіану жанру вниз. Проте завдяки масштабам виробництва, навіть невелика частка успішних рок-композицій в абсолютних значеннях перевищує кількість хітів у жанрі Hip-Hop, чий каталог уп'ятеро менший.



- Популярні пісні мають такі ж тенденції як і всі пісні.
- Порядок популярності пісень є майже ідентичним. Єдина відмінність в тому, що на графіку для всіх пісень **Rock** займав **8-9 місце**, а на цьому графіку він займає **3-5 місце**.
- Це ілюструє жорстку конкуренцію в індустрії: навіть серед об'єктивно популярної музики абсолютна більшість композицій має помірний успіх, тоді як світові мега-хіти (80-100 балів) залишаються рідкісними статистичними викидами незалежно від жанру.

Історичний розподіл музики на Spotify

Логарифмічна шкала (Y) демонструє експоненційне зростання каталогу




Розподіл змінної year


- На графіку використовуюється **логарифмічна шкала**.
- В датасеті є **невелика** кількість пісень **до 1950 року**.
- В **1950-х роках** можна побачити **стрибок** у кількості пісень, **з сотні** пісень **до тисячі**.
- Наступний стрибок відбувається у **2000-х роках**, стрибок з приблизно **3 тисяч** пісень до **10 тисяч**.

Еволюція медіанної популярності за жанрами(з 1955 року)

Чорна лінія відображає загальний тренд (LOESS)




- На графіках можна побачити неочікувану тенденцію. Жанри збільшують свою **популярність** і досягають піку **між 1970 і 1990 роками**.
- Популярність почала **спадати у 2000-х роках** і знову **зростати у 2010-х**.
- **Поясненням** цього може бути те, що до Spotify-ю додавались старі пісні, які є відомими, а не **невідомі** старі пісні просто **загубились і забулись**.



Дослідницьке питання 2


Чи впливає explicit- контент на популярність треків?



Розподіл змінної explicit


- Частка explicit пісень становить **17.6% від всього датасету.**
- Припускається, що explicit пісні **концентруються** в певних жанрах, таких як **Hip-Hop**.

Розподіл популярності за explicit content



- $\frac{1}{6}$ датасету це **explicit** пісні.
- Загалом **explicit** пісні є популярнішими на **5** значень.

Розподіл популярності за жанрами та наявністю матів




- У **всіх жанрах** пісні з explicit-content-ом є **більш популярними**. Найбільша різниця є в жанрах R&B, Hip-Hop, Country, Classical та Pop.
- Під час більш детального аналізу **explicit пісень** в жанрі **Classical**, було виявлено, що найпопулярніший альбом належить до **Hip-Hop**, проте альбом є мюзиклом і є записаним в театрі. Це наводить на думку, що **загальна популярність explicit пісень** може бути продиктована, тим, що вони перебувають на межі кількох більш популярних жанрів.

Діаграма розмаху демонструє глибоку поляризацію всередині категорії:


Розподіл популярності нішевих жанрів (Classical)

Відсортовано за медіаною. Справа вказано розмір вибірки (n) для кожної ніші



- **Традиційна класика vs. Комерційний контент:**
традиційний академічний репертуар (ніші classical, chamber music, baroque, contemporary classical) формує низ рейтингу з медіанною популярністю, що наближається до нуля. Натомість успіх макро-жанру майже повністю тримається на кінематографічному та театральному контенті.
- **Алгоритмічна міскласифікація:**
найціннішим інсайтом цієї візуалізації є емпіричне доведення недосконалості системи тегування Spotify. Графік фіксує наявність усередині класичної музики абсолютно нерелевантних ніш.

Частка Explicit-треків у наймасовіших нішевих жанрах




Частка explicit-контенту значно відрізняється між нішевими жанрами. Найвищу частку explicit-треків мають піджанри року, зокрема alternative metal, death metal, emo та black metal, що відповідає очікуванням, оскільки ці жанри часто містять більш агресивну або емоційно насичену тематику.

Водночас жанри, пов'язані з Jazz, Blue та близькими до них напрямками (наприклад, ccm, classic soul, classical country), майже не містять explicit-контенту. Хоча musicals формально належить до класичного напрямку, у ньому уже спостерігається помітна частка explicit-треків.

Топ-15 нішевих жанрів за найвищою часткою Explicit-треків

Враховано лише репрезентативні жанри (мінімум 50 треків у каталозі)




Контент

Clean

Explicit

Проте картина кардинально змінюється, якщо змінити фокус дослідження, а саме відкинути прив'язку до масовості та знайти жанри з найвищою абсолютною концентрацією.

Для кращої репрезентації були обрані ті нішеві жанри, які мають принаймні 50 треків у каталозі. Хіп-хоп (який в цьому наборі даних також включає в себе Rap) є монополістом на нецензурну лексику в музичній індустрії. Тільки в цьому жанрі відсоток пісень з наявністю explicit-контенту перевищує 76% (8 584 проти 27 838).




Дослідницьке питання 3

**Як розподіляється
тривалість треків у
різних жанрах?**

Розподіл тривалості пісень

Графік наближено до 10 хвилин (відкинуто екстремальні викиди)




Розподіл змінної duration_ms


- Всього в датасеті є **3804** пісні (0.8% від всього датасету) які є **довші за 10 хвилин**.
- Розподіл має **виражену нижню межу**, тобто пісні **рідко** бувають **менші за 2 хвилини**.
- В той же час **верхня межа** є **набагато гнучкішою**.
- Більшість** пісень сконцентровані між **3 і 4 хвилинами**.

Розподіл тривалості пісень за жанрами

Чорною лінією позначено медіану




- Пісні у жанрах **Rock, Folk, Jazz, Classical** мають **великий діапазон тривалості пісень**.
- Пісні у жанрах **Hip-Hop, Pop, Country** загалом приймають **значення від 2.5 хв до 5 хв**.
- Жанри **R&B, Blues, Electronic** мають тенденцію приймати **довші значення тривалості** в порівнянні з іншими жанрами.



Дослідницьке питання 4

**Які специфічні жанри мають
найбільшу кількість пісень?**

**Які вони мають середню
танцювальність, енергійність та
популярність?**




Розподіл змінної `total_artist_followers`

- Графік має **форму дзвона** на **логарифмічній шкалі**, це означає що на **лінійних** даних, розподіл є **скошеним вправо**.
- Медіана** приймає значення у **30 тисяч**, в той час як середнє приймає значення у **1 мільйон**.

Розподіл танцювальності пісень (Danceability)

Нормальний розподіл. Червоний пунктир вказує на медіану, зелений - на середнє




Розподіл змінної danceability

- Цей графік ілюструє **нормальний розподіл**.
- Тут ми бачимо класичну симетричну «**дзвоноподібну криву**».
- Варто зазначити, як **медіана** так і **середнє** практично **однакові**.

Це окей що на графіку щільність замість кількості пісень?

Розподіл енергійності пісень (Energy)

Лівостороння асиметрія. Позначено медіану сірим та середнє зеленим.



Розподіл змінної energy

- **Основна маса** пісень у датасеті має **високі показники** енергійності.
- Натомість треки з **низькою енергією** (0.0 - 0.3), складають абсолютну **меншість** у загальному каталозі.
- **Медіана** та **середнє** знаходяться біля позначки **0,7**.

Це окей що на графіку щільність замість кількості пісень?


Танцювальність та Енергійність: Топ-15 нішевих жанрів

У дужках вказано загальний макро-жанр




Більшість наймасовіших ніш є піджанрами макро-категорії Rock.

- Верхній лівий кут: Тут згруповані найменш популярні ніші, які характеризуються високою енергійністю, але вкрай низькою танцювальністю.
- Права частина графіка: Абсолютна більшість наймасовіших ніш концентрується в зоні з помірною або вищою за середню танцювальністю. Загалом вони демонструють рівень популярності середнього сегмента.
- Лідери популярності: Три найуспішніші ніші серед масових (alternative metal, classic rock та country) виділяються з-поміж інших: окрім помірної танцювальності, вони мають стабільно високу енергійність.



Дослідницьке питання 5


**Які жанри мають найбільш
контрастні аудіо-профілі? І чи
справді популярні треки схожі між
собою?**



Розподіл змінної speechiness

- Spotify має офіційну документацію для **speechiness**, і там є чіткі пороги.
- Менше 0.33: **Звичайна** музика.
- 0.33 - 0.66: Музика з **великою кількістю тексту** (переважно реп).
- Більше 0.66: Виключно **розмовний контент** (подкасти, вірші).
- На графіку можна побачити, що домінує музика, яка має **speechiness** менше ніж 0.33.

Розподіл емоційної окраси пісень (Valence)




Розподіл змінної Valence

- Графік має **правосторонню асиметрію**.
- Можна побачити, що у датасеті, **домінують** пісні з **низьким значення valence**, тобто більш сумніші.
- **Найпоширеніший** настрій знаходиться в районі **від 0.3 до 0.45**.

Розподіл специфічних акустичних характеристик

Вісь Y логарифмована




Розподіл змінних Acousticness, Instrumentalness, Liveness

- На графіках використано логарифмічну шкалу.
- Майже для всіх треків значення змінних **acousticness**, **instrumentalness** близьке до нуля.
- Змінна **Liveness** має найбільше треків зі значеннями **від 0 до 0.4**.

Розподіл змінної loudness

Розподіл гучності треків (Loudness)

Графік наближено до діапазону [-25, 0] dB. Червоний пунктир — медіана; зелений — середнє



- Значення **менші за -25 dB** **відкинуто**, задля читабельності графіку.
- На графіку розподілу гучності ми спостерігаємо сильну **лівосторонню асиметрію** з яскраво вираженим піком у зоні від -7 до -4 dB. Це є прямим наслідком так званої «Війни гучностей» (**Loudness War**) у музичній індустрії: тенденції мастеринг-інженерів максимізувати гучність треків майже до межі спотворення (0 dB), щоб пісня звучала агресивніше та виділялася на фоні інших під час ротації на радіо чи у плейлистах.

Жанрові аудіо-профілі за ключовими характеристиками


Використанні медіани аудіо-характеристик

Жанр	Rock	0	0.43	0.88	0	0.17	-5.92	0.06	124.81	0.36
	R&B	0.23	0.64	0.59	0	0.13	-7.67	0.06	111.4	0.56
	Pop	0.16	0.55	0.65	0	0.13	-7.42	0.04	120.9	0.5
	Jazz	0.81	0.54	0.3	0	0.12	-12.59	0.04	110.52	0.45
	Hip-Hop	0.09	0.71	0.69	0	0.14	-6.54	0.22	109.86	0.53
	Folk	0.34	0.58	0.54	0	0.12	-8.55	0.04	117.01	0.54
	Electronic	0.03	0.62	0.79	0.01	0.13	-6.38	0.05	126.99	0.39
	Country	0.37	0.56	0.54	0	0.13	-8.3	0.03	119.76	0.52
	Classical	0.73	0.46	0.38	0	0.13	-10.72	0.04	113.42	0.34
	Blues	0.38	0.55	0.56	0	0.14	-8.84	0.04	115.79	0.59
		acousticness	danceability	energy	instrumentalness	liveness	loudness	speechiness	tempo	valence
Аудіо-характеристика										


- **Hip-Hop** та **Electronic** характеризуються високою енергійністю та танцювальністю, що робить їх більш придатними для масового прослуховування. **Jazz** і **Classical** мають вищу акустичність і нижчу енергію, що відображає їхню більш інструментальну та “живу” природу.
- Важливо, що **instrumentalness** залишається низьким для всіх жанрів, що підтверджує домінування вокалу в датасеті.
- Варто відзначити показник **speechiness** (мовленнєвість): він майже повністю сконцентрований у жанрі **Hip-Hop**, що є очікуваним, оскільки цей жанр базується на реп і ритмічному мовленні. В інших жанрах цей показник залишається на дуже низькому рівні.

Відстані між жанрами за аудіо-профілями

Жанр




Відстань




Жанри справді мають помітно різні аудіо-профілі. Найменші відстані спостерігаються між жанрами, які мають схожі характеристики звучання, тоді як найбільші - між жанрами з найбільш контрастними профілями. За графіком видно, що **Rock** є одним із найбільш відмінних жанрів: його відстані до більшості інших жанрів вищі, ніж у багатьох інших пар. Особливо сильна відмінність спостерігається між **Rock** і **Jazz**, а також між **Rock** і **Hip-Hop / R&B**.

Тепер подивимося чи буде зменшуватися відстань між треками зі збільшенням популярності, чи насправді популярні треки схожі.


Jazz vs Electronic



Rock vs Jazz




Hip-Hop vs Classical



Бачимо тут явище **«акустичної гомогенізації»** (homogenization of popular music) масової музики. Щоб стати глобальним хітом, трек повинен оптимізуватися під масового слухача.


У децилях 1–4 популярності жанри зберігають свою унікальну ідентичність, а математична дистанція між ними навіть зростає. Проте, при переході до децилів 7–10, відстань стрімко скорочується.




Дослідницьке питання 6

**Які аудіо-характеристики
найбільше пов'язані з
популярністю у різних жанрах?**

Зв'язок аудіо-характеристик з popularity у різних жанрах




- Значення кореляцій малі, тому можна прийти до висновку, що немає зв'язку між аудіо-характеристиками і популярністю.



Дослідницьке питання 7


Зменшення впливу фан-бази після певного порогу: Чи однаково зростає популярність треків у малих і великих артистів?




- Бачимо очікуване **збільшення популярності** треків зі **збільшенням фан-бази**.
- У артистів, у яких **більше 100 млн підписників**, є частка треків з **популярністю 0**.
- Значення популярності визначається складніше, ніж просто за кількістю прослуховувань. Справа в тому, що метрика popularity у Spotify - це не кількість прослуховувань за весь час. Це динамічна метрика, яка має вбудоване знецінення часом.

Чи зменшується вплив фан-бази після певного порогу?

Показано лише артистів із кількістю підписників до 100 млн




- Популярність треків зростає разом із кількістю підписників артиста, однак ця залежність є **нелінійною**.
- На малих значеннях фан-бази популярність зростає особливо різко, однак у міру подальшого збільшення аудиторії темп цього зростання поступово сповільнюється. Отже, найбільший приріст популярності спостерігається саме на нижчих і середніх рівнях фан-бази, тоді як для дуже великих артистів додаткове збільшення кількості підписників дає вже менший приріст popularity.



Дослідницьке питання 8

**Як розподіляється популярність треків
усередині різних видів музичних
альбомів?**


Розподіл популярності окремих пісень усередині Топ-10 альбомів



- У більшості випадків **присутній** значний **розкид значень**.
- Альбоми **AM** та **ASTROWORLD** мають **високий загальний рівень популярності**, але все одно містять треки, які помітно відстають від лідерів.
- Альбоми **TakeCare** та **Positions** демонструють ще більшу варіативність, із **наявністю окремих “просідаючих” треків**.
- Водночас є альбоми з більш **рівномірним розподілом** (наприклад, Hamilton), де різниця між треками менша.

Синдром «Одного Хіта»

Альбоми з найбільшим розривом між супер-хітом та рештою треків




А як виглядають альбоми-представники синдрому «Одного хіта»?

Для дослідження феномену одного хіта було застосовано евристичний фільтр: відібрано альбоми, де присутній глобальний хіт (popularity > 75), але медіана решти композицій наближається до нуля. Діаграма розмаху яскраво візуалізує цю аномалію: на графіку (наприклад, альбом «Gangsta's Paradise») ми бачимо єдиний викид-хіт на позначці 80+, тоді як весь інший матеріал біля нульової відмітки. Це свідчить про те, що в цих випадках альбом як формат не спрацював.

Альбоми-бестселери VS. Один хіт


Аналіз альбомів, які мають хоча б одну пісню з популярністю > 75



Найтиповіший сценарій це альбом із **одним великим хітом і кількома помірно популярними треками**. Повністю «провальні» альбоми з одним хітом зустрічаються значно рідше. Це вказує на те, що **аудиторія зазвичай не обмежується одним треком і готова споживати більше контенту від популярного артиста**.

Висновки: *Що таке успішний альбом з точки зору даних?*


Успішний альбом - це продукт, здатний трансформувати випадкового слухача одного супер-хіта в лояльного споживача всього каталогу (що математично виражається у високій медіані та низькій дисперсії). Якщо ж хіт існує в ізоляції від решти треків, це успіх конкретної пісні, але маркетинговий провал альбому як формату.



Дослідницьке питання 9

**Еволюція музики: Як змінювалися
ключові аудіо-характеристики з
роками?**


Зміна аудіо-характеристик з роками



- Значення медіани коливаються до 1950. Це може бути пов'язано з тим що до у датасеті мала вибірка треків до 1950 року.
- В датасеті **speechiness** та **instrumentalness** зазвичай **близькі до нуля**, тому на графіку вони мають білий колір.
- **Danceability** залишалась сталою з плином часу.
- Можна побачити цікаву ситуацію з **acousticness** і **energy**: вони мають майже протилежні розподіли.

Еволюція музики: 1960 - 2023


Занепад живої акустики та зростання загальної гучності



Побудуємо графік зміни гучності, акустичності та розподілу energy з роками:


- По-перше, спостерігається стрімкий **занепад чистої акустики**, яка витісняється електронними інструментами, синтезаторами та комп'ютерним продакшеном (падіння середнього показника з 0.7 до 0.2).
- По-друге, паралельне **зростання графіка гучності є відбитком «Війни гучностей»** (або ж Loudness War) - індустріальної гонки за максимальним рівнем звукового тиску в комерційній музиці.

Як змінювався розподіл energy з роками



- У першій половині ХХ століття (це епоха джазу, блюзу та раннього свінгу) **медіана розподілу знаходилася в зоні низької енергії (0.2 - 0.4).**
- Однак, починаючи з 1960-х років (це є розквітом рок-музики) і до сьогодні, «центр мас» невпинно зміщується вправо. Це доводить, що **високоінтенсивне, агресивне звучання стало абсолютним стандартом для сучасного масового слухача.**


Розподіл змінної mode



- Музичний лад демонструє стабільну **перевагу мажорних композицій над мінорними**. Це відображає загальну орієнтацію масової музичної індустрії на створення позитивного, легкого для сприйняття контенту.
- Незважаючи на те, що мінорні тональності активно використовуються в специфічних жанрах та ліричних композиціях, **мажор залишається індустріальним стандартом для радіо-хітів та танцювальної музики**.

Міnor сумніший за Мажор


Розподіл показника Valence (позитивності) за музичним ладом



- Розподіли показника **valence** для міnorного та мажорного ладів значною мірою перекриваються.
- Треки у мінорі частіше зосереджені ближче до «сумних» емоцій, тоді як мажорні композиції мають більшу частку значень у більш «позитивному» та «світлому» настрої.
- Водночас різниця не є радикальною: значне перекриття розподілів показує, що **емоційне забарвлення треків не визначається лише музичним ладом.**

Еволюція музичного ладу: Мажор проти Мінору (1950 - 2023)

Спостерігається поступовий тренд до збільшення частки мінорних композицій



Тепер розглянемо чи є якісь цікаві тенденції в зміні ладів і тональностей з роками. Для аналізу з датасету було виключено композиції, випущені до 1950 року (через недостатність обсягу вибірки).

Історично мажор домінував (приблизно 70–80% треків), однак **з часом частка мінору поступово зростає**. Особливо після 2000-х видно стабільний тренд: **музика стає більш «мінорною», тобто емоційно темнішою або меланхолійнішою**.

Висновки

I. Глобальні тренди та еволюція звучання

- Сучасна музика стала менш акустичною, поступаючи місцем високій енергійності, електронному продакшену та підвищеній гучності. Це говорить про занепад акустики та «Війну гучностей».
- Акустична гомогенізація поп-музики: різні макро-жанри (наприклад, Rock та Jazz) мають фундаментально різні аудіо-профілі. Проте зі зростанням комерційного успіху треків ця відстань стрімко скорочується. Це свідчить про існування індустріального «поп-стандарту», під який адаптується масова музика незалежно від жанру.
- Хоча треки в мінорі статистично мають нижчий показник валентності (valence), ніж мажорні, розподіли цих величин сильно перекриваються. Це доводить, що музичний лад не є єдиним чинником, що визначає «сумний» чи «веселий» настрій композиції.

Висновки

II. Механіки популярності та споживання контенту.

- Розмір фан-бази пов'язаний із популярністю треків нелінійно. На нижчих значеннях кількості підписників популярність зростає особливо швидко, однак із подальшим розширенням аудиторії темп цього приросту поступово слабшає. Отже, найбільший приріст popularity спостерігається саме на малих і середніх масштабах фан-бази, тоді як для дуже великих артистів додаткове збільшення кількості підписників уже не дає такого самого ефекту.
- Про специфіку метрики Popularity: наявність треків із нульовою популярністю навіть у мегазірок (понад 100 млн підписників) доводить, що алгоритми Spotify оцінюють поточний хайп (тобто recent streams), а не історичні накопичення прослуховувань.
- Аналіз форматів споживання показав, що ринок тяжіє до збалансованих релізів. Альбоми з «синдромом одного хіта» становлять меншість (16%), тоді як успішні артисти здатні конвертувати увагу від головного синглу в прослуховування всього альбому.
- Треки з нецензурною лексикою (близько 21% вибірки) демонструють вищу медіанну популярність, ніж чисті (Clean) пісні. Однак це не причинно-наслідковий зв'язок: explicit-маркування є стилістичною нормою для жанрів, що домінують у сучасному стримінгу (зокрема Hip-Hop).

Висновки

III. Якість даних та обмеження датасету.

- Аудіо-характеристики не генерують успіх. Кореляційний аналіз спростував гіпотезу про існування ідеального рецепта хіта. Метрика popularity не має сильної прямої кореляції з жодною окремою аудіо-ознакою, а головним драйвером успіху виступає кількість підписників артиста.
- Було виявлено аномалії в системі тегування стримінгової платформи. Наявність explicit-мюзиклів (наприклад, «Hamilton») або агресивних піджанрів металу в консервативній категорії Classical свідчить про високу умовність агрегованої жанрової класифікації в масових датасетах. Також понад 30% усього каталогу становить макро-жанр Rock. Це створює статистичне зміщення загальних середніх показників датасету в бік високої енергійності та впливає на репрезентативність глобальних оцінок.

**ДЯКУЄМО
ЗА УВАГУ**