




СТАТИСТИЧНЕ ВИВЕДЕННЯ

Лабораторна робота №2 з дисципліни “Аналіз даних”

Команда №4

Сивоконь Валерія, Сусяк Владислав,
Ткаченко Євгеній.



Зміст презентації

1 Зміни в датасеті

2 Довірчі інтервали

3 Гіпотези щодо explicit пісень

4 Гіпотези пов'язані з аудіо-профілями

5 Гіпотези щодо кореляцій аудіо-характеристик

6 Гіпотези, щодо популярності та фан-бази

7 Еволюція змінних acoustiness та energy

8 Висновки

Зміни в датасеті

1

Видалення за комбінаціями змін `artists, name, year, genre`

Так як в минулій лабораторній було зауваження, що видалення пісень за комбінацією `artists name` може видалити зайві унікальні пісні, тому тепер ми використали комбінацію `artists, name, year, genre`.

2

Новий датасет

В датасеті, який використовувався для першої лабораторної роботи було 477 565 пісень, тепер в оновленому датасеті є 516 129 пісень. Всього було відновлено 38 564 пісні.

Метрика	Середнє значення	CI
acousticness	0.244	(0.243 ; 0.245)
danceability	0.525	(0.525 ; 0.526)
energy	0.672	(0.671 ; 0.672)
instrumentalness	0.109	(0.108 ; 0.110)
liveness	0.226	(0.225 ; 0.226)
loudness	-7.9	(-7.914 ; -7.893)
speechiness	0.0854	(0.085 ; 0.086)
tempo	123	(122.782 ; 122.943)
valence	0.464	(0.463 ; 0.464)


Нагадування про дані датасету

- В таблиці надано статистики для першої групи, тобто вони мають асимптотично нормальний розподіл


Метрика	Медіана	95% bootstrap CI
tempo	122	[121; 122]
duration_ms	223187	[222960.000; 223413.000]
total_artist_followers	247731	[245577.000; 249778.000]
avg_artist_popularity	48	[48.000; 48.000]
danceability	0.528	[0.527; 0.528]
energy	0.717	[0.716; 0.718]
loudness	-7.06	[-7.069; -7.046]

Нагадування про дані датасету


- В таблиці надано статистики для другої групи, щоб порахувати інтревали для них потрібно використати бустреп.
- Використовувався Percentile метод
- Кількість бутстреп вибірок 2000



Довірчі інтервали




Загальна медіанна популярність за жанрами



- Незважаючи на те, що Classical Pop мають однакову медіану, інтервали для Classical є довшими через меншу вибірку
- Інтервали, для жанрів Folk та Rock звузились в 1 точку.
- Загалом, розраховані довірчі інтервали є досить вузькими для всіх жанрів.


Довірчі інтервали медіанної тривалості пісень

Лише пісні коротші за 10 хв



- Найдовші композиції характерні для R&B, Electronic та Rock, а найкоротші для Country, Jazz і Classical.
- Завдяки масивним вибіркам довірчі інтервали для деяких жанрів практично виродилися в точку
- Помітно ширші «вуса» інтервалів спостерігаються лише у Blues, Classical та Jazz. Це відбулося через меншу кількість пісень у цих жанрах.


Довірчі інтервали медіанної популярності




- Знову ж таки **Explicit інтервали** мають **вищу медіанну** популярність.
- Загалом усі чотири алгоритми бутстрепа показують **схожий результат**.
- Жанри **Classical, Jazz, Blues** в категорії **Explicit** мають **дуже довгі довірчі інтервали** через малу вибірку.

Niche genre	Count	Mean Dance	CI Dance	Mean Energy	CI Energy	Mean Pop	CI Pop
classic country	13149	0.581	[0.579; 0.583]	0.468	[0.465; 0.472]	20.8	[20.54; 21.09]
death metal	12877	0.327	[0.325; 0.329]	0.934	[0.932; 0.935]	14.1	[13.85; 14.27]
blues	11576	0.553	[0.550; 0.556]	0.519	[0.514; 0.523]	13.5	[13.27; 13.79]
alt country	11549	0.521	[0.518; 0.523]	0.504	[0.500; 0.508]	11.7	[11.44; 11.94]
emo	9566	0.425	[0.422; 0.427]	0.82	[0.817; 0.824]	21.2	[20.82; 21.55]
black metal	8612	0.274	[0.271; 0.277]	0.886	[0.883; 0.889]	10.5	[10.27; 10.72]
classic rock	8295	0.501	[0.498; 0.505]	0.689	[0.685; 0.694]	24.6	[24.24; 25.04]
ccm	7591	0.479	[0.476; 0.482]	0.636	[0.632; 0.641]	19	[18.59; 19.37]
classic soul	7530	0.575	[0.572; 0.578]	0.53	[0.526; 0.534]	18.3	[17.89; 18.62]
country	7392	0.564	[0.562; 0.567]	0.668	[0.664; 0.673]	26.9	[26.48; 27.35]
alternative metal	6681	0.453	[0.450; 0.456]	0.863	[0.860; 0.867]	26.7	[26.19; 27.13]
darkwave	6057	0.538	[0.535; 0.541]	0.806	[0.802; 0.811]	11.3	[10.95; 11.58]
aor	5932	0.476	[0.473; 0.480]	0.728	[0.722; 0.733]	15.2	[14.86; 15.63]
doom metal	5928	0.34	[0.337; 0.344]	0.747	[0.742; 0.752]	12.4	[12.06; 12.71]
musicals	5208	0.482	[0.478; 0.486]	0.386	[0.380; 0.392]	20.2	[19.70; 20.64]

- Зеленим кольром виділені піджанри з найбільшим середнім значенням danceability
- Жовтим виділені піджанри з найбільшим середнім
- Фіолетовим виділено піджанри з найбільшою популярністю



Гіпотези щодо explicit пісень



Чи популярніші Explicit пісні за Clean пісні за жанрами?

H_0

$$M_{Explicit} - M_{Clean} \leq 0$$

H_1


$$M_{Explicit} - M_{Clean} > 0$$

Genre	Diff_median	W_stat	p_value	p_adj_BH	reject_H0
Rock	1	44.7	0.00e+00	0.00e+00	TRUE
R&B	9	15.8	1.58e-56	7.89e-56	TRUE
Hip-Hop	6	10.7	5.38e-27	1.79e-26	TRUE
Pop	5	6.83	4.26e-12	1.06e-11	TRUE
Country	5	6.21	2.64e-10	5.28e-10	TRUE
Classical	5	5.05	2.18e-07	3.63e-07	TRUE
Folk	3	4.6	2.11e-06	3.02e-06	TRUE
Electronic	2	3.95	3.87e-05	4.84e-05	TRUE
Jazz	3	2.05	2.00e-02	2.22e-02	TRUE
Blues	1	0.845	1.99e-01	1.99e-01	FALSE


- Нульова гіпотеза **відкидається** для всіх жанрів, **окрім Blues**.
- Хоч ми і відкидаємо нульову гіпотезу для жанру **Jazz**, значення **p** не таке **вже і мале**.
- Для жанрів **Rock, Folk, Electronic**, нульова гіпотеза виконується, проте **різниця медіан не є такою суттєвою і великі різниці** є лише для жанрів **R&B, Hip-Hop, Pop, Country, Classical**.
- **Значення p** для жанру **Rock** дорівнює **0**, це пов'язано з тим, що під час розрахунків бутстреп-симуляцій медіана не змінювалась.
- Тому доцільно також провести аналіз для **середніх значень популярності**.


Genre	Diff_mean	W_stat	p_value	p_adj_BH	reject_H0
Hip-Hop	4.82	20.5	8.01e-94	8.01e-93	TRUE
R&B	6.36	18.2	5.58e-74	2.79e-73	TRUE
Country	2.56	8.26	7.32e-17	2.44e-16	TRUE
Pop	1.62	6.37	9.41e-11	2.35e-10	TRUE
Classical	3.83	6.18	3.21e-10	6.41e-10	TRUE
Electronic	1.05	4.98	3.13e-07	5.21e-07	TRUE
Rock	0.342	3.41	3.28e-04	4.69e-04	TRUE
Folk	0.47	2.17	1.49e-02	1.86e-02	TRUE
Jazz	0.789	0.864	1.94e-01	2.15e-01	FALSE
Blues	-0.0969	-0.166	5.66e-01	5.66e-01	FALSE

- Тепер **статистика Волда** для жанру **Rock** має **адекватне значення** і можна побачити, що для цього жанру ми також **відкидаємо нульову гіпотезу**.
- Нульова гіпотеза **відкидається** для всіх жанрів, **окрім Blues та Jazz**.
- Хоча для **Folk** ми все ж відкидаємо нульову гіпотезу, отримане **p-value знаходиться досить близько до критичної межі**.
- Виконуються **схожі тенденції**, щодо **різниць середніх**, як і для **різниць медіан**.



Гіпотези пов'язані з аудіо-профілями





Пара Rock/Jazz контрастніша за Jazz/Electronic

$$H_0$$

$$d(\text{Rock}, \text{Jazz}) - d(\text{Jazz}, \text{Electronic}) \leq 0$$

$$H_1$$

$$d(\text{Rock}, \text{Jazz}) - d(\text{Jazz}, \text{Electronic}) > 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.427	0.025	[0.378; 0.475]	[0.381; 0.473]	[0.352; 0.485]	[0.381; 0.474]	17.202	< 1e-15	Н0 відхилено

Значення p дуже мале, тому ми відхиляємо нульову гіпотезу.

Це означає, що пара Rock/Jazz має більшу відстань за аудіо-профілями, ніж Jazz/Electronic.

Усі розраховані довірчі інтервали лежать у додатній зоні, тому цей результат є статистично стійким.

Для жанрів Rock та Jazz топ-треки жанрово ближчі, ніж нижні децилі

H_0

$$distance_{top} - distance_{bottom} \geq 0$$

H_1

$$distance_{top} - distance_{bottom} < 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
-0.866	0.124	[-0.987; -0.499]	[-0.981; -0.487]	[-0.953; -0.542]	[-1.246; -0.751]	-6.962	2.10e-12	Н0 відхилено

Нульову гіпотезу відхилено, адже р значення $\epsilon > 0.05$.

Всі розраховані довірчі інтервали лежать виключно в мінусовій зоні, що повністю підтверджує альтернативну гіпотезу.

Це означає, що популярні треки в жанрах Rock та Jazz дійсно стають жанрово ближчими один до одного порівняно з піснями з нижніх децилів.

Для жанрів Jazz та Electronic топ-треки жанрово ближчі, ніж нижні децилі

H_0

$$distance_{top} - distance_{bottom} \geq 0$$

H_1

$$distance_{top} - distance_{bottom} < 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.328	0.193	[0.007; 0.762]	[0.025; 0.737]	[0.142; 0.543]	[-0.081; 0.631]	1.704	0.9558	H0 не відхилено

Скориговане р-значення (0.9558) перевищує рівень значущості, тому H0 не відхиляється.

У цьому тесті дані не дають підстав стверджувати, що Jazz та Electronic зближуються серед найпопулярніших треків.

Додатна точкова оцінка (0.328) радше вказує, що очікуваний напрямок не спостерігається, але робити сильний висновок про віддалення за цією перевіркою не потрібно.

Середня міжжанрова відстань у нижніх децилях додатна

H_0

$D_{low} \leq 0$

H_1

$D_{low} > 0$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
4.046	0.03	[3.998; 4.116]	[3.992; 4.111]	[3.996; 4.118]	[3.981; 4.100]	134.506	< 1e-15	Н0 відхилено

Нульова гіпотеза відхиляється. Середня міжжанрова відстань у нижніх децилях є додатною

Bootstrap-інтервали вузькі, тому оцінка D_low є стабільною. Це свідчить про помітні акустичні відмінності між жанрами серед менш популярних треків.

Середня міжжанрова відстань у топ-децилі додатна

H_0

$D_{low} \leq 0$

H_1

$D_{low} > 0$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
3.239	0.035	[3.169; 3.306]	[3.169; 3.324]	[3.173; 3.298]	[3.153; 3.308]	92.597	< 1e-15	Н0 відхилено

Нульова гіпотеза відхиляється. Міжжанрова відстань у топ-децилі popularity також додатна.

Це означає, що навіть серед найпопулярніших треків жанрові профілі не зливаються повністю, хоча D_top менша за D_low.

**Нижні децилі мають більшу
міжжанрову відстань, ніж топ-
дециль popularity**

H_0

$$distance_{top} - distance_{bottom} \leq 0$$

H_1


$$distance_{top} - distance_{bottom} > 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.807	0.048	[0.716; 0.903]	[0.717; 0.903]	[0.703; 0.918]	[0.712; 0.898]	16.931	< 1e-15	Н0 відхилено


Нульова гіпотезу відхиляється, адже р значення є дуже низьким.


Всі розраховані довірчі інтервали лежать в додатній зоні, що підтверджує альтернативну гіпотезу.

Це означає, що треки з нижніх децилів популярності дійсно мають більшу міжжанрову відстань, ніж найпопулярніші треки з топ-дециля.



Кореляції аудіо- характеристик





Змінна energy додатно пов'язана з змінною loudness

H_0

$$\rho(\text{energy}, \text{loudness}) \leq 0$$

H_1


$$\rho(\text{energy}, \text{loudness}) > 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.759	0.001	[0.758; 0.760]	[0.758; 0.760]	[0.757; 0.761]	[0.758; 0.760]	1113.296	< 1e-15	Н0 відхилено

За результатами
статистичного тесту
нульова гіпотеза
відхиляється

Отримана рангова
кореляція є високою, а
вузькі довірчі інтервали
вказують на стабільність
цієї оцінки.

Між energy та loudness є
сильний додатний
зв'язок.



Змінна energy від'ємно пов'язана з змінною acoustiness

H_0

$\rho(\text{energy}, \text{acoustiness}) \geq 0$

H_1

$\rho(\text{energy}, \text{loudness}) < 0$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
-0.745	0.001	[-0.747; -0.744]	[-0.747; -0.744]	[-0.747; -0.744]	[-0.747; -0.744]	-979.379	< 1e-15	Н0 відхилено

Нульова гіпотеза відхиляється. Це підтверджує наявність сильного від'ємного зв'язку між енергійністю та акустичністю .

Усі довірчі інтервали повністю нижче нуля та майже збігаються, що свідчить про стабільність оцінки.

Аудіо-характеристики не мають зв'язку з популярністю

H_0

$$\rho(\text{feature}, \text{popularity}) = 0$$


H_1

$$\rho(\text{feature}, \text{popularity}) \neq 0$$

Feature	Spearman	Percentile 95% CI	SE boot	BH p-value	Decision	Direction
danceability	0.1089	[0.1064; 0.1119]	0.00142	< 1e-15	H0 відхиляється	додатна
instrumentalness	-0.1086	[-0.1110; -0.1057]	0.00138	< 1e-15	H0 відхиляється	від'ємна
liveness	-0.0389	[-0.0416; -0.0359]	0.00146	< 1e-15	H0 відхиляється	від'ємна
valence	0.0381	[0.0355; 0.0405]	0.00129	< 1e-15	H0 відхиляється	додатна
loudness	0.0324	[0.0301; 0.0354]	0.00132	< 1e-15	H0 відхиляється	додатна
energy	-0.0281	[-0.0306; -0.0251]	0.00137	< 1e-15	H0 відхиляється	від'ємна
acousticness	0.0268	[0.0239; 0.0298]	0.00146	< 1e-15	H0 відхиляється	додатна
speechiness	0.0103	[0.0078; 0.0130]	0.00143	6.3e-13	H0 відхиляється	додатна
tempo	-0.0089	[-0.0121; -0.0068]	0.00134	2.457e-11	H0 відхиляється	від'ємна

Популярність має статистично значущі, але слабкі зв'язки з аудіо-характеристиками. Найпомітніші за модулем зв'язки: danceability та instrumentalness.

Але цікаво, чи в якомусь певному жанрі є сильний зв'язок цих характеристик з popularity?



Аудіо-характеристики не мають сильного зв'язку з популярністю

H_0

$$\max |\rho(\text{feature}, \text{popularity} | \text{genre})| \geq 0.2$$

H_1


$$\max |\rho(\text{feature}, \text{popularity} | \text{genre})| < 0.2$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.162	0.009	[0.145; 0.181]	[0.145 ; 0.182]	[0.146; 0.182]	[0.143; 0.180]	-4.065	2.52e-05	Н0 відхилено


р-значення є низьким, тому нульова гіпотеза відхиляється.

Навіть найбільший модульний зв'язок дорівнює 0.162, і є нижчим за поріг 0.20.

Отримані довірчі інтервали лежать нижче цього порогу, тому підтверджується висновок, що окремі аудіо-характеристики самі по собі не мають сильного зв'язку з popularity.



Популярність та фан-база



**Різниця кореляцій між <1 млн і >10
млн підписників додатна.**

H_0

$$\rho(\text{followers}, \text{popularity}(< 1M)) - \rho(\text{followers}, \text{popularity}(> 10M)) \leq 0$$

H_1

$$\rho(\text{followers}, \text{popularity}(< 1M)) - \rho(\text{followers}, \text{popularity}(> 10M)) \leq 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.044	0.007	[0.031; 0.057]	[0.032; 0.056]	[0.031; 0.056]	[0.032; 0.056]	6.608	2.29e-11	Н0 відхилено

Нульову гіпотезу відхилено, тобто для менш популярних артистів кореляція з популярністю більша.

Проте значення є дуже малим, тому результат статистично значущий, але практично дуже слабкий.

Серед мегазірок частка треків з
 $\text{popularity} = 0$ перевищує 5%

H_0

$p_{\text{zero}} \leq 0.05$

H_1


$p_{\text{zero}} > 0.05$

Оцінка	SE	Normal CI	W	BH p	Рішення
0.143	0.01	[0.122; 0.163]	8.954	< 1e-15	H0 відхилено


Значення $p < 0.05$, тому нульову гіпотезу відхилено.

Частка композицій із нульовою popularity серед мегазірок становить 14.3%. Довірчий інтервал [0.122; 0.163] повністю перебуває вище порогу 5%

Це свідчить про наявність довгого хвоста непопулярних треків навіть у дуже відомих виконавців.



Еволюція змінних **acousticness та energy**



Чи мають старі пісні вищу
акустичність(acousticness) ніж
сучасні пісні

H_0

$$M_{Old} - M_{New} \leq 0$$

H_1

$$M_{Old} - M_{New} > 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.495	0.004	[0.489; 0.503]	[0.489; 0.502]	[0.484; 0.505]	[0.488; 0.501]	138.729	< 1e-15	НО відхилено

ВНр-значення є вкрай малим, тому нульова гіпотеза відхиляється.

Спостерігається значуща різниця, медіана acoustіcness у старих треків вища за медіану acoustіcness у сучасних на 0.495

Відповідно можна прийти до висновків, що у вибірці старі треки мають вищу медіанну acoustіcness.

Чи мають сучасні пісні вищу
енергійність(energy) ніж старі
пісні

H_0

$$M_{New} - M_{Old} \leq 0$$

H_1

$$M_{New} - M_{Old} > 0$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.283	0.002	[0.279; 0.287]	[0.278; 0.287]	[0.279; 0.288]	[0.279; 0.288]	127.229	< 1e-15	Н0 відхилено

Знову таки, р-значення є
вкрай малим, тому
нульова гіпотеза
ВІДХИЛЯЄТЬСЯ.

Різниця медіан сучасних і
старих пісень дорівнює
0.283

Медіанна energy сучасних
треків статистично
значуще вища, ніж у
старих треків.

Чи відрізняється пік розподілу
змінни *valence* між Minor і Major?

H_0

$\text{modeValence}(\text{Minor}) - \text{modeValence}(\text{Major}) = 0$

H_1

$\text{modeValence}(\text{Minor}) - \text{modeValence}(\text{Major}) \neq 0$

Статистика	Оцінка	95% percentile CI	Рішення
mode_valence(Minor) - mode_valence(Major)	-0.0045	[-0.0276; 0.0173]	H0 не відхилено

95% percentile bootstrap CI містить нуль, тому H0 не відхиляється. Отримані результати не дають підстав стверджувати, що піки розподілів valence для Minor і Major статистично відрізняються. Різниця оцінок є дуже малою (-0.0045), тому в межах цього датасету mode музичного ладу не демонструє помітного впливу на положення піку valence.

Висновки

- Explicit-треки загалом мають вищу popularity, ніж clean-треки, однак цей ефект не є універсальним для всіх жанрів. Найстійкіше він проявляється у Hip-Hop, R&B, Country, Pop, Classical, Electronic, Rock і Folk. Для Blues підтвердження немає, а для Jazz висновки слабший через малу explicit-вибірку та нестабільність інтервалів.
- Hip-Hop вирізняється найвищою медіанною popularity і найбільшою часткою хітів серед жанрів. Водночас Rock має найбільшу абсолютну кількість хітів, що пояснюється не вищою “хітовістю” жанру, а його найбільшим розміром у датасеті..
- Популярні треки демонструють ознаки акустичної гомогенізації. Міжжанрові audio-профілі у верхньому децилі popularity є ближчими, ніж у нижніх децилях. Водночас цей ефект не однаково проявляється для всіх жанрових пар: наприклад, для Rock/Jazz зближення підтверджується, а для Jazz/Electronic ні.

Висновки

- Energy майже дзеркально поводитьсь щодо loudness і acousticness: сильний додатний зв'язок із loudness і сильний від'ємний зв'язок з acousticness.
- Fan-base пов'язана з popularity, але різниця між малими та великими артистами невелика;
- Сучасна музика в датасеті є менш акустичною та енергійнішою порівняно зі старими треками.

**ДЯКУЄМО
ЗА УВАГУ**
