





НЕПАРАМЕТРИЧНА РЕГРЕСІЯ. АНАЛІЗ ГОЛОВНИХ КОМПОНЕНТ

Лабораторна робота N°4 з дисципліни “Аналіз даних”

Команда N°4

Сивоконь Валерія, Сусяк Владислав,
Ткаченко Євгеній.



Зміст презентації


1 Аналіз головних компонент

2 Залежна змінна danceability


3 Залежна змінна popularity



4 Залежна змінна explicit

5 Висновки



Аналіз головних компонент






РСА проведено для стандартизованих аудіо-характеристик. Мета цього блоку - зрозуміти, які групи аудіо-змінних рухаються разом, і чи можна стисло описати контрольні змінні кількома компонентами.



Музична метрика	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6
Duration	0.05	0.36	0.24	0.48	-0.42	0.18
Danceability	-0.11	-0.57	0.2	0.33	-0.2	-0.1
Energy	0.59	-0.05	0.03	0.04	0.06	0.02
Loudness	0.53	-0.12	0.07	-0.02	0.26	0.1
Speechiness	0.13	-0.16	-0.58	0.24	-0.03	-0.67
Acousticness	-0.53	0.02	-0.19	-0.12	-0.05	-0.01
Instrumentalness	0.07	0.38	0.28	0.22	-0.27	-0.48
Liveness	0.13	0.13	-0.65	0.23	-0.31	0.47
Valence	0.02	-0.58	0.12	0.03	-0.43	0.15
Tempo	0.21	0.05	-0.04	-0.7	-0.59	-0.15

Музична	Внесок у Dim.1	Внесок у Dim.2	Внесок у Dim.3	Внесок у Dim.4	Внесок у Dim.5	Внесок у Dim.6
Duration	0.28%	12.87%	5.84%	22.62%	18.05%	3.16%
Danceability	1.16%	32.41%	4.02%	11.01%	4.02%	0.93%
Energy	34.30%	0.22%	0.10%	0.19%	0.36%	0.05%
Loudness	27.84%	1.51%	0.51%	0.03%	6.56%	0.97%
Speechiness	1.79%	2.64%	33.77%	5.98%	0.10%	44.84%
Acousticness	28.00%	0.06%	3.62%	1.37%	0.26%	0.01%
Instrumentalne	0.51%	14.79%	7.95%	4.63%	7.47%	23.25%
Liveness	1.70%	1.77%	42.54%	5.30%	9.74%	22.55%
Valence	0.03%	33.43%	1.54%	0.06%	18.34%	2.11%
Tempo	4.38%	0.30%	0.13%	48.80%	35.11%	2.12%



- Перша компонента** описує вісь “енергійне та гучне звучання проти акустичного”. Найбільший внесок мають energy (34.3%), acousticness (28.0%) і loudness (27.8%): додатні значення відповідають більш енергійним і гучним трекам, від’ємні - більш акустичним.
- Друга компонента** відділяє танцювально-позитивні треки від довших та інструментальніших. Головні змінні: valence (33.4%), danceability (32.4%), instrumentalness (14.8%) і duration (12.9%).
- Третя компонента** майже повністю пов'язана з “живістю” та мовленнєвістю запису: liveness дає 42.5%, speechiness - 33.8%. Разом вони пояснюють понад три чверті структури цієї осі.
- Четверта компонента** є темпово-тривалісною віссю. Найсильніше її формує tempo (48.8%), а також duration (22.6%) і danceability (11.0%). Вона відокремлює швидші треки від довших та більш розмірених.
- П'ята компонента** є додатковою ритмічно-настроєвою віссю: tempo (35.1%), valence (18.3%) і duration (18.1%) мають найбільші внески. Вона уточнює відмінності між швидкими/позитивними та довшими композиціями.
- Шоста компонента** важлива для компактної PCA-специфікації моделі. Її формують speechiness (44.8%), instrumentalness (23.3%) і liveness (22.6%): це вісь мовленнєвості та живого звучання проти інструментальності.

PCA loadings for the first six components





На biplot точки відповідають трекам, спроєктованим на площину двох головних компонент. Стрілки показують початкові аудіо-змінні: напрям стрілки показує, у який бік зростає характеристика, а довжина - наскільки добре ця змінна представлена на обраній площині компонент




Залежна змінна **danceability**

Змінна (Regressor)	Частково лінійна модель (Лаб. 4)	Класична OLS модель (Лаб. 3)
energy	-0.239	-0.179
instrumentalness	-0.04	-0.042
speechiness	0.318	0.114
acousticness	-0.108	-0.07
year	0.0016	0.001


- У лінійній частині ми залишили змінні energy, instrumentalness, speechiness, acousticness, year та genre.
- У непараметричну частину моделі ми відправили змінні tempo (темпо) та valence (емоційна позитивність).
- Ефекти energy та instrumentalness виявилися стійкими.
- Водночас вплив speechiness та acousticness у гнучкій моделі став ще більш вираженим.

Ядрова регресія: вплив tempo на danceability
Порівняння Nadaraya-Watson та локально лінійної регресії




- Обидві непараметричні оцінки показують нелінійний між темпом та танцювальністю.
- Найвища танцювальність досягається на середніх темпах, тоді як занадто повільні або екстремально швидкі треки є менш танцювальними.
- На краях оцінка Надараї-Вотсона є більш згладженою, тоді як локально лінійна регресія краще адаптується до трендів на границях вибірки. Виявлена нелінійна залежність між tempo і danceability є досить стійкою до вибору способу непараметричного оцінювання.
- Довірчі смуги навколо кривих є найвужчими в діапазоні 120–150 BPM.
- Натомість для значень понад 180 BPM довірчі смуги сильно розширюються через брак даних.

Ядрова регресія: вплив valence на danceability
Порівняння Nadaraya-Watson та локально лінійної регресії




- Графік демонструє монотонно зростаючий зв'язок між емоційною позитивністю треку (valence) та його танцювальністю.
- Обидві непараметричні оцінки поведуться практично ідентично всередині розподілу.
- Навколо обох кривих побудовано довірчі смуги. Вони є вузькими в центрі графіка.
- На самих краях довірчі смуги закономірно розширюються, оскільки кількість спостережень із такими емоційними забарвленнями є значно меншою.




- Зв'язок між швидкістю відтворення і танцювальністю має нелінійну форму.
- Танцювальність зростає зі збільшенням темпу, досягаючи свого максимуму в районі 125 BPM. Далі показник танцювальності починає падати.
- Навколо оціненої кривої побудовано 95% довірчі смуги, розраховані на основі стандартних похибок. Ці смуги є найвужчими в центрі розподілів.


Частково лінійна регресія: Ефект Valence
Інші змінні зафіксовані на рівні медіани




- Графік демонструє нелінійний вплив емоційної окраси треку на його танцювальний потенціал.
- Функція є монотонно зростаючою.
- Нелінійність проявляється в тому, що швидкість цього приросту поступово сповільнюється для надзвичайно позитивних композицій.



- Максимальний позитивний вплив на танцювальність дають треки з темпом 110–120 BPM.
- Для валенсу тренд є стабільно зростаючим, а саме чим радісніший трек, тим він танцювальніший.
- 95% довірчі смуги є найвужчими в центрі розподілу даних. На краях графіків вони закономірно розширюються через брак спостережень.



Залежна змінна **popularity**




term	lm_estimate	lm_se	plm_linear_estimate	plm_linear_se
log_followers_c	2.513	0.018		
l(log_followers_c^2)	0.107	0.005		
explicitExplicit	0.868	0.119	0.821	0.119
duration_min	-0.138	0.025	-0.119	0.025
danceability	7.062	0.315	7.102	0.315
energy	-4.147	0.348	-4.069	0.348
loudness	0.517	0.018	0.509	0.018
speechiness	-2.534	0.484	-2.564	0.483
acousticness	-1.202	0.202	-1.17	0.202
instrumentalness	-0.843	0.175	-0.971	0.175
liveness	-5.015	0.205	-4.961	0.205
valence	-3.417	0.202	-3.393	0.202
tempo	0.009	0.001	0.009	0.001

Коефіцієнти контрольних змінних у частково лінійній моделі близькі до коефіцієнтів базової лінійної моделі. Це означає, що перехід від квадратичної апроксимації log_followers до гладкої функції s(log_followers) не руйнує висновки щодо контрольних аудіо-змінних.

Conditional popularity predictions by artist audience size


Audio controls fixed at medians, categorical controls fixed at modes



- Усі акустичні метрики зафіксовано на рівні медіани.
- Після певного порогу популярність треку починає стрімко зростати разом із розміром аудиторії.
- Три різні гнучкі моделі показують схожі результати.

Conditional predicted popularity by explicit content


Numeric controls fixed at medians, categorical controls fixed at modes



- Усі числові контрольні змінні зафіксовано на рівні медіан, а категорійні на рівні моди.
- Треки з нецензурною лексикою мають вищу передбачену популярність порівняно з «чистими» композиціями.
- Усі три гнучкі моделі підтверджують цей стрибок популярності.

Conditional popularity curve by danceability


Other numeric controls fixed at medians, categorical controls fixed at modes




- Контрольні змінні зафіксовано на медіанах та модах.
- Гнучкі алгоритми не виявили складних парабол, тренд є майже що прямою лінією.
- Оцінки GAM та Частково лінійної регресії повністю збігаються.
- Сама по собі танцювальність дає лише мінімальний приріст до популярності.

Kernel regression: Nadaraya-Watson vs local linear


Controls compressed with first 6 audio PCs fixed at zero




- Популярність треку має залежність від кількості підписників.
- Інші акустичні фактори стиснуті до 6 головних компонент і зафіксовані на нулі.
- Оцінки Надараї-Вотсона та Локально лінійної регресії дають ідентичні результати там, де зосереджено найбільше даних.



Залежна змінна **explicit**





У Лабораторній роботі N°3 ми досліджували фактори, що впливають на ймовірність наявності нецензурної лексики (explicit) у треках за допомогою параметричних моделей (Logit/Probit). Було доведено, що висока танцювальність (danceability) та енергійність збільшують ймовірність explicit-контенту, а позитивність (valence) — зменшує.

Однак класичні параметричні моделі припускають, що вплив цих ознак на лог-шанси є суворо лінійним. **Дослідницьке питання поточної роботи:** Чи має вплив акустичних характеристик на ймовірність появи нецензурної лексики нелінійний характер? Для цього ми застосовуємо методи частково лінійної регресії (PLM), узагальнені адитивні моделі (GAM).



НЕПАРАМЕТРИЧНЕ ОЦІНЮВАННЯ ФУНКЦІЇ РЕГРЕСІЇ

Оскільки залежна змінна є бінарною, ми використовували моделі з логістичною функцією зв'язку (family = binomial).

1) Узагальнена адитивна модель (GAM)





У повній GAM-моделі непараметричному згладжуванню (через сплайни) піддалися ключові числові регресори: danceability, energy, valence та year.

Графіки часткових ефектів доводять наявність сильної нелінійності, яку ігнорували моделі з ЛРЗ:

1) Вплив танцювальності майже відсутній на низьких рівнях, але після позначки 0.6 крива стрімко йде вгору.

2) Вплив енергії є пологим до 0.8, після чого відбувається різкий стрибок. Це означає, що ризик матів максимальний саме для екстремально "агресивних" треків.

3) Вплив позитивності (valence) має форму плавної дуги: він позитивний для нейтральних треків, але після 0.5 крива різко падає вниз.



2) Частково лінійна модель


Як реалізовано:

- Непараметрична частина: $s(\text{danceability})$
- Параметрична частина: energy , valence , year , genre

Для побудови частково лінійної моделі регресори було розділено на дві групи. У непараметричну частину було включено ключовий фактор danceability , оскільки розвідковий аналіз та ЛРЗ вказували на його сильну, але потенційно нелінійну дію. У лінійну частину включено контрольні змінні (energy , valence , year) та genre . Жанр є категорійною змінною, тому він математично може входити лише лінійно (подібно до фіксованих ефектів).

Числові контролі (energy , valence , year) зафіксовано на рівні їхньої медіани

Вплив Danceability на ймовірність Explicit (для Hip-Hop)



Ми ізолювали вплив **танцювальності** всередині жанру **Hip-Hop**, зафіксувавши інші змінні на рівні медіани.

На графіку умовної ймовірності видно, що шанси наявності матів у репі зростають від ~65% до понад 90% при русі від нетанцювальних до супер-танцювальних композицій, причому цей ріст має плато посередині (0.25 - 0.50).


Term	GLM Estimate	PLM Estimate
(Intercept)	-27.8754228954317	-27.9356370690054
danceability	1.04245728458111	
energy	1.02538133600688	1.0497712356351
valence	-0.418344709375914	-0.41043205168749
loudness	0.0637347830132842	0.0629163864924613
speechiness	4.4935984831422	4.39696977658477
year	0.0119365985865872	0.0122770486235018
genreClassical	0.802038430322188	0.802736953426919
genreCountry	0.927919890736491	0.946811434103628
genreElectronic	0.535518670280336	0.516936703901073
genreFolk	0.992222518165633	0.96590292872667
genreHip-Hop	3.38512491570255	3.32448620566251
genreJazz	-0.071375669391861	-0.0736576418890895
genrePop	0.741119059106625	0.733004475322764
genreR&B	1.13473032696626	1.10356699159769
genreRock	1.15784824578577	1.13186546540379

Для демонстрації стійкості (тобто robustness) оцінок ми переходили від базової логістичної моделі (специфікація з ЛРЗ) до частково лінійної (PLM), а потім до повної GAM-моделі зі сплайнами для всіх числових контролів.

Коефіцієнти параметричної частини PLM залишилися практично ідентичними коефіцієнтам базової моделі з ЛРЗ. Наприклад, логіт-коефіцієнт для індикатора жанру не зазнав значних зсувів. Це доводить, що переведення danceability у непараметричну форму уточнило саму форму зв'язку, але не зруйнувало загальної економетричної структури моделі.

3) Ядрова регресія


Для перевірки без припущень про глобальні сплайни було реалізовано оцінку Надарай-Вотсона у 2D-просторі предикторів (danceability та energy). Для візуалізації було зроблено умовний зріз: energy зафіксовано на рівні медіани.



Графік ядрової регресії має значно більш "хвилясту" структуру порівняно зі сплайнами GAM, оскільки ядерна оцінка є локальною і сильно реагує на густину даних у конкретних точках. Розширення синьої довірчої смуги на краях розподілу демонструє зростання невизначеності через малу кількість спостережень у цих зонах.

Ядрова регресія: Надарая-Вотсон vs Локальна лінійна

Контролі (energy, valence) зафіксовано на рівні медіани



Умовна ймовірність того, що трек міститиме нецензурну лексику, залежно від його танцювальності. Було зафіксовано два найважливіші числові контролі (energy та valence) на рівні їхніх вибірових медіан.

Обидва непараметричні методи підтверджують висновки, отримані раніше за допомогою GAM. На рівні danceability від 0.0 до 0.5 ймовірність наявності матів є стабільно низькою (близько 15-20%). Однак після подолання позначки 0.5 починається стрімке, нелінійне зростання ризику наявності explicit-контенту.

Висновки:

- PCA показав, що аудіо-характеристики треків мають багатовимірну структуру: енергійність, акустичність, танцювальність, позитивність, інструментальність, live-звучання та speechiness формують різні приховані музичні виміри.
- Для danceability ключовими факторами стали tempo та valence. Темп має нелінійний ефект: танцювальність зростає до оптимального BPM, але падає для надто повільних або надто швидких треків. Позитивніший настрій композиції загалом підвищує danceability.
- Для popularity головним результатом є нелінійний зв'язок із fan-base артиста. Ефект followers не є однаковим на всіх рівнях: у середній і верхній частині розподілу зв'язок із popularity стає помітно сильнішим.
- Для explicit-контенту моделі показали, що danceability, energy та valence впливають на ймовірність explicit-статусу нелінійно. Особливо важливо, що на високих рівнях danceability ймовірність explicit-контенту може зростати швидше.
- GAM і ядрові методи дозволили краще побачити форму залежностей, ніж проста лінійна модель, бо вони не нав'язують жорстку лінійну структуру. Водночас на краях розподілу результати менш стабільні через меншу кількість спостережень.

**ДЯКУЄМО
ЗА УВАГУ**
