

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ

ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Факультет програмних систем та прикладної математики

Кафедра прикладної математики

ЗВІТ

з лабораторної роботи №2

на тему: «Статистичне виведення»

Виконали: студенти групи

КМ-33, команда №4

Сивоконь В. В., Сусяк В. Р.,

Ткаченко Є. В.

Зміст

Вступ і дослідницькі питання	3
Дані та підготовка	3
Хід роботи.....	5
Довірчі інтервали	5
Гіпотези	28
Висновки.....	45
Використані джерела:	46

Вступ і дослідницькі питання

У першій лабораторній роботі ми побачили кілька помітних закономірностей у музичному датасеті. У цій роботі ці спостереження перевіряються статистично: для основних оцінок будуються довірчі інтервали, а висновки з EDA формулюються як гіпотези та тестуються за допомогою Wald-тестів і бутстрепа.

У звіті перевіряються такі гіпотези:

1. Чи мають explicit-треки вищу popularity, ніж clean-треки, загалом і в межах окремих жанрів;
2. Чи зближуються аудіо-профілі жанрів серед найпопулярніших треків;
3. Чи є Rock/Jazz контрастнішою жанровою парою, ніж Jazz/Electronic;
4. Чи пов'язані між собою energy, loudness та acousticness;
5. Чи слабшає зв'язок між fan-base артиста та popularity для мегазірок;
6. Чи мають мегазірки суттєву частку треків з popularity = 0;
7. Чи старі треки є акустичнішими, а сучасні - енергійнішими;
8. Чи відрізняється пік розподілу valence для Minor і Major;
9. Чи підвищує explicit-контент ймовірність потрапляння треку до супер-хітів.

Дані та підготовка

Початковий файл songs.csv було повторно очищено. Основні кроки: вилучено дублікати за name, artists, genre, year; відкинуто некоректні duration_ms ≤ 0; вилучено технічні ідентифікатори id та artist_ids; обрізано зайві пробіли; порожні рядки перетворено на NA; зі спискових полів artists і niche_genres витягнуто перше значення; створено змінну explicit за словником

нецензурної лексики; жанри, тональності, mode та explicit перетворено на фактори. Після очищення залишилося 516 129 рядків.

Змінна	Мін.	Середнє	Ст. відх.	Макс.
danceability	0.045	0.525	0.173	0.988
energy	0.000	0.672	0.247	1.000
loudness	-44.868	-7.904	3.878	0.000
speechiness	0.022	0.085	0.093	0.966
acousticness	0.000	0.244	0.309	0.996
instrumentalness	0.000	0.109	0.241	0.998
liveness	0.007	0.226	0.199	1.000
valence	0.000	0.464	0.250	0.998
tempo	30.946	122.863	29.464	245.941
duration_ms	15027	237840.753	96735.543	4995315
year	1900	2006.986	13.573	2025
popularity	0	17.569	17.127	98
total_artist_followers	0	2266524.240	8359223.421	295181876
avg_artist_popularity	0	47.366	19.061	100

Розподіл за жанрами такий: Rock має 186 943 треки, Pop має 66 728, Electronic має 64 758, Folk має 47 917, Country має 43 885, Hip-Hop має 37 887, R&B має 25 248, Jazz має 16 024, Blues має 15 173, Classical має 11 566.

Explicit-треків має 88 111, clean-треків має 428 018.

Хід роботи

Довірчі інтервали

У роботі кожна числова характеристика розглядається як оцінка відповідного невідомого параметра. Щоб не обмежуватися лише точковими значеннями, для оцінок будуються 95% довірчі інтервали, а ключові твердження перевіряються за допомогою Wald-тестів з рівнем значущості $\alpha = 0.05$.

Усі статистики поділено на три групи. До першої групи належать середні, частки, кількості та різниці середніх, для яких стандартну похибку можна оцінити напряму. Наприклад, для частки $\hat{p}$ використовується стандартна похибка $\sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$. До другої групи належать медіани та інші квантілі. Для них використовується непараметричний бутстреп, оскільки дисперсія квантиля залежить від невідомої щільності розподілу в точці цього квантиля. До третьої групи належать кореляції Спірмена, евклідові відстані між аудіо-профілями, різниці кореляцій та інші складні функціонали; для них також використовується бутстреп.

Wald-тест має вигляд $W = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$. Для статистик першої групи se обчислюється за аналітичною формулою, а для статистик другої та третьої груп з бутстреп-розподілу. Односторонні альтернативи використовуються тоді, коли нас цікавить конкретний напрямок ефекту, наприклад, `explicit > clean`, `D_low > D_top` або `old acousticness > modern acousticness`. Для серій одночасних перевірок застосовується корекція Benjamini-Hochberg, щоб зменшити ризик хибних статистично значущих висновків.

Нижче наведено основні довірчі інтервали, які безпосередньо відповідають EDA-спостереженням. Вони не просто дублюють точкові оцінки з ЛР1, а

показують, наскільки стабільними є висновки з урахуванням вибіркової невизначеності.

1) Довірчі інтервали для медіани популярності за жанрами:

genre	n	median	norm_ci	basic_ci	stud_ci	perc_ci
Hip-Hop	37887	25	(24.40 ; 26.06)	(25.00 ; 26.00)	(25.00 ; 26.38)	(24.00 ; 25.00)
R&B	25248	20	(18.95 ; 20.59)	(19.00 ; 20.00)	(19.00 ; 20.00)	(20.00 ; 21.00)
Country	43885	17	(16.47 ; 17.79)	(17.00 ; 18.00)	(17.00 ; 18.05)	(16.00 ; 17.00)
Classical	11566	15	(14.40 ; 16.04)	(15.00 ; 16.00)	(15.00 ; 16.46)	(14.00 ; 15.00)
Pop	66728	15	(14.65 ; 15.43)	(15.00 ; 16.00)	(15.00 ; 15.41)	(14.00 ; 15.00)
Electronic	64758	14	(12.66 ; 14.57)	(13.00 ; 14.00)	(11.46 ; 14.00)	(14.00 ; 15.00)
Jazz	16024	13	(12.62 ; 13.34)	(12.00 ; 13.00)	(12.72 ; 13.00)	(13.00 ; 14.00)
Folk	47917	12	(11.80 ; 12.23)	(12.00 ; 12.00)	(12.00 ; 12.00)	(12.00 ; 12.00)
Rock	186943	12	(11.79 ; 12.19)	(12.00 ; 12.00)	(12.00 ; 12.00)	(12.00 ; 12.00)

Blues	15173	10	(9.43 ; 10.43)	(9.00 ; 10.00)	(9.33 ; 10.00)	(10.00 ; 11.00)
-------	-------	----	-------------------	-------------------	-------------------	--------------------

Наведена таблиця демонструє розподіл медіанних значень для понад 516 тисяч треків для десяти музичних жанрів. Найвищі медіанні показники спостерігаються у Нір-Нор (25) та R&B (20), тоді як замикає список Blues з найменшим значенням (10). Найбільший обсяг даних представлений у жанрі Rock (понад 186 тисяч треків), тоді як Classical має найменшу вибірку (близько 11,5 тисяч).

Розраховані довірчі інтервали є досить вузькими для всіх жанрів, що свідчить про високу точність та статистичну надійність отриманих медіанних оцінок завдяки великому розміру вибірок.

2) Кількість хітів для жанрів, коли popularity ≥ 50

Жанр	n	К-сть хітів	95% СІ для кількості	$\hat{p}$
Rock	186 943	6 753	[6594.87; 6911.13]	0.0361
Pop	66 728	4 887	[4755.10; 5018.90]	0.0732
Hip-Hop	37 887	4 770	[4643.44; 4896.56]	0.1260
Electronic	64 758	2 759	[2658.27; 2859.73]	0.0426

Country	43 885	2 352	[2259.53; 2444.47]	0.0536
R&B	25 248	1 913	[1830.59; 1995.41]	0.0758
Folk	47 917	1 587	[1510.22; 1663.78]	0.0331
Jazz	16 024	671	[621.30; 720.70]	0.0419
Classical	11 566	570	[524.37; 615.63]	0.0493
Blues	15 173	298	[264.50; 331.50]	0.0196

Наведена таблиця показує, що попри першість Rock за загальною кількістю хітів (6 753 треки), з точки зору ефективності лідером є Нір-Нор, де найбільша частка композицій $\hat{p}=12.6$ стає популярною. Високу конверсію в хіти демонструють також R&B та Pop, тоді як найменш ефективним виявився Blues, де лише 1.96% треків долають цей поріг.

Розраховані 95% асимптотичні довірчі інтервали є досить вузькими для всіх позицій, що підтверджує високу точність отриманих оцінок завдяки великим обсягам вибірок у кожному жанрі.

3) Медіанна популярність для пісень з popularity ≥ 50

genre	n	median	ci_percentile
Hip-Hop	4770	57	(57.00 ; 57.00)
Pop	4887	57	(57.00 ; 57.00)
R&B	1913	57	(56.00 ; 57.00)
Classical	570	56	(55.00 ; 56.00)
Country	2352	56	(56.00 ; 56.00)
Electronic	2759	56	(55.00 ; 56.00)
Rock	6753	56	(56.00 ; 56.00)
Blues	298	55	(54.00 ; 56.00)
Folk	1587	55	(55.00 ; 55.00)
Jazz	671	55	(54.00 ; 56.00)

Аналіз цієї підвибірки чітко демонструє ефект стандартизації, якщо у загальному датасеті розрив між жанрами для медіан досягав 15 пунктів, то серед популярних треків він скоротився всього до 2 пунктів (діапазон 55–57). Найвищі позиції утримують Нір-Нор, Поп та R&B з медіаною 57.

Перцентильні довірчі інтервали для більшості домінуючих жанрів (зокрема Rock, Pop, Нір-Нор) повністю виродилися в одну точку, що свідчить про монолітну однорідність треків, які перетинають цей поріг популярності. Водночас для Blues та Jazz інтервали залишаються ширшими [54.00; 56.00]. Це пояснюється помітно меншою кількістю композицій (усього 298 для Blues), здатних вийти у високі рейтинги, що й зумовлює більшу статистичну варіативність їхніх оцінок.

4) Довірчі інтервали для тривалості (≤ 10 хв) за жанрами

genre	n	median	norm_ci	basic_ci	stud_ci	perc_ci
R&B	25096	3.96	(3.95 ; 3.97)	(3.95 ; 3.97)	(3.95 ; 3.97)	(3.95 ; 3.97)
Electronic	64489	3.88	(3.87 ; 3.89)	(3.87 ; 3.89)	(3.87 ; 3.89)	(3.87 ; 3.89)
Rock	184070	3.86	(3.86 ; 3.87)	(3.86 ; 3.87)	(3.86 ; 3.87)	(3.86 ; 3.87)
Blues	15064	3.70	(3.67 ; 3.72)	(3.67 ; 3.73)	(3.67 ; 3.73)	(3.67 ; 3.72)
Hip-Hop	37849	3.60	(3.59 ; 3.61)	(3.59 ; 3.61)	(3.59 ; 3.61)	(3.59 ; 3.61)
Pop	66553	3.58	(3.57 ; 3.59)	(3.57 ; 3.59)	(3.57 ; 3.59)	(3.57 ; 3.58)
Folk	47795	3.54	(3.53 ; 3.55)	(3.53 ; 3.55)	(3.53 ; 3.55)	(3.53 ; 3.55)
Classical	11486	3.49	(3.47 ; 3.52)	(3.47 ; 3.52)	(3.46 ; 3.52)	(3.46 ; 3.52)
Jazz	15918	3.48	(3.45 ; 3.50)	(3.45 ; 3.50)	(3.45 ; 3.51)	(3.46 ; 3.51)
Country	43839	3.45	(3.44 ; 3.46)	(3.44 ; 3.46)	(3.44 ; 3.46)	(3.44 ; 3.46)

Наведена таблиця демонструє міжжанрову диференціацію за досліджуваним медіанним показником. Найвищі значення стабільно фіксуються у жанрах R&B (3.96), Electronic (3.88) та Rock (3.86), тоді як найменші показники притаманні Classical (3.49), Jazz (3.48) та Country (3.45). Завдяки масивним обсягам вибірок, усі чотири типи розрахованих довірчих інтервалів виявилися вузькими та практично збігаються між собою. Для більшості масових жанрів ширина інтервалу не перевищує 0.01–0.02 пункти, що свідчить про статистичну точність та надійність отриманих оцінок медіани. Таким чином, результати надійно доводять, що зафіксована ієрархія жанрів є не випадковою, а фундаментальною характеристикою цих аудіоданих.

5) Довірчі інтервали для нішевих жанрів жанру Classical

Niche genre	n	Q1	CI Q1	Median	CI Median	Q3	CI Q3
gregorian chant	88	11.2	[0.00; 24.00]	37	[26.80; 42.00]	45	[42.00; 48.60]
japanese classical	22	9.25	[0.13; 24.75]	28	[12.67; 33.00]	34	[29.00; 39.00]
score	175	15	[6.00; 19.00]	27	[23.00; 32.00]	43	[37.00; 48.73]
soundtrack	84	18	[0.75; 22.00]	26	[23.00; 29.00]	37.2	[30.13; 44.00]
celtic	80	14.8	[8.00; 17.75]	23.5	[19.00; 27.00]	33.2	[29.77; 37.00]
comedy	28	19	[14.00; 21.75]	22.5	[20.00; 25.50]	26.2	[25.00; 34.00]
ambient	27	0	[0.00; 16.00]	19	[0.00; 26.00]	27	[21.50; 30.00]
musicals	4941	4	[4.00; 5.00]	19	[18.00; 19.00]	32	[31.00; 33.00]
ballet	86	4	[0.00; 6.25]	17	[7.00; 19.73]	23.8	[21.00; 28.75]
east coast hip hop	33	0	[0.00; 11.00]	16	[2.00; 24.00]	32	[19.60; 45.00]

art pop	66	4.25	[0.13; 10.60]	15	[11.00; 21.00]	26.8	[21.27; 30.50]
big band	106	6.25	[5.00; 11.00]	14.5	[11.00; 18.50]	22	[20.00; 25.75]
alternative metal	39	13	[11.00; 13.50]	14	[13.00; 18.00]	19.5	[16.00; 23.00]
baroque pop	2531	0	[0.00; 0.00]	14	[13.00; 15.00]	28	[27.00; 30.00]
catholic music	52	0.75	[0.00; 11.00]	14	[8.00; 23.00]	26.5	[23.00; 34.00]
classical crossover	621	0	[0.00; 1.00]	13	[11.00; 15.00]	25	[22.00; 27.00]
choral	414	2	[1.00; 4.00]	11	[10.00; 13.00]	26	[22.00; 28.00]
neoclassical	150	5	[1.00; 6.00]	11	[8.00; 13.50]	17	[15.88; 20.00]
avant-garde	265	0	[0.00; 1.00]	10	[7.00; 11.00]	16	[14.00; 18.00]
christmas	75	2	[1.00; 5.00]	10	[6.00; 19.00]	30.5	[20.00; 36.23]
canzone napoletana	38	0	[0.00; 3.00]	8.5	[1.77; 19.50]	25	[14.00; 34.00]
orchestral	102	0	[0.00; 2.12]	6	[4.00; 10.00]	18.8	[12.00; 28.60]

chamber music	62	0	[0.00; 0.00]	5	[0.50; 13.47]	25.5	[13.00; 35.00]
classical	409	0	[0.00; 0.00]	5	[4.00; 7.00]	20	[18.00; 23.00]
contempo rary classical	56	0	[0.00; 0.00]	3.5	[0.00; 16.50]	27.8	[17.07; 38.00]

6) Count, danceability, energy та popularity для топ-15 нішевих жанрів.

Niche genre	Count	CI Count	Mean Dance	CI Dance	Mean Energy	CI Energy	Mean Pop	CI Pop
classic country	13149	[12927; 13371]	0.581	[0.579; 0.583]	0.468	[0.465; 0.472]	20.8	[20.54; 21.09]
death metal	12877	[12657; 13097]	0.327	[0.325; 0.329]	0.934	[0.932; 0.935]	14.1	[13.85; 14.27]
blues	11576	[11368; 11784]	0.553	[0.550; 0.556]	0.519	[0.514; 0.523]	13.5	[13.27; 13.79]
alt country	11549	[11341; 11757]	0.521	[0.518; 0.523]	0.504	[0.500; 0.508]	11.7	[11.44; 11.94]
emo	9566	[9376; 9756]	0.425	[0.422; 0.427]	0.820	[0.817; 0.824]	21.2	[20.82; 21.55]
black metal	8612	[8432; 8792]	0.274	[0.271; 0.277]	0.886	[0.883; 0.889]	10.5	[10.27; 10.72]

classic rock	8295	[8118; 8472]	0.501	[0.498; 0.505]	0.689	[0.685; 0.694]	24.6	[24.24; 25.04]
ccm	7591	[7421; 7761]	0.479	[0.476; 0.482]	0.636	[0.632; 0.641]	19.0	[18.59; 19.37]
classic soul	7530	[7361; 7699]	0.575	[0.572; 0.578]	0.530	[0.526; 0.534]	18.3	[17.89; 18.62]
country	7392	[7225; 7559]	0.564	[0.562; 0.567]	0.668	[0.664; 0.673]	26.9	[26.48; 27.35]
alternative metal	6681	[6522; 6840]	0.453	[0.450; 0.456]	0.863	[0.860; 0.867]	26.7	[26.19; 27.13]
darkwave	6057	[5905; 6209]	0.538	[0.535; 0.541]	0.806	[0.802; 0.811]	11.3	[10.95; 11.58]
aor	5932	[5782; 6082]	0.476	[0.473; 0.480]	0.728	[0.722; 0.733]	15.2	[14.86; 15.63]
doom metal	5928	[5778; 6078]	0.340	[0.337; 0.344]	0.747	[0.742; 0.752]	12.4	[12.06; 12.71]
musicals	5208	[5067; 5349]	0.482	[0.478; 0.486]	0.386	[0.380; 0.392]	20.2	[19.70; 20.64]

Отримані результати демонструють, що audio-features самі по собі не визначають комерційний успіх жанру. Наприклад, death metal і black metal характеризуються дуже високими значеннями energy, однак їхня середня popularity залишається помітно нижчою за country або classic rock. Водночас жанри з помірними аудіо-параметрами можуть мати вищі показники популярності, що вказує на суттєвий вплив зовнішніх факторів: розміру аудиторії, історичної впізнаваності жанру, алгоритмів стрімінгових платформ та культурного контексту.

7) Довірчі інтервали для топ-15 нішевих жанрів за часткою explicit.

Niche genre (macro)	Усього	Explicit	p_hat	95% CI
trap (Hip-Hop)	160	157	0.981	[0.960; 1.002]
melodic rap (Hip-Hop)	1637	1577	0.963	[0.954; 0.972]
chicago drill (Hip-Hop)	549	528	0.962	[0.946; 0.978]
west coast hip hop (Hip-Hop)	120	115	0.958	[0.923; 0.994]
brooklyn drill (Hip-Hop)	314	300	0.955	[0.933; 0.978]
country hip hop (Hip-Hop)	182	170	0.934	[0.898; 0.970]
gangster rap (Hip-Hop)	316	295	0.934	[0.906; 0.961]
crunk (Hip-Hop)	1859	1695	0.912	[0.899; 0.925]
southern hip hop (Hip-Hop)	1029	937	0.911	[0.893; 0.928]
hardcore hip hop (Hip-Hop)	246	224	0.911	[0.875; 0.946]
hyphy (Hip-Hop)	457	416	0.910	[0.884; 0.936]

rap (Hip-Hop)	1901	1723	0.906	[0.893; 0.919]
new orleans bounce (Hip- Hop)	80	72	0.900	[0.834; 0.966]
trap metal (Hip-Hop)	157	140	0.892	[0.843; 0.940]
g-funk (Hip- Hop)	3091	2744	0.888	[0.877; 0.899]

Результати підтверджують сильну концентрацію explicit-контенту саме у hip-hop напрямках. Для більшості rap-похідних ніш частка explicit перевищує 90%, а в окремих випадках наближається до 100%. Це свідчить, що використання explicit-лексики в межах цих піджанрів є радше типовою стилістичною нормою, ніж винятком.

8) Довірчі інтервали для частки explicit для топ-15 наймасовіших нішевих жанрів.

Niche genre	Усього	Explicit	p_hat	95% CI
alternative metal	6681	2048	0.307	[0.295; 0.318]
death metal	12877	3213	0.250	[0.242; 0.257]
emo	9566	1864	0.195	[0.187; 0.203]
black metal	8612	1604	0.186	[0.178; 0.194]
country	7392	1195	0.162	[0.153; 0.170]

darkwave	6057	715	0.118	[0.110; 0.126]
musicals	5208	581	0.112	[0.103; 0.120]
doom metal	5928	656	0.111	[0.103; 0.119]
alt country	11549	1151	0.0997	[0.094; 0.105]
classic rock	8295	545	0.0657	[0.060; 0.071]
aor	5932	289	0.0487	[0.043; 0.054]
blues	11576	475	0.0410	[0.037; 0.045]
classic country	13149	414	0.0315	[0.029; 0.034]
classic soul	7530	176	0.0234	[0.020; 0.027]
ccm	7591	59	0.00777	[0.006; 0.010]

Аналіз свідчить про значну неоднорідність explicit-частки серед масових ніш від 30.7% в alternative metal до менш ніж 1 % у ccm. Проте загалом цей показник тут є суттєво нижчим, ніж у профільних rap/hip-hop напрямках. Вузькі довірчі інтервали підтверджують високу точність оцінок для кожної з представлених ніш.

9) Довірчі інтервали для середньої popularity для топ-10 альбомів.

Для верифікації середньої популярності окремих альбомів розмір вибірки є обмеженим (кількість треків в одному альбомі $n < 30$). У таких умовах асимптотична нормальність за ЦГТ ще не досягається повноцінно, а вибіркова оцінка s^2 вносить додаткову варіативність. Для демонстрації методологічної відмінності було розраховано інтервали за нормальним квантилем Z (1.96) та за консервативним t -розподілом Стюдента.

Альбом	n	Сер. поп	95% Z CI	95% t CI
AM	11	79.0	[73.42; 84.58]	[72.66; 85.34]
The Dark Side of the Moon	9	72.3	[68.21; 76.45]	[67.49; 77.18]
ASTROWORLD	17	72.1	[69.18; 74.93]	[68.95; 75.17]
Certified Lover Boy	17	71.0	[68.04; 73.96]	[67.80; 74.20]
Nothing but the Beat (Ultimate Edition)	9	70.2	[63.86; 76.59]	[62.73; 77.71]
DAMN.	13	70.2	[65.94; 74.37]	[65.47; 74.84]
Chocolate Starfish And The Hot Dog Flavored Water	10	69.5	[63.18; 75.82]	[62.21; 76.79]
Her Loss	11	69.3	[67.21; 71.34]	[66.92; 71.62]
The New Abnormal	8	69.2	[63.66; 74.84]	[62.51; 75.99]
A Christmas Gift For You From Phil Spector	12	69.0	[61.52; 76.48]	[60.61; 77.39]

Як демонструють результати таблиці, в усіх випадках довірчі інтервали за Стьюдентом є ширшими за класичні нормальні. Це математично обґрунтовано квантилі t-розподілу враховують підвищений ризик відхилень на малих обсягах даних. Наприклад, для альбому 'The New Abnormal' (n = 8) нормальний ДІ штучно звужує невизначеність до [63.66; 74.84], тоді як t-інтервал коректно розширює

межі до [62.51; 75.99]. Це доводить необхідність використання розподілу Стьюдента для малих вибірок в індустрії.

10) Інтервали для медіан та квантилів топ-10 альбомів.

Альбом	n	Q1	CI Q1	Median	CI Median	Q3	CI Q3
AM	11	73	[65.00; 81.73]	80	[69.00; 88.00]	87	[78.50; 90.00]
The Dark Side of the Moon	9	66	[64.00; 76.00]	72	[65.00; 78.00]	78	[71.00; 81.00]
ASTROWORLD	17	67	[65.00; 71.00]	71	[67.00; 76.00]	76	[71.00; 82.00]
Certified Lover Boy	17	65	[64.53; 71.00]	71	[65.00; 75.00]	75	[71.00; 81.00]
Nothing but the Beat (Ultimate Edition)	9	64	[56.00; 77.00]	70	[57.00; 78.00]	77	[69.00; 84.00]
Her Loss	11	67	[65.00; 69.73]	69	[67.00; 71.00]	71	[68.27; 74.50]
Chocolate Starfish And The Hot Dog Flavored Water	10	64.2	[53.75; 72.00]	68.5	[61.77; 79.50]	76.5	[65.75; 83.50]

DAMN.	13	64	[61.00; 69.00]	68	[64.00; 76.00]	76	[67.00; 82.00]
The New Abnormal	8	62.5	[61.00; 70.98]	67.5	[62.00; 78.00]	75	[64.75; 82.00]
A Christmas Gift For You From Phil Spector	12	58	[53.50; 70.17]	66.5	[55.80; 79.00]	79	[65.25; 86.75]

Альбомні квартилі показують не тільки середній рівень популярності, а й розкид усередині релізу; для малих альбомів невизначеність квартилів помітна.

11) Pop-gap

Альбом	n	pop_gap	95% bootstrap CI
Fallen	43	87	[62.0; 89.0]
Gangsta's Paradise	13	87	[0.0; 87.0]
Ghost Stories	29	87	[21.0; 87.0]
Toxicity	14	85.5	[18.0; 86.0]
Franz Ferdinand	8	85	[0.5; 85.0]
Jingle Bell Rock	23	84	[4.0; 84.0]
Recovery	45	84	[36.0; 86.0]
This Old Dog	13	84	[14.7; 84.0]
True	24	84	[43.5; 86.0]
Graduation	15	83	[1.0; 84.0]

Для деяких топ-альбомів нижня межа ДІ знаходиться суттєво вище нуля. Це доводить, що різкий розрив між синглом та іншими піснями є стійкою характеристикою бізнес-моделей окремих релізів, а не випадковим шумом вибірки. Однак для деяких альбомів нижня межа ДІ знаходиться в нулі або трохи вище, що можна пов'язати з занадто малою кількістю треків у виданні.

- 12) Довірчі інтервали для кількості за жанрами, для кількості за музичним ладом (Mode) та для кількості за EXPLICIT контентом.

Жанр	К-сть	95% СІ к-сті	Частка	95% СІ частки
Rock	186943	(186266; 187620)	0.362	(0.3609; 0.3635)
Pop	66728	(66256; 67200)	0.129	(0.1284; 0.1302)
Electronic	64758	(64292; 65224)	0.125	(0.1246; 0.1264)
Folk	47917	(47508; 48326)	0.0928	(0.0920; 0.0936)
Country	43885	(43492; 44278)	0.0850	(0.0843; 0.0858)
Hip-Hop	37887	(37520; 38254)	0.0734	(0.0727; 0.0741)
R&B	25248	(24944; 25552)	0.0489	(0.0483; 0.0495)

Jazz	16024	(15780; 16268)	0.0310	(0.0306; 0.0315)
Blues	15173	(14935; 15411)	0.0294	(0.0289; 0.0299)
Classical	11566	(11358; 11774)	0.0224	(0.0220; 0.0228)

Жанровий склад датасету дуже нерівномірний. Rock займає найбільшу частку каталогу, тому абсолютні кількості для Rock не можна напряду трактувати як більшу популярність жанру.

Категорія	К-сть	95% СІ к-сті	Частка	95% СІ частки
Major	344905	(344242; 345568)	0.668	(0.6670; 0.6695)
Minor	171224	(170561; 171887)	0.332	(0.3305; 0.3330)
Clean	428018	(427488; 428548)	0.829	(0.8283; 0.8303)
Explicit	88111	(87581; 88641)	0.171	(0.1697; 0.1717)

Major-треки становлять приблизно дві третини датасету, а explicit-контент близько 17%. Інтервали вузькі, тому ці пропорції оцінені дуже стабільно.

13) Довірчі інтервали для кількості за тональністю (Key)

Key	К-сть	95% СІ к-сті	Частка	95% СІ частки
G	61076	(60621; 61531)	0.118	(0.1175; 0.1192)
C	58792	(58345; 59239)	0.114	(0.1130; 0.1148)
D	57189	(56747; 57631)	0.111	(0.1099; 0.1117)
A	55810	(55373; 56247)	0.108	(0.1073; 0.1090)
C#	48390	(47980; 48800)	0.0938	(0.0930; 0.0946)
E	42002	(41617; 42387)	0.0814	(0.0806; 0.0821)
B	40356	(39978; 40734)	0.0782	(0.0775; 0.0789)
F	40000	(39624; 40376)	0.0775	(0.0768; 0.0782)
F#	33015	(32670; 33360)	0.0640	(0.0633; 0.0646)
A#	32099	(31759; 32439)	0.0622	(0.0615; 0.0629)
G#	31611	(31273; 31949)	0.0612	(0.0606; 0.0619)
D#	15789	(15547; 16031)	0.0306	(0.0301; 0.0311)

Найчастіші тональності це G, C, D та A. Різниці між частками невеликі, але через великий розмір вибірки інтервали дуже вузькі.

14) ДІ для кількості за роками (Топ-10 наймасовіших)

Рік	К-сть	95% СІ к-сті	Частка	95% СІ частки
2019	26082	(25774; 26390)	0.0505	(0.0499; 0.0511)
2018	25739	(25432; 26046)	0.0499	(0.0493; 0.0505)
2017	23541	(23247; 23835)	0.0456	(0.0450; 0.0462)
2020	22957	(22667; 23247)	0.0445	(0.0439; 0.0450)
2014	20254	(19981; 20527)	0.0392	(0.0387; 0.0398)
2015	20039	(19767; 20311)	0.0388	(0.0383; 0.0394)
2013	19645	(19376; 19914)	0.0381	(0.0375; 0.0386)
2012	19356	(19088; 19624)	0.0375	(0.0370; 0.0380)

2016	19068	(18802; 19334)	0.0369	(0.0364; 0.0375)
2006	17367	(17113; 17621)	0.0336	(0.0332; 0.0341)

Найбільш представлені роки припадають на 2010-ті та 2020 рік, що відображає сильне зміщення стрімінгового каталогу до сучасніших релізів.

15) Частка треків з popularity == 0

Статистика	Оцінка	95% CI
Частка треків з popularity = 0	0.2581	[0.2569; 0.2593]

Понад чверть усього світового музичного каталогу в стрімінгах залишається повністю незатребуваною.

16) Довірчі інтервали для середніх значень змінних

Метрика	Середнє	95% CI
tempo	123	[122.782; 122.943]
duration_ms	237841	[237576.843; 238104.662]

total_artist_followers	2266524	[2243718.987; 2289329.493]
avg_artist_popularity	47.4	[47.314; 47.418]
danceability	0.525	[0.525; 0.526]
energy	0.672	[0.671; 0.672]
loudness	-7.90	[-7.914; -7.893]

Для глобальних середніх невизначеність мінімальна через велику вибірку ($n = 516\,129$). Тому важливішою стає не статистична, а практична інтерпретація величини ефектів.

17) Частки типів успішних альбомів

album_type	n	p_hat	CI
Bestseller	182	0.303	[0.267; 0.340]
Middle	323	0.538	[0.498; 0.578]
One-hit	95	0.158	[0.129; 0.188]

18) Бутстреп ДІ для загальних медіан

Metric	Median	CI
tempo	122	[121.609; 121.928]
duration_ms	223187	[222960.000; 223413.000]
total_artist_followers	247731	[245577.000; 249778.000]

avg_artist_popularity	48	[48.000; 48.000]
danceability	0.528	[0.527; 0.528]
energy	0.717	[0.716; 0.718]
loudness	-7.06	[-7.069; -7.046]

19) Бутстреп ДІ для Коефіцієнта Асиметрії (Skewness)

Метрика	Skewness	Напрямок	95% bootstrap CI
tempo	0.359	Правостороння (>0)	[0.3546; 0.3638]
valence	0.198	Правостороння (>0)	[0.1947; 0.2021]
speechiness	3.53	Правостороння (>0)	[3.4931; 3.5752]
energy	-0.598	Лівостороння (<0)	[-0.6026; -0.5938]
loudness	-1.22	Лівостороння (<0)	[-1.2355; -1.2045]
danceability	-0.0727	Лівостороння (<0)	[-0.0766; -0.0680]
acousticness	1.08	Правостороння (>0)	[1.0787; 1.0900]

instrumentalness	2.29	Правостороння (>0)	[2.2773; 2.2998]
liveness	1.97	Правостороння (>0)	[1.9631; 1.9779]

Отримані значення асиметрії показують, що значна частина аудіо-ознак має суттєво ненормальний розподіл. Це додатково обґрунтовує використання бутстреп-підходів та непараметричних методів у роботі, оскільки класичні нормальні припущення для таких змінних можуть давати некоректні оцінки невизначеності.

Гіпотези

1) *Clean* пісні популярніші за *Explicit* пісні?

В минулій лабораторній роботі ми визначили те, що для всіх жанрів пісні, які містять explicit-content, мають більше значення медіани. Тепер ми хочемо перевірити чи справді explicit пісні є більш популярними для всіх жанрів.

Для цього висунемо нульову гіпотезу $H_0: M_{Explicit} - M_{Clean} \leq 0$ та альтернативну гіпотезу $H_1: M_{Explicit} - M_{Clean} > 0$.

genre	diff_median	W_stat	p_value	p_adj_BH	reject_H0
Rock	1	44.7	0.00e+00	0.00e+00	TRUE
R&B	9	15.8	1.58e-56	7.89e-56	TRUE

Hip-Hop	6	10.7	5.38e-27	1.79e-26	TRUE
Pop	5	6.83	4.26e-12	1.06e-11	TRUE
Country	5	6.21	2.64e-10	5.28e-10	TRUE
Classical	5	5.05	2.18e-07	3.63e-07	TRUE
Folk	3	4.6	2.11e-06	3.02e-06	TRUE
Electronic	2	3.95	3.87e-05	4.84e-05	TRUE
Jazz	3	2.05	2.00e-02	2.22e-02	TRUE
Blues	1	0.845	1.99e-01	1.99e-01	FALSE

Як можна побачити, нульова гіпотеза відкидається для всіх жанрів, окрім Blues. Проте для жанру Rock значення p дорівнює 0. Це пов'язано з тим, що в датасеті шкала популярності є дискретною, і приблизно третя пісень належать до жанру Rock, тому під час розрахунків бутстреп-симуляцій медіана не змінювалась, що призвело до того, що значення стандартної похибки медіани близьке до нуля. Через це значення W стає неймовірно великим і значення p дорівнює 0, тому доцільно також провести аналіз для середніх значень популярності.

Також варто звернути увагу на те, що хоч ми і відкидаємо нульову гіпотезу для жанру Jazz, значення p не таке вже і мале.

genre	diff_mean	W_stat	p_value	p_adj_BH	reject_H0
Hip-Hop	4.82	20.5	8.01e-94 a	8.01e-93	TRUE
R&B	6.36	18.2	5.58e-74 a	2.79e-73	TRUE
Country	2.56	8.26	7.32e-17 a	2.44e-16	TRUE
Pop	1.62	6.37	9.41e-11 a	2.35e-10	TRUE
Classical	3.83	6.18	3.21e-10 a	6.41e-10	TRUE
Electronic	1.05	4.98	3.13e-07 a	5.21e-07	TRUE
Rock	0.342	3.41	3.28e-04 a	4.69e-04	TRUE
Folk	0.470	2.17	1.49e-02 a	1.86e-02	TRUE
Jazz	0.789	0.864	1.94e-01 a	2.15e-01	FALSE
Blues	-0.0969	-0.166	5.66e-01 a	5.66e-01	FALSE

Тепер для середніх значень ми не можемо відкинути нульову гіпотезу для жанрів Jazz і Blues. Статистика Волда для жанру Rock має адекватне значення, і можна побачити, що для цього жанру ми також відкидаємо нульову гіпотезу.

Отже, можна прийти до висновків, що нульова гіпотеза не підтверджується для жанрів Jazz та Blues. Також варто звернути увагу на те, що для жанрів Rock, Folk, Electronic, нульова гіпотеза виконується, проте різниця медіан(≤ 3) і середніх значень(≤ 1.05) не є такою суттєвою і значущі різниці є лише для жанрів R&B, Hip-Hop, Pop, Country, Classical.

2) Гіпотези, пов'язані з аудіо-профілями

H1: пара Rock/Jazz контрастніша за Jazz/Electronic

Контрастність двох жанрових пар за аудіо-профілями.

$H_0: d(\text{Rock, Jazz}) - d(\text{Jazz, Electronic}) \leq 0.$

$H_1: d(\text{Rock, Jazz}) - d(\text{Jazz, Electronic}) > 0.$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.427	0.025	[0.378; 0.475]	[0.381; 0.473]	[0.352; 0.485]	[0.381; 0.474]	17.202	< 1e-15	H_0 відхилено

Статистичний тест відхиляє H_0 : дані підтримують висновок, що пара Rock/Jazz має більшу відстань за audio-профілями, ніж Jazz/Electronic. Усі розраховані довірчі інтервали лежать у додатній зоні, тому цей результат є статистично стійким.

H2: для Rock/Jazz топ-треки жанрово ближчі, ніж нижні децилі

Чи зближуються Rock і Jazz серед найпопулярніших треків.

$H_0: distance_{top} - distance_{bottom} \geq 0.$

$H_1: distance_{top} - distance_{bottom} < 0.$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
-0.866	0.124	[-0.987; -0.499]	[-0.981; -0.487]	[-0.953; -0.542]	[-1.246; -0.751]	-6.962	2.10e-12	H_0 відхилено

H0 відхиляється ($p = 2.10e-12$), а від'ємна оцінка (-0.866) означає, що для Rock/Jazz відстань у топ-децилі менша, ніж у нижніх децилях. Дані підтримують висновок про жанрове зближення цієї пари серед найпопулярніших треків.

H3: для Jazz/Electronic топ-треки жанрово ближчі, ніж нижні децилі

Чи зближуються Jazz і Electronic серед найпопулярніших треків.

H0: $distance_{top} - distance_{bottom} \geq 0$.

H1: $distance_{top} - distance_{bottom} < 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.328	0.193	[0.007; 0.762]	[0.025; 0.737]	[0.142; 0.543]	[-0.081; 0.631]	1.704	0.9558	H0 не відхилено

Скориговане р-значення (0.9558) перевищує рівень значущості, тому H0 не відхиляється. У цьому тесті дані не дають підстав стверджувати, що Jazz та Electronic зближуються серед найпопулярніших треків. Додатна точкова оцінка (0.328) радше вказує, що очікуваний напрямок не спостерігається, але робити сильний висновок про віддалення за цією перевіркою не потрібно.

H4: середня міжжанрова відстань у нижніх децилях додатна

Наявність ненульової середньої міжжанрової відстані в нижніх децилях.

H0: $D_{low} \leq 0$.

H1: $D_{low} > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення

4.046	0.030	[3.998; 4.116]	[3.992; 4.111]	[3.996; 4.118]	[3.981; 4.100]	134.506	< 1e- 15	H0 відхилено
-------	-------	-------------------	-------------------	-------------------	-------------------	---------	----------------	-----------------

H0 відхиляється: середня міжжанрова відстань у нижніх децилях є додатною. Bootstrap-інтервали вузькі, тому оцінка D_{low} є стабільною; це свідчить про помітні акустичні відмінності між жанрами серед менш популярних треків.

H5: середня міжжанрова відстань у топ-децилі додатна

Наявність ненульової середньої міжжанрової відстані в топ-децилі.

H0: $D_{top} \leq 0$.

H1: $D_{top} > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішення
3.239	0.035	[3.169; 3.306]	[3.169; 3.324]	[3.173; 3.298]	[3.153; 3.308]	92.597	< 1e- 15	H0 відхилено

H0 відхиляється: міжжанрова відстань у топ-децилі popularity також додатна. Це означає, що навіть серед найпопулярніших треків жанрові профілі не зливаються повністю, хоча D_{top} менша за D_{low} .

H6: нижні децилі мають більшу міжжанрову відстань, ніж топ-дециль popularity

Гіпотеза акустичної гомогенізації популярних треків.

$$H_0: D_{low} - D_{top} \leq 0.$$

$$H_1: D_{low} - D_{top} > 0.$$

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішення
0.807	0.048	[0.716; 0.903]	[0.717; 0.903]	[0.703; 0.918]	[0.712; 0.898]	16.931	< 1e-15	H0 відхилено

H0 відхиляється: $D_{low} - D_{top} = 0.807$, тобто середня міжжанрова відстань у нижніх децилях більша, ніж у топ-децилі. Це статистично підтримує гіпотезу акустичної гомогенізації популярних треків у межах цього датасету, але не встановлює причинного механізму цього явища.

Загальний висновок: У пункті 2 перевірили, чи є популярні треки акустично більш схожими між жанрами, ніж менш популярні. Основний результат є стійким: $D_{low} - D_{top} = 0.807$, а percentile CI [0.712;0.898] повністю розташований вище нуля. Це означає, що у верхньому децилі popularity жанрові профілі зближуються. Перевірка для пари Rock/Jazz також підтверджує, що топ-треки є ближчими між собою, ніж треки нижнього дециля. Водночас для пари Jazz/Electronic зменшення відстані не підтверджується, тому гомогенізація не є однаково сильною для всіх жанрових пар. Додатні значення D_{low} і D_{top} показують, що жанрові профілі залишаються різними в обох частинах розподілу popularity, однак серед найпопулярніших треків ця різниця є меншою.

3) Кореляції аудіо-характеристик

H1: energy додатно пов'язана з loudness

Напрямок зв'язку між energy та loudness.

H0: $\rho(\text{energy}, \text{loudness}) \leq 0$.

H1: $\rho(\text{energy}, \text{loudness}) > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
0.759	0.001	[0.758; 0.760]	[0.758; 0.760]	[0.757; 0.761]	[0.758; 0.760]	1113.296	< 1e-15	H0 відхилено

H0 відхиляється: між energy та loudness є сильний додатний ранговий зв'язок ($\rho = 0.759$).

H2: energy від'ємно пов'язана з acousticness

Напрямок зв'язку між energy та acousticness.

H0: $\rho(\text{energy}, \text{acousticness}) \geq 0$.

H1: $\rho(\text{energy}, \text{acousticness}) < 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
-0.745	0.001	[-0.747; -0.744]	[-0.747; -0.744]	[-0.747; -0.744]	[-0.747; -0.744]	-979.379	< 1e-15	H0 відхилено

H0 відхиляється: між energy та acousticness є сильний від'ємний ранговий зв'язок ($\rho = -0.745$). Bootstrap-інтервали дуже вузькі, тому результат статистично стійкий.


H3: audio-features не мають зв'язку з popularity

Чи аудіо-характеристики треків корелюють з популярністю?

H0: ρ (feature, popularity) = 0.

H1: ρ (feature, popularity) $\neq$ 0.

Feature	Spearman ρ	Percentile 95% CI	SE boot	BH p-value	Decision	Direction
danceability	0.1089	[0.1064; 0.1119]	0.00142	< 1e-15	H0 відхиляється	додатна
instrumentalness	-0.1086	[-0.1110; -0.1057]	0.00138	< 1e-15	H0 відхиляється	від'ємна
liveness	-0.0389	[-0.0416; -0.0359]	0.00146	< 1e-15	H0 відхиляється	від'ємна
valence	0.0381	[0.0355; 0.0405]	0.00129	< 1e-15	H0 відхиляється	додатна
loudness	0.0324	[0.0301; 0.0354]	0.00132	< 1e-15	H0 відхиляється	додатна
energy	-0.0281	[-0.0306; -0.0251]	0.00137	< 1e-15	H0 відхиляється	від'ємна
acousticness	0.0268	[0.0239; 0.0298]	0.00146	< 1e-15	H0 відхиляється	додатна
speechiness	0.0103	[0.0078; 0.0130]	0.00143	6.300e-13	H0 відхиляється	додатна
tempo	-0.0089	[-0.0121; -0.0068]	0.00134	2.457e-11	H0 відхиляється	від'ємна



Популярність має статистично значущі, але слабкі зв'язки з аудіо-характеристиками. Найпомітніші за модулем зв'язки: danceability та instrumentalness. Але цікаво, чи в якомусь певному жанрі є сильний зв'язок цих характеристик з popularity?

H4: жанрово-агреговані audio-features не мають сильного зв'язку з popularity

Чи всі жанрово-агреговані audio-feature зв'язки з popularity є слабкими?

H0: $\max |\rho(\text{feature}, \text{popularity} | \text{genre})| \geq 0.20$.

H1: $\max |\rho(\text{feature}, \text{popularity} | \text{genre})| < 0.20$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	BH p	Рішення
--------	----	-----------	----------	----------------	---------------	---	------	---------

0.162	0.009	[0.145; 0.181]	[0.145 ; 0.182]	[0.146; 0.182]	[0.143; 0.180]	-4.065	2.52e -05	H0 відхилен о
-------	-------	-------------------	--------------------	-------------------	-------------------	--------	--------------	---------------------

H0 відхиляється: навіть найбільший модульний зв'язок дорівнює 0.162, тобто нижчий за поріг 0.20. Отримані довірчі інтервали лежать нижче цього порогу, тому дані підтримують висновок, що окремі audio-features самі по собі не мають сильного прямого зв'язку з popularity.

Загальний висновок: Пункт 3 фокусується на зв'язках між аудіо-характеристиками. Energy майже лінійно узгоджується з loudness у ранговому сенсі: $\rho = 0.759$, а всі інтервали практично збігаються. Водночас energy має сильний від'ємний зв'язок з acousticness: $\rho = -0.745$. Окрема перевірка $\max |\rho| < 0.20$ показує, що жанрові audio-features самі по собі не дають сильного прямого зв'язку з popularity.

4) Fan-base і популярність

H1: у малих артистів followers додатно пов'язані з popularity

Зв'язок followers і popularity для артистів < 1 млн followers.

H0: $\rho_{\text{small}} \leq 0$.

H1: $\rho_{\text{small}} > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішен ня
--------	----	--------------	-------------	-------------------	------------------	---	------	-------------

0.231	0.002	[0.228; 0.234]	[0.228; 0.234]	[0.227; 0.235]	[0.228; 0.235]	144.51 0	< 1e- 15	H0 відхил ено
-------	-------	-------------------	-------------------	-------------------	-------------------	-------------	-------------	---------------------

H0 відхиляється: у малих артистів followers додатно пов'язані з popularity ($\rho = 0.231$). Вузькі довірчі інтервали свідчать про точну оцінку зв'язку, але це не встановлює, що приріст аудиторії причинно підвищує popularity кожного треку.

H2: у великих артистів followers додатно пов'язані з popularity

Зв'язок log-followers і popularity для артистів > 10 млн followers.

H0: $\rho_{big} \leq 0$.

H1: $\rho_{big} > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішенн я
0.187	0.006	[0.175; 0.199]	[0.172; 0.198]	[0.167; 0.202]	[0.176; 0.202]	30.012	< 1e- 15	H0 відхиле но

H0 відхиляється: для великих артистів (>10 млн followers) зв'язок між log-followers та popularity також додатний ($\rho = 0.187$). Менша точкова оцінка порівняно з малими артистами узгоджується з ідеєю слабшої асоціації у групі мегазірок, але не встановлює причинний ефект додаткових підписників.

Н3: різниця кореляцій між <1 млн і >10 млн followers додатна

Основна перевірка: порівнюються саме < 1 млн і > 10 млн followers.

H0: $\rho(\text{followers}, \text{popularity}(<1\text{M})) - \rho(\text{followers}, \text{popularity}(>10\text{M})) \leq 0$.

H1: $\rho(\text{followers}, \text{popularity}(<1\text{M})) - \rho(\text{followers}, \text{popularity}(>10\text{M})) > 0$.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішення
0.044	0.007	[0.031; 0.057]	[0.032; 0.056]	[0.031; 0.056]	[0.032; 0.056]	6.608	2.29e-11	H0 відхилено

H0 відхиляється: різниця кореляцій додатна, а всі наведені СІ лежать вище нуля. Отже, зв'язок followers з popularity статистично сильніший для малих артистів, ніж для великих. Водночас ефект практично невеликий: $\rho_{\text{small}} - \rho_{\text{big}} = 0.044$, тому його треба інтерпретувати обережно.

Н4: серед мегазірок частка треків з popularity = 0 перевищує 5%

Частка треків із popularity = 0 серед мегазірок.

H0: $p_{\text{zero}} \leq 0.05$.

H1: $p_{\text{zero}} > 0.05$.

Оцінка	SE	Normal CI	W	ВН р	Рішення
0.143	0.010	[0.122; 0.163]	8.954	< 1e-15	H0 відхилено

H0 відхиляється, оскільки частка композицій із нульовою popularity серед мегазірок становить 14.3%. Довірчий інтервал [0.122; 0.163] повністю перебуває

вище порогу 5%, що свідчить про наявність довгого хвоста непопулярних треків навіть у дуже відомих виконавців.

Загальний висновок: Пункт 4 порівнює малих артистів (<1 млн followers) і мегазірок (>10 млн followers). Зв'язок із popularity додатний в обох групах, але для малих артистів він сильніший: різниця кореляцій 0.044 має percentile CI [0.032; 0.056]. Практично це невеликий, але стабільний ефект. Додатково частка popularity = 0 серед мегазірок становить 0.143 і значуще перевищує 5%, тобто навіть дуже відомі артисти мають великий хвіст непопулярних треків.

5) Еволюція *acousticness* та *energy*

H1: старі треки мають вищу медіанну *acousticness*, ніж сучасні

Різниця *acousticness* між старими й сучасними треками. Старі треки визначено як year < 1980, сучасні - як year ≥ 2000.

H0: median_old_acousticness - median_modern_acousticness ≤ 0.

H1: median_old_acousticness - median_modern_acousticness > 0.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішення
0.495	0.004	[0.489; 0.503]	[0.489; 0.502]	[0.484; 0.505]	[0.488; 0.501]	138.729	< 1e-15	H0 відхилено

H0 відхиляється: старі треки (до 1980 року) мають вищу медіанну *acousticness*, ніж сучасні (з 2000 року). Різниця 0.495 та вузькі довірчі інтервали свідчать про статистично стійку відмінність у межах датасету.

H2: сучасні треки мають вищу медіанну energy, ніж старі

Різниця energy між сучасними й старими треками.

H0: median_modern_energy - median_old_energy $\leq$ 0.

H1: median_modern_energy - median_old_energy $>$ 0.

Оцінка	SE	Normal CI	Basic CI	Studentized CI	Percentile CI	W	ВН р	Рішення
0.283	0.002	[0.279; 0.287]	[0.278; 0.287]	[0.279; 0.288]	[0.279; 0.288]	127.22 9	< 1e- 15	H0 відхилено

H0 відхиляється: сучасні треки мають вищу медіанну energy, ніж старі релізи (різниця 0.283). Вузькі bootstrap-інтервали показують статистичну стійкість результату, але не є математичним доказом глобального причинного тренду.

Загальний висновок: Пункт 5 порівнює старі та сучасні треки за acousticness і energy. Поділ такий: старі треки це релізи до 1980 року, сучасні це релізи з 2000 року і пізніше; проміжні 1980-1999 роки не входять у ці дві контрастні групи, щоб порівняння було чистішим. Старі треки мають значно вищу медіанну acousticness: різниця 0.495 з percentile CI [0.488; 0.501]. Сучасні треки мають вищу медіанну energy: різниця 0.283 з percentile CI [0.279; 0.288]. Обидва висновки дуже далекі від нуля, тому історичний зсув до менш акустичного і більш енергійного звучання підтверджується.

6) Чи explicit-контент підвищує ймовірність супер-хіта?

Супер-хіт у цьому тесті визначено як $\text{popularity} \geq 75$.

$H_0: p_{\text{hit}}(\text{Explicit}) - p_{\text{hit}}(\text{Clean}) \leq 0$.

$H_1: p_{\text{hit}}(\text{Explicit}) - p_{\text{hit}}(\text{Clean}) > 0$.

Статистика	Оцінка	95% CI	W	p-value	Рішення
$p_{\text{explicit}} - p_{\text{clean}}$	0.0018	[0.0013; 0.0022]	8.24	2.22e-16	H_0 відхилено

Ефект статистично значущий, але практично малий: ймовірність супер-хіта зростає лише приблизно на 0.18 відсоткового пункту. Це типовий приклад ситуації, де великий n робить навіть малий ефект статистично значущим.

7) Чи *explicit*-треки популярніші за *clean* всередині *Hip-Hop*?

$H_0: \text{median_pop}(\text{Explicit}, \text{Hip-Hop}) - \text{median_pop}(\text{Clean}, \text{Hip-Hop}) \leq 0$

$H_1: \text{median_pop}(\text{Explicit}, \text{Hip-Hop}) - \text{median_pop}(\text{Clean}, \text{Hip-Hop}) > 0$.

Статистика	Оцінка	95% percentile CI	SE boot	W	p-value	Рішення

Δ median	6.00	[6.00; 8.00]	0.5544	10.82	≈ 0	H0 відхилено
-----------------	------	-----------------	--------	-------	-------------	-----------------

Навіть у межах одного жанру explicit має стійку перевагу popularity. Це важливо, бо частково знімає пояснення, що глобальна explicit-різниця виникає тільки через змішування жанрів.

8) Чи відрізняється пік розподілу valence між Minor і Major?

H0: mode_valence(Minor) - mode_valence(Major) = 0.

H1: mode_valence(Minor) - mode_valence(Major) $\neq$ 0.

Статистика	Оцінка	95% percentile CI	Рішення
mode_valence(Minor) - mode_valence(Major)	-0.0045	[-0.0276; 0.0173]	H0 не відхилено

Інтервал містить нуль, тому переконливої різниці піків valence між Minor і Major немає. Це руйнує стереотип про те, що музика у мінорі сумна, а у мажорі навпаки – весела.

Висновки

У лабораторній роботі було проведено статистичне виведення для великого музичного датасету обсягом понад 516 тисяч треків. На відміну від попередньої лабораторної роботи, де основний акцент робився на exploratory data analysis, у цій роботі отримані закономірності були формалізовані як статистичні гіпотези та перевірені за допомогою Wald-тестів, довірчих інтервалів і bootstrap-методів.

Результати показали, що explicit-контент у більшості жанрів асоціюється з вищою popularity, однак сила цього ефекту суттєво відрізняється між жанрами. Найбільш виражений ефект спостерігається для Hip-Hop та R&B, тоді як для Jazz і Blues статистично значущої різниці підтвердити не вдалося.

Окремий блок дослідження був присвячений аналізу жанрових audio-профілів. Було статистично підтверджено, що серед найпопулярніших треків жанрові профілі стають ближчими між собою, тобто спостерігається ефект акустичної гомогенізації. Водночас жанрові відмінності не зникають повністю навіть у топ-децилі popularity.

Кореляційний аналіз показав сильний додатний зв'язок між energy та loudness, а також сильний від'ємний зв'язок між energy та acousticness. При цьому жодна окрема audio-feature не демонструє сильного прямого зв'язку з popularity, що свідчить про багатofакторну природу музичної популярності.

Дослідження fan-base артистів показало, що кількість followers додатно пов'язана з popularity як для малих артистів, так і для мегазірок. Проте для артистів із меншою аудиторією цей зв'язок є статистично сильнішим. Також було встановлено, що навіть серед мегазірок існує значна частка треків із popularity = 0, що вказує на наявність довгого хвоста малопомітних композицій навіть у дуже успішних виконавців.

Практично для всіх великих підвибірок довірчі інтервали виявилися вузькими, що свідчить про високу статистичну точність оцінок. Водночас результати потрібно інтерпретувати обережно: статистична значущість не означає причинного зв'язку, а великий обсяг вибірки дозволяє виявляти навіть дуже слабкі ефекти.

Окремий блок дослідження був присвячений аналізу жанрових audio-профілів. Було статистично підтверджено, що серед найпопулярніших треків жанрові профілі в середньому стають ближчими між собою, тобто спостерігається ефект акустичної гомогенізації. Водночас цей ефект не є універсальним для всіх жанрових пар: для окремих порівнянь зменшення міжжанрової відстані не підтвердилося статистично, тому відповідну нульову гіпотезу не було відхилено.

Загалом робота демонструє, що статистичне виведення дозволяє не лише описувати закономірності в музичних даних, а й оцінювати їхню надійність, стійкість та узгодженість із дослідницькими гіпотезами.

Використані джерела:

1. Тавров Д. Ю. Аналіз даних: Лекція2. Оцінки та асимптотика
2. Тавров Д. Ю. Аналіз даних: Лекція3. Довірчі інтервали та тестування гіпотез
3. Тавров Д. Ю. Аналіз даних: Лекція4. Бутстреп
4. Сивоконь В., Сусяк В., Ткаченко Є. Лабораторна робота 1: EDA