

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Факультет програмних систем та прикладної математики
Кафедра прикладної математики

ЗВІТ
з лабораторної роботи №3
на тему: «Регресійний аналіз»

Виконали: студенти групи КМ-
33, команда №4
Сивоконь В. В., Сусяк В. Р.,
Ткаченко Є. В.

Зміст

ВСТУП	2
ДАНІ ТА ПІДГОТОВКА ДО РЕГРЕСІЙНОГО АНАЛІЗУ	3
ЧАСТИНА 1. Аналіз тривалості пісень (duration_ms)	4
ЧАСТИНА 2. Аналіз танцювальності пісень (danceability)	16
ЧАСТИНА 3. Аналіз нецензурної лексики (explicit)	28
ЧАСТИНА 4. Аналіз популярності	40
ЗАГАЛЬНІ ВИСНОВКИ	58
ДЖЕРЕЛА	61

ВСТУП

У Лабораторній роботі 2 було застосовано методи статистичного виведення для перевірки гіпотез щодо однієї або двох змінних. Метою поточної Лабораторної роботи 3 є перехід до багатовимірного аналізу. За допомогою регресійних моделей (OLS, Logit, Probit) ми досліджуємо причинно-наслідкові зв'язки між характеристиками треків, контролюючи вплив інших факторів (ceteris

paribus). Основний фокус зосереджено на трьох ключових залежних змінних: тривалості пісні (duration_ms), танцювальності (danceability) та наявності нецензурної лексики (explicit).

ДАНИ ТА ПІДГОТОВКА ДО РЕГРЕСІЙНОГО АНАЛІЗУ

У роботі використано очищений датасет Spotify Songs, який застосовувався у попередніх лабораторних роботах. Початковий робочий набір містить 516 129 спостережень і 23 змінні; після підготовки регресійної вибірки залишилося 516 123 спостереження. У даних представлено 10 жанрів, 13 десятиліть випуску та 43 531 кластер артистів, що є важливим для коректного розрахунку стандартних похибок у моделі популярності.

Ключові змінні дослідження: duration_ms та його логарифм для аналізу тривалості; danceability як неперервна метрика танцювальності; explicit_num як бінарна ознака наявності explicit-контенту; popularity як індекс популярності треку; total_artist_followers та $\log(1 + \text{total_artist_followers})$ як характеристика fan-base артиста. Для моделей також використано аудіо-характеристики tempo, energy, valence, acousticness, instrumentalness, speechiness та інші доступні контролі.

Категорійні змінні genre та decade включалися до регресій як набори фіктивних змінних із базовими категоріями. Для змінних із сильно скошеним розподілом використовувалося логарифмування; для перевірки нелінійності додавалися квадрати відповідних регресорів, а для зменшення технічної мультиколінеарності окремі змінні центрувалися. У всіх частинах гомоскедастичні стандартні похибки не використовувалися: для OLS застосовувалися робастні або кластеризовані похибки, для Logit/Probit - робастні матриці коваріацій.

Діапазони ключових змінних після очищення відповідають змісту даних: popularity = [0; 98], year = [1900; 2025], duration_ms = [15027; 4995315],

`total_artist_followers` = [0; 295181876]. Така підготовка дозволяє перейти від описових висновків ЛР1-ЛР2 до багатофакторної регресії, де кожний ефект інтерпретується за інших рівних умов.

ЧАСТИНА 1. Аналіз тривалості пісень (`duration_ms`)

Дослідницьке питання

Головною метою цього регресійного аналізу є встановлення причинно-наслідкового зв'язку між роком випуску, музичним жанром, акустичними характеристиками (зокрема темпом) та тривалістю пісні. Дослідницьке питання звучить так: Як історична епоха, музичний жанр та темп впливають на тривалість треку за інших рівних умов?

Гіпотези дослідження

- З розвитком платформ на кшталт Spotify (особливо після 2010-х років) тривалість пісень зменшується, оскільки артисти максимізують кількість прослуховувань для збільшення монетизації.
- Еволюція тривалості протягом століття не є лінійною. До 1990-х років пісні ставали довшими, а згодом тренд розвернувся на спад.
- Тренди на зміну тривалості суттєво відрізняються залежно від жанру (наприклад, що поп-музика скорочується швидше за консервативний джаз чи класику).

Базова модель

Найпростіша структурна специфікація мала вигляд: `log_duration ~ year + tempo + genre`.

Зміщення від неврахованих змінних (OVB)

Базова модель страждає від OVB, оскільки ігнорує акустичний профіль треку. Наприклад, енергійність (`energy`) та танцювальність (`danceability`) корелюють як із жанром, так і з тривалістю треку. Для мінімізації OVB у розширені моделі ці змінні було додано як контролі. Проте ідеально було б мати

дані про тип релізу (сингл/альбом) та вимоги лейблів, відсутність яких залишає ризик ендогенності.

Логарифмування та нелінійність

Як залежна змінна використовується логарифм тривалості ($\log_duration$). Це дозволяє стабілізувати дисперсію та перейти до лог-лінійної моделі, де зміна регресора впливає на відсоткову зміну тривалості. Для перевірки нелінійності було додано квадрати темпу $I(tempo^2)$ та відцентрованого року $I(year_centered^2)$.

Фактори взаємодії

Для перевірки неоднорідності еволюції музики додано взаємодію $year * genre$. Це дозволяє перевірити, чи, наприклад, електронна музика скорочується з часом швидше, ніж класична.

Фіктивні змінні

Категорійна змінна $genre$ була перетворена на набір індикаторних (бінарних) змінних. Для уникнення пастки повної мультиколінеарності (dummy variable trap) базову категорію було автоматично вилучено алгоритмом OLS.

Робастні стандартні похибки

Оскільки дані музичних стрімінгів є гетероскедастичними (дисперсія тривалості класичної музики набагато більша за поп-музику), використання класичних гомоскедастичних похибок є некоректним. Для всіх моделей застосовано робастні похибки Вайта (HC1).

F-тести та спільна значущість

Тести лінійних гіпотез показали, що групи змінних є високо значущими ($p\text{-value} \approx 0.000$). Зокрема, спільно значущими є жанри, взаємодії року з жанром, а також поліноми часу та темпу. Це доводить, що тривалість залежить від складної комбінації цих факторів.

Мультиколінеарність

Щоб уникнути жорсткої мультиколінеарності між year та year^2 , рік було центровано ($\text{year_centered} = \text{year} - 2000$).

Перевірка на стійкість

Для перевірки стійкості (robustness) оцінок було побудовано п'ять специфікацій моделі з поступовим ускладненням:

1. Базова модель: $\text{year} + \text{tempo} + \text{genre}$.
2. Модель з контролями: додано акустичні метрики (energy, danceability, acousticness, explicit) для зменшення OVB.
3. Модель із взаємодіями: додано фактори взаємодії $\text{year} * \text{genre}$ для перевірки неоднорідності еволюції музики в різних жанрах.
4. Поліноміальна модель: для перевірки нелінійності часу рік було центровано (year_centered), щоб уникнути мультиколінеарності, та додано його квадрат $I(\text{year_centered}^2)$.
5. Модель епохи стрімінгів (Sub-sampling): останню специфікацію оцінено на суб вибірці винятково сучасних треків (266 468 спостережень), щоб ізолювати ефект стрімінгових платформ від загальноісторичного тренду.

Висновки за частиною 1

Час

У минулому столітті тривалість пісень зростала (додатний лінійний коефіцієнт), проте додавання квадрата року виправляє помилку специфікації і показує параболічний тренд (гілками вниз). В епоху стрімінгів кожен наступний рік пов'язаний зі скороченням очікуваної тривалості приблизно на 0.4%.

Темп

Ефект темпу має форму параболи (додатний лінійний, від'ємний квадратичний коефіцієнт). Оптимальна тривалість досягається при ≈ 117 BPM. При збільшенні темпу з 80 до 90 BPM тривалість зростає на 2.05%, а з 120 до 130 BPM — дещо падає (-0.10%).

Змінна / Показник	Базова (1)	З контролями (2)	Взаємодії (3)	Параболи часу та темпу (4)	Сучасна епоха + Парабола темпу (5)
year	0.0004*** (0.00004)	0.0002*** (0.00004)	0.002*** (0.0001)		-0.004*** (0.001)
year_centered				0.0001 (0.0001)	
tempo	- 0.0001*** (0.00002)	-0.0003*** (0.00002)	- 0.0003*** (0.00002)	0.006*** (0.0001)	0.007*** (0.0002)
I(tempo2)				- 0.00002*** (0.00000)	- 0.00003*** (0.00000)
genreClassical	-0.132*** (0.005)	-0.126*** (0.004)	-2.751*** (0.515)	-0.149*** (0.005)	-0.068 (3.729)
genreCountry	-0.100*** (0.003)	-0.106*** (0.003)	-2.685*** (0.305)	-0.129*** (0.003)	5.891* (2.289)
genreElectronic	0.045*** (0.003)	0.018*** (0.003)	30.524*** (0.445)	0.164*** (0.004)	47.241*** (2.258)

genreFolk	-0.097*** (0.003)	-0.098*** (0.003)	3.791*** (0.347)	-0.101*** (0.003)	4.299 (2.371)
genreHip-Hop	-0.104*** (0.003)	-0.084*** (0.003)	29.498*** (0.478)	0.058*** (0.004)	52.072*** (2.421)
genreJazz	-0.047*** (0.004)	-0.023*** (0.004)	-1.795*** (0.328)	-0.008* (0.004)	6.854* (3.415)
genrePop	-0.072*** (0.003)	-0.092*** (0.003)	3.652*** (0.310)	-0.095*** (0.003)	2.330 (2.283)
genreR&B	0.025*** (0.003)	0.013*** (0.003)	9.369*** (0.409)	0.031*** (0.003)	25.938*** (2.529)
genreRock	-0.009*** (0.003)	-0.060*** (0.003)	1.071*** (0.294)	-0.078*** (0.003)	-8.674*** (2.220)
I(year_centered2)				-0.0001*** (0.00000)	
danceability		-0.166*** (0.004)	-0.175*** (0.004)	-0.221*** (0.004)	-0.294*** (0.005)
energy		-0.233*** (0.003)	-0.244*** (0.003)	-0.252*** (0.003)	-0.227*** (0.005)

acousticness		-0.297*** (0.003)	-0.288*** (0.003)	-0.277*** (0.003)	-0.244*** (0.004)
explicitExplicit		-0.059*** (0.002)	-0.059*** (0.002)	-0.056*** (0.002)	-0.056*** (0.002)
year:genreClassical			0.001*** (0.0003)		-0.00003 (0.002)
year:genreCountry			0.001*** (0.0002)		-0.003** (0.001)
year:genreElectronic			-0.015*** (0.0002)		-0.023*** (0.001)
year:genreFolk			-0.002*** (0.0002)		-0.002 (0.001)
year:genreHip-Hop			-0.015*** (0.0002)		-0.026*** (0.001)
year:genreJazz			0.001*** (0.0002)		-0.003* (0.002)
year:genrePop			-0.002*** (0.0002)		-0.001 (0.001)

year:genreR&B			-0.005*** (0.0002)		-0.013*** (0.001)
year:genreRock			-0.001*** (0.0001)		0.004*** (0.001)
year_centered:genreClassical				0.002*** (0.0003)	
year_centered:genreCountry				0.002*** (0.0002)	
year_centered:genreElectronic				-0.012*** (0.0002)	
year_centered:genreFolk				-0.001*** (0.0002)	
year_centered:genreHip-Hop				-0.012*** (0.0003)	
year_centered:genreJazz				0.0001 (0.0002)	
year_centered:genrePop				-0.001*** (0.0002)	

year_centered:genreR&B				-0.003*** (0.0002)	
year_centered:genreRock				0.001*** (0.0002)	
Constant	11.508*** (0.076)	12.238*** (0.075)	8.501*** (0.259)	12.396*** (0.009)	20.753*** (2.116)
Observations	512,156	512,156	512,156	512,156	266,468
R2	0.023	0.056	0.078	0.087	0.096
Adjusted R2	0.023	0.056	0.078	0.087	0.096

Оскільки в моделях використовуються категорійні змінні, поліноми та велика кількість факторів взаємодії, аналіз лише індивідуальних р-значень (t-тестів) є недостатнім. Для підтвердження статистичної значущості цих груп змінних було проведено низку спільних F-тестів з використанням робастної матриці коваріацій:

F-тест 1 (Спільна значущість жанрів): Перевіряв одночасну рівність нулю всіх індикаторів жанру в базовій Моделі 1. Тест ($F=1442.5$, $p<2.2e-16$) відкинув нульову гіпотезу, довівши, що жанрова приналежність має статистично значущий вплив на тривалість пісні.

F-тест 2 (Взаємодія year:genre на всій вибірці): Перевіряв Модель 3 і підтвердив спільну значущість факторів взаємодії між роком випуску та жанром ($F=1398.7$, $p<2.2e-16$). Це підтверджує, що тренд на скорочення чи подовження треків у часі не є універсальним, а статистично значущо відрізняється для різних музичних напрямків.

F-тест 3 (Нелінійність часу / Поліном року): Перевіряв одночасну значущість лінійного року та його квадрата у поліноміальній Моделі 4. Тест ($F=832.08$, $p<2.2e-16$) рішуче відкинув нульову гіпотезу, довівши, що вплив історичної епохи має нелінійний характер.

F-тест 4 (Нелінійність темпу / Поліном темпу): Перевіряв спільну значущість лінійного темпу (tempo) та його квадрата ($I(\text{tempo}^2)$) також у Моделі 4. Тест ($F=1292.4$, $p<2.2e-16$) підтвердив, що швидкість відтворення (BPM) впливає на структуру композиції нелінійно. Це доводить, що відсоткова зміна довжини треку при його пришвидшенні суттєво відрізняється залежно від того, чи є композиція спочатку повільною, чи вже екстремально швидкою.

Після підтвердження ключових структурних гіпотез за допомогою спільних F-тестів, перейдемо до детальної інтерпретації оцінених коефіцієнтів. Оскільки наша залежна змінна є логарифмованою ($\log_duration$), а такі неперервні регресори, як темп та рік випуску включені до моделі у вигляді поліномів другого ступеня, їхній маржинальний ефект не є сталим. Для розуміння реальної відсоткової зміни тривалості треку за інших рівних умов необхідно застосовувати нелінійні розрахунки для конкретних діапазонів.

Розпочнемо з аналізу впливу темпу композиції. Спираючись на результати Моделі 4, де коефіцієнт біля лінійного tempo дорівнює 0.006, а біля квадрата дорівнює -0.00002 , продемонструємо, як однакове пришвидшення треку на 10 ударів на хвилину дає різні результати для початково повільних та вже швидких пісень

Збільшення темпу з 80 до 90

$$0.006 * (90 - 80) - 0.00002 * (90^2 - 80^2) \approx 0.026$$
$$(e^{0.026} - 1) * 100 \approx 2.63$$

Збільшення темпу з 160 до 170

$$0.006 * (170 - 160) - 0.00002 * (170^2 - 160^2) \approx -0.006$$
$$(e^{-0.006} - 1) * 100 \approx 0.6\%$$

Тобто, при збільшенні темпу з 80 до 90 тривалість пісні збільшується на $\approx 2.6\%$, а ось при збільшенні темпу з 160 до 170 тривалість пісні зменшується на $\approx 0.6\%$

Аналогічний нелінійний підхід необхідно застосувати й для інтерпретації історичної еволюції тривалості пісень. Як було доведено раніше, використання простого лінійного тренду призводило до помилкової специфікації моделі. Введення полінома з центруванням року відносно 2000-го дозволило коректно змодельовати ефект перевернутої параболи. Щоб наочно продемонструвати зміну музичних трендів від епохи поступового зростання тривалості до сучасного стрімкого скорочення треків під впливом стрімінгових платформ розрахуємо відсоткову зміну середньої тривалості пісні при переході між різними десятиліттями:

Приклад для зміни тривалості при переході з 1980 року по 1990.

$$0.0001 * (-10 - (-20) - 0.0001 * (-10^2 - (-20^2))) \approx 0.031$$
$$(e^{0.031} - 1) * 100 \approx 3.15$$

Приклад для зміни тривалості при переході з 2000 року по 2010.

$$0.0001 * (10) - 0.0001 * (10^2) \approx -0.009$$
$$(e^{-0.009} - 1) * 100 \approx -0.9\%$$

Приклад для зміни тривалості при переході з 2010 року по 2020.

$$0.0001 * (20 - 10) - 0.0001 * (20^2 - 10^2) \approx -0.029$$
$$(e^{0.031} - 1) * 100 \approx -2.86\%$$

Отже, при переході з 1980 року по 1990 тривалість збільшується на $\approx 3\%$, при переході з 2000 року по 2010 тривалість зменшується на $\approx 1\%$, а при переході з 2010 року по 2020 тривалість зменшується на $\approx 3\%$.

Проте виявлений історичний тренд не є універсальним. Як засвідчив спільний F-тест 4, фактори взаємодії між центрованим роком та музичним жанром (year_centered:genre) є статистично значущими. Це означає, що еволюція тривалості кардинально відрізняється залежно від конкретного музичного напрямку. Щоб продемонструвати цю неоднорідність наочно, порівняємо зміну хронометражу для двох концептуально різних жанрів - стрімко прогресуючого комерційного хіп-хопу та консервативної класичної музики за один і той самий проміжок часу:

Порахуємо ефект для хіп-хопу при переході з 2000 до 2020 року

$$(0.0001 - 0.012) * 20 - (-0.0001) * 20^2 \approx -0.278$$
$$(e^{-0.278} - 1) * 100 \approx -24.27\%$$

Порахуємо ефект для класики при переході з 2000 до 2020 року

$$(0.0001 + 0.002) * 20 - (-0.0001) * 20^2 \approx 0.002$$
$$(e^{0.002} - 1) * 100 \approx 0.2\%$$

Ці розрахунки наочно демонструють особливість еволюції музичної індустрії, а саме що, вплив часу залежить від жанру. Тоді як сучасна комерційна музика (на прикладі хіп-хопу) стрімко адаптується до нових вимог стрімінгових платформ і алгоритмів, скорочуючи свої треки майже на чверть за 20 років, консервативні жанри на кшталт класичної музики залишаються практично незмінними у своєму хронометражі (зміна лише на 0.2%). Це підтверджує гіпотезу про жанрову неоднорідність еволюції тривалості треків в епоху цифровізації.

Окрім часу та базового музичного жанру, тривалість композиції тісно пов'язана з її внутрішньою звуковою структурою. Для мінімізації зміщення від неврахованих змінних OVB та отримання більш чистих оцінок еволюції часу, до моделі було включено низку акустичних метрик як контрольних змінних. Аналіз

їхніх маржинальних ефектів дозволяє зрозуміти, як саме динаміка, настрій та формат треку впливають на його хронометраж за інших рівних умов.

Вплив контрольних аудіо-характеристик:

Усі додані акустичні контролі мають статистично значущий від'ємний вплив на тривалість Acousticness має найбільш сильний від'ємний вплив. Зростання акустичності треку на 1 скорочує його на $\approx 24.2\%$, щодо інших змінних результати такі: energy скорочує на $\approx 22.3\%$ danceability на $\approx 19.8\%$, а наявність explicit-contenty на $\approx 5.4\%$

Окрім динаміки в часі та акустичних метрик, музичний жанр також визначає базову тривалість композиції. Оскільки змінна genre є категорійною, її коефіцієнти інтерпретуються як відсоткова різниця відносно базової категорії (базового жанру, вилученого алгоритмом). Звертаючись до результатів Моделі 4, важливо враховувати, що базові коефіцієнти жанрів показують відсоткову різницю саме для базового періоду, а саме 2000 року. Ми бачимо, що електронна музика має додатний коефіцієнт 0.164, тобто у 2000 році такі треки були в середньому на $\approx 17.8\%$ довші за базовий жанр за інших рівних умов. Також довшими були треки жанру Hip-Hop (коефіцієнт 0.058, тобто на $\approx 6\%$ довші). Натомість такі жанри як Classical (-0.149), Country (-0.129) та Pop (-0.095) були об'єктивно коротшими на $\approx 13.8\%$, $\approx 12.1\%$ та $\approx 9.1\%$ відповідно.

Оцінка якості підгонки моделей (Аналіз коефіцієнтів детермінації R^2)

Для оцінки загальної якості підгонки побудованих моделей та їхньої пояснювальної здатності звернемося до коефіцієнта детермінації та скоригованого коефіцієнта детермінації.

Як видно зі зведеної фінальної таблиці, пояснювальна здатність моделі стабільно зростала з кожним кроком ускладнення специфікації:

Базова Модель 1 (лише лінійний рік, темп і жанр) пояснює всього 2.3% дисперсії логарифма тривалості ($R^2 = 0.023$).

Додавання контрольних аудіо-характеристик у Моделі 2 збільшило цей показник більше ніж удвічі до 5.6% ($R^2 = 0.056$).

Включення складних факторів взаємодії між роком і жанром (Модель 3) та поліноміальних нелінійних ефектів часу і темпу (Модель 4) підняло якість підгонки до 7.8% та 8.7% відповідно.

Нарешті, Модель 5, оцінена на суб-вибірці сучасної музики (епоха стрімінгів), показала найвищий результат, пояснюючи 9.6% варіативності даних ($R^2 = 0.096$).

ЧАСТИНА 2. Аналіз танцювальності пісень (danceability)

Дослідницьке питання

Метою цієї частини дослідження є виявлення та квантифікація факторів, що впливають на танцювальність музичної композиції (danceability).

Танцювальність є ключовою метрикою для комерційного успіху в багатьох жанрах, тому важливо зрозуміти, як саме акустичні характеристики та історичні тренди формують цей показник.

Гіпотези дослідження

- Гіпотеза 1 (Нелінійність темпу): Зв'язок між темпом (BPM) і танцювальністю має форму параболи (існує "ідеальний" темп для танців, після перевищення якого танцювати стає складно).
- Гіпотеза 2 (Вплив настрою): Емоційна позитивність пісні (valence) має нелінійний додатний вплив на її танцювальний потенціал.
- Гіпотеза 3 (Жанрова специфіка): Жанри на кшталт Hip-Hop чи Electronic є фундаментально більш танцювальними, ніж Classical чи Rock.

Опис змінних, мультиколінеарність та OVB

Залежною змінною виступає danceability (неперервна шкала від 0 до 1). Оскільки змінна не логарифмована, ми маємо справу з моделлю рівня linear-linear, де коефіцієнти показують абсолютну зміну танцювальності.

Перевірка на мультиколінеарність (VIF): Під час побудови початкової моделі було виявлено високу колінеарність між енергійністю та гучністю показники GVIF перевищували допустимі норми (зокрема, для energy GVIF = 4.62). Для уникнення мультиколінеарності змінну loudness було вилучено з фінальних специфікацій. Після цього тест VIF показав відсутність проблем (усі GVIF < 3).

OVB (Зміщення від неврахованих змінних): До моделі додано значний масив контрольних змінних (energy, instrumentality, valence, year, genre, speechiness, acousticness), що суттєво мінімізує OVB. Проте ризик зміщення залишається, оскільки модель не враховує складність ритмічного малюнку чи специфіку цільової аудиторії артиста.

Для перевірки стійкості оцінених параметрів та детального аналізу впливу різних факторів на танцювальність композицій було побудовано п'ять специфікацій моделі з поступовим ускладненням. Оскільки залежна змінна не логарифмована (знаходиться в межах від 0 до 1), усі специфікації формують модель рівня-рівня (linear-linear), де оцінені коефіцієнти відображають абсолютну зміну показника танцювальності.

1. Модель 1 (Базова): Включає лише базовий набір фундаментальних акустичних характеристик: швидкість відтворення, загальну енергійність, інструментальність та емоційну позитивність / настрій треку (valence).
2. Модель 2 (3 контролюми): Для мінімізації зміщення від неврахованих змінних (OVB) та отримання більш чистих оцінок, до базової специфікації додано ширший масив контрольних змінних.

Зокрема, додано гучність, акустичність, наявність розмовного тексту, а також рік випуску та базовий музичний жанр.

3. Модель 3 (Поліноміальна з нелінійними ефектами): Специфікація, що враховує складну нелінійну природу сприйняття музики. Для перевірки гіпотези про існування ідеального танцювального темпу додано квадрат темпу ($I(\text{tempo}^2)$). Аналогічно, для моделювання нелінійного впливу настрою на танцювальний потенціал пісні додано квадрат валентності ($I(\text{valence}^2)$).

4. Модель 4 (Із взаємодіями): Ускладнена специфікація, до якої включено фактори взаємодії між емоційною позитивністю та музичним жанром ($\text{valence} * \text{genre}$). Це дозволяє перевірити структурну гіпотезу про те, що вплив веселого настрою на танцювальність не є універсальним, а суттєво відрізняється залежно від конкретного музичного напрямку.

5. Модель 5 (Фінальна специфікація без мультиколінеарності): Як було виявлено на попередніх етапах аналізу та підтверджено тестом VIF, між енергійністю та гучністю існує сильна мультиколінеарність, яка здатна викривлювати стандартні похибки та результати t-тестів. Для вирішення цієї проблеми та ізоляції чистого маржинального ефекту енергійності, з фінальної специфікації було вилучено змінну loudness.

Базова модель

Початкова специфікація оцінювала вплив базового аудіо-профілю: $\text{danceability} \sim \text{tempo} + \text{energy} + \text{instrumentalness} + \text{valence}$.

Зміщення від неврахованих змінних (OVB)

Без урахування жанру ми можемо помилково приписати ефект стилю до ефекту енергійності. Ідеально було б мати дані про музичний розмір (наприклад, 4/4) та наявність прямого біту (four-on-the-floor), оскільки вони визначають танцювальність на фундаментальному рівні.

Логарифмування та нелінійність

Змінна *danceability* має природні межі [0, 1], тому логарифмування не застосовувалось. Перевірка нелінійності показала, що *valence* та *tempo* мають квадратичні ефекти. Коефіцієнт *valence* додатний, а *valence*² від'ємний, що означає послаблення приросту танцювальності на екстремально високих рівнях позитивності.

Фактори взаємодії

Додано взаємодію *valence* * *genre*, оскільки позитивність мелодії може стимулювати танцювальність у поп-музиці, але мати нульовий або інший ефект у металі чи класиці.

Фіктивні змінні

Жанр знову включено як набір даммі-змінних для контролю специфіки стилю.

Робастні стандартні похибки

Застосовано HC1 похибки для компенсації можливої гетероскедастичності залишків у різних жанрових кластерах.

F-тести та спільна значущість

Гіпотези про нульовий вплив полінома темпу (*tempo* та *tempo*²), а також жанрів та блоку взаємодій (*valence***genre*) були рішуче відхилені (*p*-value < 0.001). Танцювальність неможливо пояснити простою лінійною моделлю.

Мультиколінеарність

Аналіз Variance Inflation Factor (VIF) виявив серйозну проблему: *energy* (VIF = 4.10) та *loudness* (VIF = 2.95) є високо колінеарними. Гучність є фізичним відображенням енергії. Для усунення проблеми змінну *loudness* було вилучено, після чого VIF для *energy* впав до прийнятних 2.46.

Перевірка на стійкість

Вилучення *loudness* послужило перевіркою на стійкість: головні висновки щодо *valence*, *acousticness* та *instrumentalness* залишилися стабільними та змістовними.

Висновки за частиною 2

Valence:

Найсильніший позитивний фактор. При зміні *valence* з 0.30 до 0.60

танцювальність зростає на значні 0.098 пунктів (за шкалою від 0 до 1).

Energy та Acousticness:

Обидві змінні мають від'ємні коефіцієнти (-0.022 та -0.007 при зміні на 0.10). Від'ємний вплив енергії не означає, що вона "погана" причинно, а відображає те, що після контролю темпу та позитивності надмірна енергія характерна для агресивних (не танцювальних) жанрів.

Змінна	Базова
tempo	-0.001*** (0.00001)
energy	-0.098*** (0.001)
instrumentalness	-0.056*** (0.001)
valence	0.344*** (0.001)
Constant	0.547*** (0.001)
R2	0.303

Змінна	Контролі (1)	Поліноми (2)	Взаємодії (3)	Без Loudness (No VIF) (4)
tempo	-0.001*** (0.00001)	0.009*** (0.00004)	0.009*** (0.00004)	0.009*** (0.00004)
I(tempo2)		-0.00004***	-0.00004***	-0.00004***

		(0.00000)	(0.00000)	(0.00000)
energy	-0.200*** (0.002)	-0.219*** (0.002)	-0.221*** (0.002)	-0.179*** (0.001)
instrumentalness	-0.034*** (0.001)	-0.034*** (0.001)	-0.035*** (0.001)	-0.042*** (0.001)
valence	0.329*** (0.001)	0.382*** (0.003)	0.420*** (0.005)	0.422*** (0.005)
I(valence2)		-0.062*** (0.003)	-0.084*** (0.003)	-0.090*** (0.003)
loudness	0.003*** (0.0001)	0.004*** (0.0001)	0.003*** (0.0001)	
year	0.001*** (0.00001)	0.001*** (0.00001)	0.001*** (0.00001)	0.001*** (0.00001)
genreClassical	-0.052*** (0.002)	-0.054*** (0.001)	-0.101*** (0.003)	-0.109*** (0.003)
genreCountry	0.016*** (0.001)	0.013*** (0.001)	0.032*** (0.003)	0.034*** (0.003)

genreElectronic	0.117*** (0.001)	0.100*** (0.001)	0.136*** (0.003)	0.134*** (0.003)
genreFolk	0.030*** (0.001)	0.027*** (0.001)	-0.005* (0.003)	-0.008*** (0.003)
genreHip-Hop	0.141*** (0.001)	0.133*** (0.001)	0.209*** (0.003)	0.209*** (0.003)
genreJazz	0.019*** (0.001)	0.017*** (0.001)	-0.026*** (0.003)	-0.031*** (0.003)
genrePop	0.014*** (0.001)	0.007*** (0.001)	-0.008*** (0.003)	-0.008*** (0.003)
genreR&B	0.063*** (0.001)	0.060*** (0.001)	0.048*** (0.003)	0.050*** (0.003)
genreRock	-0.047*** (0.001)	-0.051*** (0.001)	-0.031*** (0.003)	-0.034*** (0.003)
speechiness	0.060*** (0.002)	0.129*** (0.002)	0.125*** (0.002)	0.114*** (0.002)
acousticness	-0.082*** (0.001)	-0.074*** (0.001)	-0.069*** (0.001)	-0.070*** (0.001)

valence:genreClassical			0.127*** (0.006)	0.139*** (0.006)
valence:genreCountry			-0.035*** (0.005)	-0.037*** (0.005)
valence:genreElectronic			-0.070*** (0.005)	-0.068*** (0.005)
valence:genreFolk			0.062*** (0.005)	0.068*** (0.005)
valence:genreHip-Hop			-0.139*** (0.005)	-0.135*** (0.005)
valence:genreJazz			0.089*** (0.006)	0.097*** (0.006)
valence:genrePop			0.035*** (0.005)	0.035*** (0.005)
valence:genreR&B			0.025*** (0.005)	0.024*** (0.005)
valence:genreRock			-0.033*** (0.004)	-0.032*** (0.004)

Constant	-1.251*** (0.029)	-1.766*** (0.027)	-1.793*** (0.027)	-2.157*** (0.026)
---	---	---	---	---
Observations	516,129	516,129	516,129	516,129
R2	0.483	0.540	0.546	0.544
Adjusted R2	0.483	0.540	0.546	0.544

Оскільки в моделях використовуються категорійні змінні (genre) та поліноми другого ступеня (квадрати темпу та валентності), аналіз лише індивідуальних р-значень є недостатнім. Для підтвердження статистичної значущості цих груп змінних було проведено спільні F-тести з використанням робастної матриці коваріацій:

F-тест 1 (Нелінійність темпу / Поліном темпу): Перевіряв спільну значущість лінійного темпу (tempo) та його квадрата ($I(\text{tempo}^2)$). Тест ($F=36343$, $p<2.2e-16$) беззаперечно довів значущість цього полінома. Це математично підтверджує, що зв'язок між швидкістю пісні та її танцювальністю має складну форму параболи.

F-тест 2 (Спільна значущість жанрів): Перевіряв одночасну рівність нулю всіх індикаторів жанру. Тест ($F=12239$, $p<2.2e-16$) рішуче відкинув нульову гіпотезу, довівши наявність базових відмінностей у танцювальності між різними музичними напрямками.

F-тест 3 (Нелінійність настрою / Поліном валентності): Перевіряв спільну значущість лінійного терма емоційної позитивності (valence) та його квадрата ($I(\text{valence}^2)$). Тест ($F=18886$, $p<2.2e-16$) статистично довів, що емоційний настрій треку також впливає на танцювальність нелінійно.

Після підтвердження ключових структурних гіпотез перейдемо до детальної математичної інтерпретації коефіцієнтів.

Згідно з результатами фінальної моделі, лінійний коефіцієнт tempo дорівнює 0.009, а його квадрат $I(\text{tempo}^2)$ дорівнює -0.00004 . Щоб зрозуміти реальний вплив, розглянемо приклади однакового пришвидшення треку на 10 BPM для різних базових швидкостей

Зміна від 80 до 90:

$$0.009 * (90 - 80) - 0.00004 * (90^2 - 80^2) \approx 0.022$$

Зміна від 120 до 130:

$$0.009 * (130 - 120) - 0.00004 * (130^2 - 120^2) \approx -0.01$$

Як можна побачити з прикладів при збільшенні темпу з 80 до 90 танцювальність збільшується на 0.022 значення, а при зміні зі 120 до 130 танцювальність зменшується на 0.01 значення. Вершина параболи для поліному темпу знаходиться в районі 112 BPM.

Аналогічно до темпу, емоційна позитивність (valence) має статистично значущий нелінійний ефект, що додатково було підтверджено спільним F-тестом. Відповідно до результатів фінальної Моделі 4, лінійний терм валентності дорівнює 0.422, а квадратичний складає -0.090 . Щоб наочно продемонструвати, як зміна емоційного забарвлення треку впливає на його танцювальність залежно від початкового настрою, розглянемо маржинальні ефекти при однаковому збільшенні показника валентності на 0.1

Приклад при зміні валентності від 0.3 до 0.4

$$0.422 * (0.4 - 0.3) - 0.09 * (0.4^2 - 0.3^2) \approx 0.0359$$

Приклад при зміні валентності від 0.8 до 0.9

$$0.422 * (0.9 - 0.8) - 0.09 * (0.9^2 - 0.8^2) \approx 0.0269$$

Як можна побачити з цих розрахунків, позитивніший і веселіший настрій композиції незмінно призводить до підвищення її танцювальності. Математичний аналіз цієї параболи показує, що її вершина знаходиться в точці ≈ 2.34 . Оскільки шкала валентності за своєю природою обмежена діапазоном від 0 до 1, реальні треки ніколи не досягають цієї теоретичної вершини спадання. Це означає, що в межах усіх допустимих значень функція є монотонно зростаючою. Будь-яке збільшення валентності треку завжди підвищуватиме його танцювальність. Однак, нелінійність проявляється в тому, що швидкість цього приросту поступово сповільнюється для надзвичайно позитивних, ейфорійних композицій.

Згідно з результатами фінальної моделі (очищеної від мультиколінеарності), лінійний коефіцієнт біля змінної *year* є статистично значущим і становить 0.001. Оскільки в цій специфікації рік включено у лінійному вигляді, його маржинальний вплив на танцювальність є сталим у часі. Це математично означає, що за інших рівних умов (при фіксованому жанрі, темпі та однакових акустичних метриках) кожний наступний рік асоціюється з абсолютним зростанням показника танцювальності. Щоб наочно продемонструвати цю тенденцію, розрахуємо зміну базової танцювальності для такого історичного проміжку:

Зміна за одне десятиліття, наприклад, з 2010 по 2020 рік.

$$0.001 * (2020 - 2010) = 0.01$$

Отже, за кожне нове десятиліття базова танцювальність індустріального стандарту зростає на 0.01 пункти.

Окрім темпу, настрою та року, танцювальність суттєво визначається базовою акустичною структурою треку. Аналіз оцінених коефіцієнтів Моделі 4 демонструє чіткі ефекти контрольних змінних.

Змінна *speechiness* (наявність розмовного тексту) має позитивний вплив (0.114). Натомість *energy* (−0.179), *acousticness* (−0.070) та *instrumentalness* (−0.042) мають статистично значущий від'ємний вплив. Ці результати доводять,

що як надто шумні та екстремально інтенсивні композиції (наприклад, важкий метал), так і повністю акустичні чи суто інструментальні треки об'єктивно набагато важче піддаються стандартним танцювальним ритмам.

Нарешті, базова жанрова приналежність композиції відіграє фундаментальну роль у формуванні її танцювального потенціалу. Оскільки залежна змінна не логарифмована, коефіцієнти показують абсолютну різницю в танцювальності порівняно з базовою категорією. Аналізуючи Модель 4, ми бачимо, що найвищу базову танцювальність мають треки жанрів Hip-Hop (0.209) та Electronic (0.134). Також додатний вплив мають R&B (0.050) та Country (0.034). Натомість найменш танцювальними об'єктивно є складні або не масові ритмічні напрямки: Classical (0.109), Rock (0.034) та Jazz (0.031). Ці результати показують те, що індустріальні стандарти створення танцювальної музики прив'язані до конкретних жанрових ніш, де хіп-хоп та електронна музика є лідерами.

Цікаві результати демонструють фактори взаємодії емоційної позитивності з категоріями жанрів. Вони статистично доводять, що настрої по-різному впливає на танцювальність композиції залежно від її музичного напрямку. Базовий лінійний вплив валентності у Моделі 4 становить 0.422. Проте для таких ритмічно домінуючих жанрів як Hip-Hop та Electronic, коефіцієнти взаємодії є суттєво від'ємними (-0.135 та -0.068 відповідно). Це означає, що в цих жанрах треки створюються максимально танцювальними від самого початку, і цей потенціал слабше залежить від того, сумна це пісня чи весела. Натомість для жанрів, що не є танцювальними за своєю природою, таких як Classical ($+0.139$) або Jazz ($+0.097$), коефіцієнти взаємодії є додатними. Це свідчить про те, що для класичної чи джазової композиції саме веселий, мажорний і життєрадісний настрій є критично важливим драйвером, який тільки і здатен зробити її хоч трохи придатною для танцю.

Для оцінки загальної якості побудованих моделей та їхньої пояснювальної здатності звернемося до скоригованого коефіцієнта детермінації.

Як видно зі зведеної фінальної таблиці, базова Модель 1, яка містить лише лінійні контролі, пояснює 48.3% дисперсії танцювальності. Додавання поліноміальних ефектів у Моделі 2 різко підвищує якість підгонки до 54.0%, що ще раз математично підтверджує правильність висунутої гіпотези про нелінійність (параболічність) сприйняття темпу та настрою. Ускладнена Модель 3 з факторами взаємодії між жанром і валентністю дещо підіймає показник до 54.6%.

Фінальна Модель 4 (очищена від мультиколінеарності) демонструє Adjusted R^2 на рівні 0.544 (54.4%). Загалом, пояснення понад 54% варіативності для даних із креативної мистецької сфери є високим результатом. Усі ключові початкові гіпотези дослідження знайшли своє переконливе економетричне підтвердження.

ЧАСТИНА 3. Аналіз нецензурної лексики (explicit)

Дослідницьке питання

Метою цієї частини дослідження є виявлення та квантифікація факторів, що визначають ймовірність наявності нецензурної лексики (позначки Explicit) у музичних композиціях. Дослідницьке питання полягає в тому, щоб з'ясувати, як саме аудіо-характеристики треку, його базова жанрова приналежність та рік випуску впливають на ймовірність використання артистом нецензурної лексики. У рамках дослідження висувуються такі гіпотези:

- Гіпотеза 1 (Жанр як ключовий детермінант): Музичний жанр є фундаментальним фактором, що визначає ймовірність explicit-контенту. Очікується, що жанр Нір-Нор матиме значно вищу ймовірність наявності нецензурної лексики порівняно з консервативними напрямками.
- Гіпотеза 2 (Вплив акустичних метрик): Більш танцювальні та високоенергійні треки мають вищу ймовірність містити нецензурну лексику, оскільки такі метрики часто притаманні сучасній комерційній музиці. Натомість позитивний настрій композиції (valence) може знижувати цю ймовірність.

- Гіпотеза 3 (Неоднорідність впливу ритміки): Вплив танцювальності на ймовірність наявності explicit-контенту не є універсальним і суттєво відрізняється залежно від музичного жанру (наявність статистично значущих факторів взаємодії).

Залежною змінною у цьому аналізі виступає `explicit_num` бінарна змінна, яка набуває значення 1, якщо трек має позначку "Explicit" (у нашому датасеті таких треків 88 111), і 0, якщо "Clean" (428 018 треків).

Оскільки залежна змінна є бінарною, використання класичної лінійної ймовірнісної моделі є неякісним підходом, адже немає гарантії, що прогнозовані значення лежатимуть у межах від 0 до 1. Щоб забезпечити максимальну надійність результатів та переконатися, що наші висновки не залежать від обраної функції зв'язку, ми оцінюємо моделі одразу двома методами: Logit, який припускає логістичний розподіл похибки ϵ_i , та Probit, що базується на стандартному нормальному розподілі похибки.

OVВ (Зміщення від неврахованих змінних): Незважаючи на додавання великої кількості акустичних контролів, ризик OVВ залишається. Наша модель не може врахувати такі важливі неспостережувані фактори, як особистий імідж та бекграунд артиста, цільова аудиторія, або наявність цензури на радіостанціях у конкретній країні в рік релізу.

Для перевірки стійкості оцінених параметрів було побудовано три специфікації моделі з поступовим ускладненням. Кожна з цих специфікацій була паралельно оцінена обома методами (Logit та Probit).

Модель 1 (Базова): Включає виключно базові акустичні характеристики треку (`energy`, `valence`, `danceability`).

Модель 2 (3 контролями): Для мінімізації OVВ до моделі було додано категорійну змінну музичного жанру (`genre`) та лінійний тренд часу (`year`). Це дозволяє очистити ефекти акустичних характеристик від жанрової та історичної специфіки.

Модель 3 (Із взаємодіями): Найскладніша специфікація, до якої додатково включено фактори взаємодії між танцювальністю та жанром. Це дозволяє перевірити гіпотезу про те, що вплив танцювального потенціалу пісні на ймовірність наявності нецензурної лексики є неоднорідним для різних музичних ніш.

Базова модель

Оскільки залежна змінна `explicit_num` є бінарною (1 = Explicit, 0 = Clean), класичний OLS (Linear Probability Model) не підходить через ризик прогнозів поза межами [0, 1]. Використано моделі бінарного вибору (Logit та Probit).

Зміщення від неврахованих змінних (OVB)

Модель фіксує лише аудіо-властивості. Величезна частка дисперсії (OVB) припадає на демографію артиста, цільову аудиторію та культурний контекст країни походження, яких немає у датасеті.

Логарифмування та нелінійність (функція зв'язку)

Застосовано логістичну (Logit) та нормальну (Probit) функції зв'язку для трансформації лінійного предиктора у ймовірності.

Фактори взаємодії

Додано взаємодію `danceability * genre`, оскільки висока танцювальність у реп-музиці часто асоціюється з клубною/explicit культурою, тоді як у поп-музиці або кантрі цей зв'язок може бути іншим.

Фіктивні змінні

Жанр традиційно включено як контрольний набір даммі-змінних.

Робастні стандартні похибки

Для моделей максимальної вірогідності (GLM) також розраховано робастні коваріаційні матриці (HC1), щоб захистити тести Волда від можливої неправильної специфікації дисперсії.

Тести Волда

Тест Волда підтвердив спільну статистичну значущість жанрових змінних (LPM proxy: $p\text{-value} < 0.001$) та взаємодій `danceability * genre`.

Мультиколінеарність

Обґрунтування з попередньої моделі зберігається: для уникнення проблем loudness не включалася разом з energy.

Перевірка на стійкість

Оцінено паралельно специфікації Logit та Probit. Оскільки самі коефіцієнти вимірюються в лог-шансах (log-odds) і не мають прямої інтерпретації, для порівняння та аналізу розраховано Середні Маржинальні Ефекти (Average Marginal Effects, AME). Результати виявилися абсолютно стійкими.

Висновки за частиною 3

Energy та Danceability:

Вищі значення цих метрик причинно асоціюються з більшою ймовірністю матів. Збільшення енергійності на 0.10 підвищує ймовірність explicit-статусу на 2.39 процентних пункти (п.п.). Збільшення танцювальності на 0.10 дає приріст у 1.27 п.п..

Valence:

На противагу цьому, позитивні за настроєм треки рідше містять нецензурну лексику (збільшення valence на 0.10 зменшує ймовірність на -0.64 п.п.).

Таблиці для Logit

Таблиця для Базової моделі

Term	Comparison	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
danceability	dY/dX	0.428	0.00379	113.2	<0.001	0.421	0.436
energy	dY/dX	0.306	0.00237	129.2	<0.001	0.301	0.311
valence	dY/dX	-0.144	0.00233	-61.6	<0.001	-0.148	-0.139

Таблиця для моделі з контролями

Term	Contrast	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
------	----------	----------	------------	---	----------	-------	--------

danceability	dY/dX	0.12700	3.78e-03	33.57	<0.001	0.11959	0.13442
energy	dY/dX	0.23854	2.71e-03	88.03	<0.001	0.23323	0.24385
genre	Classical - Blues	0.07193	4.71e-03	15.26	<0.001	0.06269	0.08117
genre	Country - Blues	0.05769	2.92e-03	19.78	<0.001	0.05198	0.06341
genre	Electronic - Blues	0.02434	2.60e-03	9.38	<0.001	0.01926	0.02943
genre	Folk - Blues	0.09186	2.97e-03	30.91	<0.001	0.08604	0.09769
genre	Hip-Hop - Blues	0.64721	3.53e-03	183.42	<0.001	0.64029	0.65412
genre	Jazz - Blues	-0.01369	3.46e-03	-3.95	<0.001	-0.02048	-0.00691
genre	Pop - Blues	0.04345	2.66e-03	16.35	<0.001	0.03824	0.04866
genre	R&B - Blues	0.11056	3.42e-03	32.33	<0.001	0.10386	0.11726
genre	Rock - Blues	0.07853	2.53e-03	30.99	<0.001	0.07356	0.08349
valence	dY/dX	-0.06433	2.34e-03	-27.51	<0.001	-0.06892	-0.05975
year	dY/dX	0.00167	4.44e-05	37.59	<0.001	0.00158	0.00176

Таблиця для моделі із взаємодіями між жанром і танцювальністю.

Term	Contrast	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
danceability	dY/dX	0.1238	3.86e-03	32.08	<0.001	0.11623	0.13135
energy	dY/dX	0.2284	2.75e-03	83.07	<0.001	0.22306	0.23383
genre	Classical - Blues	0.0800	5.02e-03	15.94	<0.001	0.07016	0.08984
genre	Country - Blues	0.0525	2.90e-03	18.09	<0.001	0.04681	0.05818
genre	Electronic - Blues	0.0207	2.65e-03	7.78	<0.001	0.01546	0.02586
genre	Folk - Blues	0.0954	3.08e-03	30.94	<0.001	0.08939	0.10148
genre	Hip-Hop - Blues	0.6148	4.45e-03	138.11	<0.001	0.60606	0.62351
genre	Jazz - Blues	-0.0176	3.41e-03	-5.15	<0.001	-0.02424	-0.01088
genre	Pop - Blues	0.0408	2.66e-03	15.33	<0.001	0.03556	0.04599
genre	R&B - Blues	0.0879	3.59e-03	24.50	<0.001	0.08086	0.09492
genre	Rock - Blues	0.0673	2.54e-03	26.50	<0.001	0.06233	0.07229

valence	dY/dX	-0.0595	2.36e-03	-25.22	<0.001	-0.06417	-0.05491
year	dY/dX	0.0017	4.49e-05	37.92	<0.001	0.00161	0.00179

Таблиця для моделі із взаємодіями між жанром і танцювальністю.

genre	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
Blues	0.03407	0.01163	2.93	0.0034	0.01127	0.0569
Classical	0.20307	0.01593	12.75	<0.001	0.17186	0.2343
Country	0.20643	0.01280	16.13	<0.001	0.18134	0.2315
Electronic	0.19007	0.01065	17.85	<0.001	0.16921	0.2109
Folk	0.06112	0.00901	6.78	<0.001	0.04346	0.0788
Hip-Hop	0.37535	0.01443	26.01	<0.001	0.34706	0.4036
Jazz	0.05283	0.00862	6.13	<0.001	0.03594	0.0697
Pop	0.17331	0.00791	21.92	<0.001	0.15781	0.1888
R&B	0.33177	0.01596	20.79	<0.001	0.30050	0.3630
Rock	0.00921	0.00651	1.41	0.1574	-0.00356	0.0220

Таблиці для Probit

Таблиця для Базової моделі

Term	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
danceability	0.418	0.00378	110.5	<0.001	0.410	0.425

energy	0.306	0.00226	135.0	<0.001	0.301	0.310
valence	-0.143	0.00235	-60.8	<0.001	-0.147	-0.138

Таблиця для моделі з контролями

Term	Contrast	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
danceability	dY/dX	0.12463	3.76e-03	33.13	< 0.001	0.11726	0.13201
energy	dY/dX	0.22839	2.60e-03	87.90	< 0.001	0.22330	0.23348
genre	Classical - Blues	0.07051	4.47e-03	15.77	< 0.001	0.06175	0.07928
genre	Country - Blues	0.05318	2.85e-03	18.68	< 0.001	0.04760	0.05877
genre	Electronic - Blues	0.02080	2.59e-03	08.02	< 0.001	0.01571	0.02588
genre	Folk - Blues	0.08578	2.90e-03	29.58	< 0.001	0.08009	0.09146
genre	Hip-Hop - Blues	0.65021	3.46e-03	187.85	< 0.001	0.64343	0.65700
genre	Jazz - Blues	-0.01053	3.45e-03	-3.05	0.00228	-0.01730	-0.00377
genre	Pop - Blues	0.04037	2.63e-03	15.37	< 0.001	0.03522	0.04552

genre	R&B - Blues	0.10425	3.33e-03	31.27	< 0.001	0.09771	0.11078
genre	Rock - Blues	0.07537	2.52e-03	29.96	< 0.001	0.07044	0.08030
valence	dY/dX	-0.06299	2.34e-03	-26.90	< 0.001	- 0.06758	- 0.05840
year	dY/dX	0.00165	4.28e-05	38.47	< 0.001	0.00156	0.00173

Таблиця для моделі із взаємодіями між жанром і танцювальністю.

Term	Contrast	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
danceability	dY/dX	0.11918	3.83e-03	31.12	<0.001	0.11167	0.12669
energy	dY/dX	0.21831	2.64e-03	82.63	<0.001	0.21313	0.22349
genre	Classical - Blues	0.07901	4.82e-03	16.38	<0.001	0.06956	0.08847
genre	Country - Blues	0.04895	2.85e-03	17.20	<0.001	0.04337	0.05452
genre	Electronic - Blues	0.01766	2.65e-03	6.66	<0.001	0.01246	0.02286
genre	Folk - Blues	0.08896	2.98e-03	29.80	<0.001	0.08311	0.09481
genre	Hip-Hop - Blues	0.61725	4.42e-03	139.56	<0.001	0.60858	0.62591

genre	Jazz - Blues	-0.01318	3.49e-03	-3.78	<0.001	-0.02002	-0.00634
genre	Pop - Blues	0.03820	2.63e-03	14.54	<0.001	0.03305	0.04334
genre	R&B - Blues	0.08279	3.47e-03	23.85	<0.001	0.07599	0.08959
genre	Rock - Blues	0.06413	2.52e-03	25.44	<0.001	0.05919	0.06907
valence	dY/dX	-0.05809	2.36e-03	-24.64	<0.001	-0.06271	-0.05347
year	dY/dX	0.00167	4.32e-05	38.73	<0.001	0.00159	0.00176

Таблиця для моделі із взаємодіями між жанром і танцювальністю.

genre	Estimate	Std. Error	z	Pr(> z)	2.5 %	97.5 %
Blues	0.04138	0.01171	3.535	<0.001	0.0184	0.0643
Classical	0.20463	0.01553	13.178	<0.001	0.1742	0.2351
Country	0.19128	0.01236	15.473	<0.001	0.1671	0.2155
Electronic	0.18390	0.01055	17.432	<0.001	0.1632	0.2046
Folk	0.06004	0.00882	6.808	<0.001	0.0428	0.0773
Hip-Hop	0.36520	0.01461	24.989	<0.001	0.3366	0.3938
Jazz	0.04535	0.00825	5.499	<0.001	0.0292	0.0615
Pop	0.17349	0.00774	22.405	<0.001	0.1583	0.1887
R&B	0.33077	0.01540	21.475	<0.001	0.3006	0.3610

Rock	0.00452	0.00644	0.702	0.482	-0.0081	0.0171
------	---------	---------	-------	-------	---------	--------

Оскільки ми маємо справу з нелінійними моделями бінарного вибору (Logit та Probit), оціненими за методом максимальної правдоподібності (MLE), використання класичних F-тестів є некоректним. Для перевірки спільної статистичної значущості груп категорійних змінних та факторів взаємодії ми використовуємо тести Волда (Wald χ^2 test) з використанням робастної матриці коваріацій. Для підтвердження надійності результатів тести були проведені паралельно для обох методологій:

Тест Волда 1 (Спільна значущість жанрів): Перевіряв одночасну рівність нулю всіх індикаторів базового музичного жанру в Моделі 2. Результати тесту беззаперечно відкидають нульову гіпотезу як для логіт-моделі ($\chi^2 = 49180$, $p < 2.2e-16$), так і для пробіт-моделі ($\chi^2 = 53820$, $p < 2.2e-16$). Це доводить, що жанрова приналежність композиції є одним із детермінантів наявності в ній нецензурної лексики.

Тест Волда 2 (Спільна значущість взаємодії danceability:genre): Перевіряв одночасну рівність нулю всіх факторів взаємодії між танцювальністю та жанрами в ускладненій Моделі 3. Тест також рішуче відкинув нульову гіпотезу для обох специфікацій (Logit: $\chi^2 = 1189.7$, $p < 2.2e-16$; Probit: $\chi^2 = 1168$, $p < 2.2e-16$). Це підтверджує нашу третю гіпотезу, що вплив танцювального потенціалу пісні на ймовірність використання матів є неоднорідним і відрізняється залежно від музичної ніші.

На відміну від лінійних моделей, оцінені коефіцієнти β у моделях Logit та Probit не мають прямої інтуїтивної інтерпретації у відсоткових пунктах. Хоча знаки коефіцієнтів вказують на напрямок впливу, сам маржинальний ефект не є сталим і залежить від значень усіх інших регресорів. Тому для кількісної оцінки впливу факторів на ймовірність наявності explicit-контенту ми розраховуємо

Середні Маржинальні Ефекти (AME). Аналіз AME дозволяє зробити такі висновки щодо впливу ключових метрик:

Згідно з результатами розрахунку Середніх Маржинальних Ефектів для ускладненої Моделі 3, енергійність та танцювальність є сильними драйверами нецензурної лексики. Зростання енергійності треку на 1 одиницю підвищує ймовірність наявності матів у середньому на 22.8 відсоткових пункти (AME = 0.228). Значний вплив також має танцювальний потенціал, а саме зростання danceability на 1 збільшує ймовірність explicit-контенту в середньому на 12.4 відсоткових пункти (AME=0.124). Натомість емоційна позитивність (valence) має зворотний ефект, тобто більш веселі та мажорні треки рідше містять нецензурну лексику, ймовірність зменшується в середньому на 6.0 відсотка, AME = -0.060).

Як довели спільні тести Волда, базова ймовірність наявності explicit-контенту фундаментально залежить від музичного жанру. Аналіз Середніх Маржинальних Ефектів (AME) для ускладненої Моделі 3 дозволяє кількісно оцінити ці відмінності порівняно з базовою категорією (Blues). Результати обох методологій (Logit та Probit) демонструють узгодженість:

Належність треку до жанру Нір-Нор дає найпотужніший ефект: вона підвищує ймовірність наявності нецензурної лексики в середньому на колосальні 61.48 відсоткових пункти у логіт-моделі (та на 61.73 в.п. у пробіт-моделі) порівняно з блюзом за інших рівних умов. Інші масові жанри також мають об'єктивно вищу схильність до explicit-контенту порівняно з базою. Зокрема, ймовірність матів підвищується для Folk (на 9.54 в.п.), R&B (на 8.79 в.п.), Classical (на 8.00 в.п.) та Rock (на 6.73 в.п.).

Натомість найменш схильним до нецензурної лексики виявився інструментальний жанр Jazz, який зменшує цю ймовірність на 1.76 відсоткових пункти (Logit) порівняно з блюзом.

Спільний тест Волда для факторів взаємодії (danceability:genre) відкинув нульову гіпотезу ($\chi^2 = 1189.7$, $p < 2.2e-16$), що доводить, що вплив танцювального потенціалу пісні на наявність у ній матів не є сталим і відрізняється залежно від музичної ніші. Щоб оцінити цю неоднорідність, було розраховано груповані

Середні Маржинальні Ефекти (маржинальний ефект *danceability* всередині кожного конкретного жанру). Аналіз цих ефектів виявляє чіткі патерни:

У жанрі Нір-Нор вплив танцювальності є найпотужнішим. Зростання танцювальності на 1 одиницю експоненційно підвищує ймовірність *explicit*-контенту в середньому на 37.54 відсоткових пункти ($AME=0.375$) для Logit та на 36.52 в.п. для Probit. Схожий потужний підсилюючий ефект спостерігається і для R&B (зростання на 33.18 в.п.). Це означає, що в цих комерційних напрямках танцювальна ритміка жорстко прив'язана до використання нецензурної лексики.

Натомість для жанру Rock маржинальний ефект танцювальності виявився статистично незначущим в обох специфікаціях ($AME=0.009$, $p=0.157$ для Logit ; $AME=0.004$, $p=0.482$ для Probit). Це свідчить про те, що в рок-індустрії наявність чи відсутність нецензурної лексики взагалі не диктується тим, наскільки трек є придатним для танців чи ритмічним.

Оскільки залежна змінна у нашому дослідженні є бінарною, використання класичного скоригованого коефіцієнта детермінації для оцінки якості підгонки є економетрично некоректним. Натомість надійність та пояснювальна здатність побудованих моделей підтверджується структурною узгодженістю результатів між двома альтернативними специфікаціями, високою статистичною значущістю спільних тестів Волда, а також підтвердженням усіх висунутих на початку дослідження гіпотез.

ЧАСТИНА 4. Аналіз популярності

Дослідницьке питання та гіпотези

У ЛР1 було виявлено, що популярність треків пов'язана з жанром, *explicit*-контентом, аудіо-характеристиками та фан-базою артиста. У ЛР2 частину цих спостережень перевірено за допомогою довірчих інтервалів, Wald-тестів і бутстрепу. У ЛР3 ми переходимо до багатофакторної регресійної моделі, щоб оцінити зв'язок *popularity* з кількома змінними одночасно.

Основне дослідницьке питання: які характеристики треку та артиста статистично пов'язані з *popularity*, і які з них зберігають зв'язок після контролю

жанру та року випуску? У роботі є три змістовні блоки регресорів: fan-base артиста, аудіо-характеристики самого треку та explicit-статус. Окремо перевіряємо, чи fan-base артиста пов'язана з popularity нелінійно, чи аудіо-характеристики спільно додають інформацію до моделі, чи explicit-треки відрізняються від clean-треків, і чи окремі жанри мають іншу очікувану popularity за інших рівних умов.

1. H1: коефіцієнт біля $\log(1 + \text{total_artist_followers})$ має бути додатним.
2. H2: якщо зв'язок слабшає для великих артистів, коефіцієнт біля квадрата $\log_followers$ має бути від'ємним.
3. H3: аудіо-характеристики треку спільно пов'язані з popularity і можуть розглядатися як змістовний блок регресорів.
4. H4: explicit-контент може мати додатний зв'язок із popularity навіть після контролю жанру, часу та інших характеристик треку.
5. H5: genre fixed effects спільно статистично значущі; тобто жанр пов'язаний з popularity навіть після контролю інших факторів.

Дані та підготовка

Кластеризація стандартних похибок виконувалась на рівні artists; кількість кластерів: 43 531.

Діапазони ключових змінних: popularity = [0; 98], year = [1900; 2025], duration_ms = [15027; 4995315], total_artist_followers = [0; 295181876].

Основні змінні

Змінна	Роль	Пояснення
popularity	залежна змінна	Індекс популярності треку від 0 до 100.
log_followers_c	ключовий регресор	$\log(1 + \text{total_artist_followers})$, центрований навколо середнього.
explicit	змістовний регресор	Фактор Clean/Explicit.

audio features	регресори треку / контрольний блок	duration, danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo; змістовний блок характеристик звучання.
genre, decade	категорійні fixed effects	Контроль жанрових і часових відмінностей.

Найважливіша змінна для дослідження - `log_followers_c`: вона показує розмір fan-base артиста після логарифмування та центрування. Логарифм потрібний, бо кількість підписників дуже нерівномірна: різниця між малими артистами й мегазірками вимірюється мільйонами. Центрування потрібне для коректнішої роботи з квадратом `log_followers_c^2` і зменшує технічну залежність між лінійним та квадратичним членом. Audio features є змістовним блоком характеристик самого треку: вони показують, чи звучання і тривалість пов'язані з popularity. Одночасно вони допомагають не приписувати fan-base те, що може пояснюватися самими властивостями треку. Змінні genre і decade потрібні як fixed effects: без них модель могла б переплутати ефект fan-base або аудіо-характеристик із жанровими чи часовими відмінностями.

Розподіл жанрів та explicit

Жанр	К-сть	Частка
Rock	186943	36.22%
Pop	66728	12.93%
Electronic	64758	12.55%
Folk	47917	9.28%

Country	43885	8.50%
Hip-Hop	37887	7.34%
R&B	25248	4.89%
Jazz	16024	3.10%
Blues	15173	2.94%
Classical	11566	2.24%

Ця таблиця показує, що датасет жанрово незбалансований: Rock має найбільшу кількість треків, а менш масові жанри представлені суттєво слабше. Це важливо для регресії, бо popularity може відрізнятися не тільки через fan-base артиста, а й через сам жанр. Саме тому genre додається в моделі M2-M4 як факторна контрольна змінна.

Explicit	К-сть	Частка
Clean	428018	82.93%
Explicit	88111	17.07%

Таблиця explicit показує співвідношення Clean і Explicit треків. Оскільки explicit-контент у попередніх лабораторних вже був пов'язаний із popularity, у ЛРЗ він використовується як окремий регресор. Коефіцієнт explicitExplicit у таблиці моделей означає різницю між Explicit і Clean треками за інших рівних умов.

Методологія

Використано OLS-моделі. Теоретично ми спираємося на функцію умовного сподівання $Y = m(X) + e$, $E[e | X] = 0$. Якщо ця умова не виконується через omitted variable bias, коефіцієнти слід трактувати як умовні асоціації, а не як доведений причинний ефект.

Основна специфікація: $\text{popularity}_i = \beta_0 + \beta_1 \log_followers_c_i + \beta_2 \log_followers_c_i^2 + \beta_3 \text{explicit}_i + \gamma' \text{Audio}_i + \delta_genre + \tau_decade + e_i$

Гомоскедастичні стандартні похибки не використовувались. Основні p-values та SE в таблицях розраховано як кластеризовані на рівні artists, оскільки один артист може мати багато треків, а залишки для треків одного артиста природно можуть бути корельованими.


Категорійна змінна	Базова категорія
genre	Rock
decade	2010

Для genre базою обрано Rock, бо це найбільша група у вибірці. Для decade базою обрано 2010-ті, бо це сучасна й велика категорія.

Графічна мотивація нелінійності

На графіку видно, що popularity зростає разом із $\log(1 + \text{followers})$, але форма зв'язку не є строго лінійною.

Зв'язок popularity з $\log(1 + \text{total_artist_followers})$



Кожна точка на графіку - окремий трек із вибірки. По осі X відкладено $\log(1 + \text{total_artist_followers})$, тобто логарифмовану fan-base артиста. По осі Y -

popularity треку. Червона згладжена лінія показує середню тенденцію: popularity загалом зростає разом із fan-base. Водночас лінія не є ідеально прямою, тому в модель додається квадрат $\log_followers_c^2$.

Результати регресій

У кожному стовпчику наведено коефіцієнт, а в дужках під ним - кластеризовану стандартну похибку. M0 містить тільки fan-base; M1 додає audio features та explicit; M2 додає genre і decade; M3 додає квадрат $\log_followers$; M4 додає взаємодію $\log_followers$ з explicit.

label	M0	M1	M2	M3	M4
log followers, centered	2.7236 (0.0518)	2.6385 (0.0492)	2.4477 (0.0511)	2.5389 (0.0598)	2.4589 (0.0639)
log followers ²	nan	nan	nan	0.1057 (0.0133)	0.0984 (0.0133)
Explicit	nan	1.0813 (0.1673)	0.8774 (0.1468)	0.8316 (0.1456)	0.7831 (0.1406)
Duration, minutes	nan	-0.2429 (0.0399)	-0.1622 (0.0376)	-0.1752 (0.0377)	-0.1791 (0.0376)
Danceability	nan	7.3880 (0.4601)	7.1439 (0.4484)	6.9394 (0.4489)	6.8605 (0.4472)
Energy	nan	-3.7144 (0.4964)	-4.5563 (0.4551)	-4.2800 (0.4487)	-4.1965 (0.4486)
Loudness	nan	0.2709 (0.0283)	0.5176 (0.0260)	0.5050 (0.0259)	0.5020 (0.0258)

Speechiness	nan	-2.0320 (0.6612)	-2.6190 (0.6097)	-2.5283 (0.6135)	-2.6363 (0.6120)
Acousticness	nan	-1.8133 (0.3134)	-1.5533 (0.2990)	-1.5475 (0.3051)	-1.5136 (0.3017)
Instrumentalness	nan	-1.7256 (0.2269)	-1.0168 (0.2263)	-0.8755 (0.2257)	-0.9012 (0.2255)
Liveness	nan	-5.5807 (0.2531)	-5.1189 (0.2368)	-5.1808 (0.2361)	-5.1477 (0.2355)
Valence	nan	-2.3728 (0.2876)	-3.2038 (0.2785)	-3.2095 (0.2801)	-3.1754 (0.2775)
Tempo	nan	0.0082 (0.0012)	0.0086 (0.0012)	0.0085 (0.0012)	0.0082 (0.0012)
log followers x Explicit	nan	nan	nan	nan	0.4251 (0.0811)

1. log followers, centered - головна змінна fan-base. Додатний коефіцієнт означає, що більша fan-base пов'язана з більшою popularity.
2. log followers² - перевірка нелінійності. Від'ємний знак підтримував би гіпотезу про слабшання ефекту для великих артистів; додатний знак означає, що в цій специфікації слабшання не підтвердилось.
3. Explicit - різниця Explicit-треків порівняно з Clean-треками.
4. log followers x Explicit - взаємодія. Вона показує, чи відрізняється нахил зв'язку fan-base з popularity для Explicit-треків.
5. Duration і audio features - змістовний блок регресорів треку. Їх можна аналізувати як зв'язок характеристик звучання з popularity, але без причинної інтерпретації. У моделі вони також виконують контрольну роль, бо дозволяють порівнювати треки з подібними спостережуваними характеристиками звучання.

Порівняння M0-M4 показує стійкість основного результату. Коефіцієнт біля $\log_followers_c$ залишається додатним після додавання explicit, audio features, genre, decade, квадрата та взаємодій. Це означає, що зв'язок fan-base з popularity не зникає після контролю інших факторів.

Модель	N	Кластери artists	К-сть коеф.	R2	Adj. R2
M0	516123	43531	2	0.1435	0.1435
M1	516123	43531	13	0.1601	0.1600
M2	516123	43531	34	0.1798	0.1797
M3	516123	43531	35	0.1823	0.1823
M4	516123	43531	36	0.1828	0.1827

N - кількість спостережень у моделі. Кластери artists - кількість унікальних артистів, на рівні яких рахуються кластеризовані стандартні похибки. К - кількість оцінених коефіцієнтів. R2 показує, яку частку варіації popularity пояснює модель. Зростання R2 від M0 до M3 означає, що додавання контролів і нелінійності покращує пояснювальну здатність, хоча вона залишається малою.

Інтерпретація ключових коефіцієнтів

- У M3 коефіцієнт біля $\log_followers_c$ дорівнює 2.539, але через квадрат $\log_followers_c$ ефект не є сталим. У медіанній точці розподілу +10% followers відповідає приблизно 0.24 пункта popularity, за інших рівних умов.
- Коефіцієнт біля $\log_followers_c^2$ у M3 дорівнює 0.106 і є статистично значущим. Знак додатний, тому початкова гіпотеза про слабшання зв'язку для великих артистів не підтвердилася в квадратичній специфікації.
- У M3 explicit-треки мають popularity у середньому на 0.832 пункта вищу, ніж clean-треки, за інших рівних умов.

4. У М4 взаємодія $\log_followers_c \times \text{explicit}$ дорівнює 0.425. Це означає, що нахил зв'язку fan-base з popularity для explicit-треків вищий.

Граничний ефект fan-base у М3

Точка	$\log_followers_c$	$\partial E[Y]/\partial \log_followers$
p10 log followers	-3.008	1.903
median log followers	0.061	2.552
p90 log followers	3.007	3.175

Оскільки $\beta_2 > 0$, оцінений граничний ефект більший у верхній частині розподілу fan-base.

Ця таблиця показує не сам коефіцієнт, а граничний ефект fan-base у трьох точках розподілу: низька fan-base (p10), типове значення (медіана) і висока fan-base (p90). Через наявність квадрата ефект $\log_followers$ не є сталим. Оскільки регресор логарифмічний, невелику відсоткову зміну followers можна читати через множення граничного ефекту на зміну логарифма. Наприклад, +10% followers дає зміну $\log(1 + followers)$ приблизно на $\log(1.10)$, тобто на 0.095.

Зміна followers і очікувана зміна popularity

Інтерпретація за основною моделлю М3. Розрахунок використовує $\log(1 + followers)$ і квадрат $\log_followers_c$; інші змінні моделі вважаються фіксованими.

Зміна followers	Очікувана зміна popularity
1 тис. -> 10 тис.	+3.75 пункти
10 тис. -> 100 тис.	+4.87 пункти
100 тис. -> 1 млн	+5.99 пункти
1 млн -> 10 млн	+7.12 пункти
10 млн -> 100 млн	+8.24 пункти
+10% followers при 100 тис.	+0.23 пункти
+10% followers при 1 млн	+0.27 пункти

+10% followers при 10 млн	+0.32 пункти
---------------------------	--------------

Окремі жанрові ефекти у М3

Жанр	Коефіцієнт	Cluster SE	t	p-value
Rock	0.000			
Blues	-1.582	0.737	-2.146	0.0319
Classical	4.489	0.768	5.845	5.06e-09
Country	0.949	0.498	1.905	0.0568
Electronic	0.673	0.306	2.203	0.0276
Folk	-0.243	0.429	-0.567	0.5707
Hip-Hop	1.848	0.462	3.998	6.40e-05
Jazz	1.045	0.693	1.508	0.1315
Pop	0.789	0.377	2.090	0.0366
R&B	1.379	0.460	3.002	0.0027

У М3 базовим жанром є Rock, тому його коефіцієнт дорівнює 0. Коефіцієнти інших жанрів показують, на скільки пунктів popularity відповідний жанр відрізняється від Rock за однакових fan-base, explicit, аудіо-характеристик і decade. Наприклад, додатний коефіцієнт Hip-Hop означає, що Hip-Hop має вищу очікувану popularity, ніж Rock, якщо інші змінні однакові.

Ця таблиця дає відповідь на питання про окремі жанри: якщо p-value для жанру менше 0.05, то різниця цього жанру відносно Rock є статистично значущою. Але це не означає, що сам жанр причинно створює популярність; це умовна різниця після контролю наявних змінних.

Wald-тести

Тест	df	Статистика	p-value
------	----	------------	---------

M3: nonlinear fan-base term	1	62.695	2.41e-15
M4: interaction log_followers x explicit	1	27.457	1.61e-07
M3: all genre fixed effects	9	66.325	7.96e-11
M3: all decade fixed effects	12	812.126	4.15e-166
M3: all audio controls	10	1276.636	4.21e-268

Нелінійний член fan-base, взаємодія з explicit, genre fixed effects, decade fixed effects і група audio features є статистично значущими. Це означає, що основну модель M3/M4 варто залишати з квадратом fan-base, категорійними fixed effects і блоком аудіо-характеристик.

1. M3: nonlinear fan-base term - перевіряє, чи потрібен квадрат $\log_followers_c^2$.
2. M4: interaction log_followers x explicit - перевіряє, чи відрізняється ефект fan-base для Explicit-треків.
3. M3: all genre fixed effects - перевіряє, чи жанр загалом важливий.
4. M3: all decade fixed effects - перевіряє, чи десятиліття релізу загалом важливе.
5. M3: all audio features - перевіряє, чи аудіо-характеристики разом мають значення.

Чи корисні audio features

Перевірка	df	p-value, ordinary	p-value, clustered	Змінні
All duration/audio controls	10	0.00e+00	4.21e-268	duration_min, danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo
Core sound controls: danceability, energy, loudness, valence, tempo	5	0.00e+00	3.28e-154	danceability, energy, loudness, valence, tempo
Texture/context controls: speechiness, acousticness, instrumentalness, liveness	4	0.00e+00	1.45e-114	speechiness, acousticness, instrumentalness, liveness
Individual control: duration_min	1	9.47e-35	3.30e-06	duration_min
Individual control: danceability	1	0.00e+00	6.60e-54	danceability
Individual control: energy	1	4.34e-107	1.45e-21	energy

Individual control: loudness	1	0.00e+00	1.06e-84	loudness
Individual control: speechiness	1	9.11e-21	3.77e-05	speechiness
Individual control: acousticness	1	1.17e-42	3.92e-07	acousticness
Individual control: instrumentalness	1	3.78e-19	1.05e-04	instrumentalness
Individual control: liveness	1	0.00e+00	1.08e-106	liveness
Individual control: valence	1	4.85e-178	2.18e-30	valence
Individual control: tempo	1	3.01e-28	3.29e-13	tempo

Блок duration/audio features спільно статистично значущий навіть після кластеризації за артистами, тому прибирати його як повністю некорисний не варто. Водночас окремі аудіо-змінні не треба переінтерпретовувати як головні дослідницькі ефекти: індивідуальні p-value залежать від того, які інші audio features уже є в моделі, і через кореляції між energy, loudness, acousticness тощо окремі коефіцієнти можуть бути менш стабільними. Найважливіший висновок такий: аудіо-характеристики мають сенс як змістовний блок регресорів треку.

Ordinary SE проти clustered SE

Змінна	Коефіцієнт	Ordinary SE	Clustered SE	Cluster / ordinary	p-value, ordinary	p-value, clustered
--------	------------	-------------	--------------	--------------------	-------------------	--------------------


log followers	2.539	0.010	0.060	6.041	0.00e+00	0.00e+00
log followers^2	0.106	0.003	0.013	5.041	0.00e+00	2.41e-15
Explicit	0.832	0.066	0.146	2.202	2.77e-36	1.12e-08
Duration	-0.175	0.014	0.038	2.644	9.47e-35	3.30e-06
danceability	6.939	0.176	0.449	2.551	0.00e+00	6.60e-54
energy	-4.280	0.195	0.449	2.305	4.34e-107	1.45e-21
loudness	0.505	0.010	0.026	2.597	0.00e+00	1.06e-84
speechiness	-2.528	0.271	0.613	2.268	9.11e-21	3.77e-05
acousticness	-1.548	0.113	0.305	2.699	1.17e-42	3.92e-07
instrumentalness	-0.876	0.098	0.226	2.305	3.78e-19	1.05e-04
liveness	-5.181	0.114	0.236	2.065	0.00e+00	1.08e-106
valence	-3.209	0.113	0.280	2.483	4.85e-178	2.18e-30
tempo	0.008	7.68e-04	0.001	1.514	3.01e-28	3.29e-13

Звичайні standard errors припускають незалежність і однакову дисперсію помилок. Для треків одного артиста це сильне припущення, тому в основних висновках використовуються clustered SE by artist. Порівняльна таблиця показує, що кластеризація часто змінює розмір SE; отже, звичайні похибки були б занадто


оптимістичним варіантом для частини коефіцієнтів. Якщо висновок зберігається і при clustered SE, він надійніший.

Діагностика, мультиколінеарність і robustness

Діагностика M3: залишки проти fitted values



На цьому графіку по осі X відкладено прогнозовані моделлю M3 значення popularity, а по осі Y - залишки, тобто різницю між реальною popularity і прогнозом моделі. Ідеально залишки мають бути розкидані навколо нуля без чіткої структури. Якщо видно сильний системний патерн, це означає, що модель щось не враховує.




Кореляції та VIF

Змінна 1	Змінна 2	Кореляція
energy	loudness	0.778
acousticness	energy	-0.751
acousticness	loudness	-0.607
danceability	valence	0.492
log_followers	popularity	0.379
energy	tempo	0.216
duration_min	valence	-0.206
instrumentalness	valence	-0.193

Таблиця показує найсильніші парні кореляції між числовими змінними. Висока кореляція означає, що дві змінні частково несуть схожу інформацію. Це важливо для регресії, бо сильна кореляція між регресорами може збільшувати стандартні похибки та ускладнювати інтерпретацію окремих коефіцієнтів.

Змінна	R2 aux	VIF
energy	0.780	4.549
loudness	0.644	2.805
acousticness	0.592	2.453
danceability	0.371	1.590
valence	0.342	1.520
instrumentalness	0.139	1.161
duration_min	0.096	1.107
liveness	0.096	1.106
speechiness	0.090	1.098
tempo	0.081	1.089
log_followers	0.048	1.050

VIF для числових регресорів



Найвищий VIF має energy (близько 4.55), що очікувано через зв'язок з loudness і acoustiness. Це не є критичним рівнем, але коефіцієнти окремих аудіо-змінних треба інтерпретувати обережно.

VIF показує, наскільки сильно змінна пояснюється іншими регресорами. Якщо VIF дуже високий, коефіцієнт цієї змінної може бути нестабільним. У нашій моделі найбільший VIF має energy, бо energy природно пов'язана з loudness та acoustiness. Це не руйнує модель, але означає, що аудіо-змінні краще трактувати як спільний блок характеристик звучання, а не як набір незалежних причинних ефектів.

Robustness-перевірки

Вибірка	N	Кластер и	log_follower s	SE	log_followers^ 2	SE^2	R2
full M3 sample	51612 3	43531	2.5389	0.059 8	0.1057	0.013 3	0.182 3
without popularity = 0	38289 6	35326	2.8208	0.062 0	0.1121	0.015 3	0.269 0
year >= 2000	42368 1	40892	2.5629	0.060 3	0.1162	0.012 7	0.179 0
without top 0.1% followers	51560 4	43525	2.5308	0.060 3	0.1026	0.013 4	0.180 6

У всіх перевірках коефіцієнти біля log_followers і log_followers^2 залишаються додатними. Отже, знак основного результату стійкий до вилучення нульової popularity, обмеження роками після 2000 та вилучення top 0.1% артистів за followers.

OVB та обмеження причинної інтерпретації

Неврахований фактор	Чому це проблема
Маркетинг і плейлистинг	Може одночасно збільшувати followers і popularity.
Рівень лейблу	Великі лейбли можуть давати і більшу фан-базу, і кращу промоцію.
Динаміка popularity у часі	Поточна popularity може залежати від часу після релізу і алгоритмів Spotify.

Через ці ризики результати краще трактувати як умовну статистичну асоціацію. Причинна інтерпретація можлива лише за сильним припущенням, що після наявних контролів похибка не корелює з ключовими регресорами.

Висновки за частиною 4

1. Fan-base артиста має стабільний додатний зв'язок із popularity треку в усіх специфікаціях.
2. Explicit-контент як один з основних регресорів має додатний і статистично значущий зв'язок із popularity після врахування інших змінних.
3. Аудіо-характеристики спільно статистично значущі, тому їх можна залишати як змістовний блок основних регресорів треку; вони також виконують роль контролів для оцінки fan-base.
4. Genre та decade спільно статистично значущі, тому їх потрібно залишати як fixed effects для жанрових і часових відмінностей.
5. Через можливий omitted variable bias висновки не слід подавати як остаточне доведення причинного ефекту.

ЗАГАЛЬНІ ВИСНОВКИ

Регресійний аналіз показав, що характеристики треків у Spotify Songs не можна адекватно описати лише простими двовимірними зв'язками з попередніх лабораторних робіт. Після додавання контрольних змінних, нелінійних членів, жанрових фіктивних змінних, взаємодій і робастних стандартних похибок більшість змістовних закономірностей збереглася, але стала точнішою з погляду інтерпретації за інших рівних умов.

У частині про тривалість підтверджено, що історичний тренд не є лінійним: у старіших періодах треки мали тенденцію до подовження, а в сучасну епоху стрімінгових платформ очікувана тривалість скорочується. Водночас цей процес залежить від жанру: комерційні жанри швидше адаптуються до коротшого формату, тоді як консервативні жанри змінюються слабше. Темп також має нелінійний ефект, тому однакове збільшення BPM по-різному впливає на тривалість повільних і швидких композицій.

У частині про танцювальність найважливішими результатами стали нелінійний вплив tempo і valence, значущість жанрових відмінностей та роль мультиколінеарності між energy і loudness. Після вилучення loudness фінальна модель залишилася змістовною: позитивність треку підвищує danceability, але приріст поступово слабшає; жанри Hip-Hop та Electronic мають вищу базову танцювальність, а складніші або менш ритмічно орієнтовані жанри мають нижчі значення цього показника.

У частині про explicit-контент бінарна природа залежної змінної вимагала використання Logit і Probit та інтерпретації через середні маржинальні ефекти. Обидві специфікації дали узгоджені результати: жанр є ключовим детермінантом імовірності explicit-статусу, особливо для Hip-Hop; energy і danceability підвищують цю імовірність, тоді як valence має протилежний зв'язок. Спільні Wald-тести підтвердили значущість жанрових ефектів і взаємодій danceability з genre.

У частині про popularity стабільним залишився додатний зв'язок fan-base артиста з популярністю треку. Explicit-контент також має додатний статистично значущий зв'язок із popularity після контролю жанру, десятиліття та аудіо-характеристик. Додавання квадратичного члена для log_followers показало, що

початкова гіпотеза про спадну граничну віддачу fan-base у цій специфікації не підтвердилася; навпаки, оцінений граничний ефект більший у верхній частині розподілу fan-base. Audio features, genre та decade залишаються змістовними блоками контролів.

Обмеження аналізу

Попри статистичну значущість багатьох коефіцієнтів, результати слід трактувати переважно як умовні асоціації, а не як остаточний доказ причинного впливу. Дані є спостережувальними, тому залишається ризик omitted variable bias: у моделях відсутні дані про маркетингові бюджети, формат релізу, роботу лейблів, алгоритмічне просування на стрімінгових платформах, країну та культурний контекст артиста, демографію аудиторії, радіоцензуру, плейлистинг і точну історію прослуховувань. Ідеально ці змінні можна було б отримати з метаданих Spotify API, даних лейблів, платформ аналітики стрімінгів, чартів, плейлистів і відкритих джерел про артистів.

Також частина моделей чутлива до функціональної специфікації: для коректної інтерпретації важливі логарифмування, центрування, квадрати, взаємодії та вибір базових категорій. Для бінарної залежної змінної коефіцієнти Logit/Probit не мають прямої змістовної інтерпретації без маржинальних ефектів. Через кореляції між audio features окремі коефіцієнти не слід переінтерпретовувати як незалежні причинні ефекти; надійніше трактувати їх як спільний блок характеристик звучання.

Підсумковий висновок

Отже, ЛРЗ виконала перехід від описових і двовимірних результатів ЛР1-ЛР2 до багатофакторного регресійного аналізу. Побудовані моделі дали відповіді на поставлені дослідницькі питання, показали значущість жанру, часу, fan-base та аудіо-характеристик, а також продемонстрували, що для музичних даних принципово важливі нелінійність, взаємодії та коректні стандартні похибки. Найобережніша інтерпретація результатів така: наявні дані переконливо показують стійкі статистичні зв'язки між характеристиками треків, артистів і популярністю, але для сильнішої причинної інтерпретації потрібні додаткові контрольні змінні й дані про механізми просування музики.

ДЖЕРЕЛА

1. Вимоги до лабораторних робіт з дисципліни «Аналіз даних», розділ 3 «Лабораторна робота №3. Регресійний аналіз».
2. Лекційні матеріали курсу «Аналіз даних», лекції 5-9: регресійний аналіз, OLS, робастні стандартні похибки, Logit/Probit, тести Волда та інтерпретація маржинальних ефектів.
3. Очищений робочий датасет Spotify Songs (`songs\_clean.rds`) та результати попередніх лабораторних робіт команди №4.
4. R-пакети та інструменти, використані для оцінювання моделей і формування таблиць: tidyverse, fixest, sandwich, lmtest, car, marginaleffects, modelsummary.