

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ

ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Факультет програмних систем та прикладної математики

Кафедра прикладної математики

## **ЗВІТ**

### **з лабораторної роботи №4**

на тему: «Непараметрична регресія. Аналіз го ловних  
компонент»

Виконали: студенти

групи КМ-33, команда

№4

Сивоконь В. В., Сусяк

В. Р., Ткаченко Є. В.

Київ – 2026

# Зміст

|                                 |    |
|---------------------------------|----|
| Вступ і постановка задачі ..... | 3  |
| Дані та підготовка .....        | 3  |
| Аналіз головних компонент ..... | 5  |
| Непараметрична регресія .....   | 11 |
| Модель для danceability .....   | 11 |
| Модель для popularity .....     | 22 |
| Модель для explicit .....       | 31 |
| Загальні висновки .....         | 41 |
| Використані джерела .....       | 43 |

## Вступ і постановка задачі

У лабораторній роботі №4 продовжено моделювання музичного датасету з попередніх робіт, але замість суто параметричних специфікацій використано непараметричні та напівпараметричні підходи. Загальна ідея роботи полягає в тому, щоб перевірити, чи є зв'язки між аудіо-характеристиками, популярністю, танцювальністю та explicit-контентом справді лінійними, чи їх краще описувати гнучкими функціями.

Звіт побудовано як єдиний аналіз із трьома залежними змінними.

Спочатку наведено спільний PCA-блок для аудіо-характеристик, після чого окремо розглянуто моделі для danceability, popularity та explicit.

- PCA використовується як спільний опис структури аудіо-змінних.
- Для неперервних залежних змінних застосовано GAM, частково лінійні та ядрові моделі.
- Для бінарної змінної explicit використано логістичну GAM-логіку та умовні ймовірності.

## Дані та підготовка

Використано той самий очищений набір даних, що й у попередніх лабораторних роботах.

Таблиця 1. Короткий опис вибірки

| metric | value |
|--------|-------|
|--------|-------|

|                      |         |
|----------------------|---------|
| rows_raw             | 516 129 |
| columns_raw          | 23.000  |
| rows_after_cleaning  | 516 123 |
| artist_clusters      | 43 531  |
| genres               | 10.000  |
| decades              | 13.000  |
| mean_popularity      | 17.570  |
| median_popularity    | 14.000  |
| mean_log_followers   | 12.359  |
| median_log_followers | 12.420  |

Таблиця 2. Дескриптивні статистики

| variable             | n          | mean  | sd        | min          | p25       | media<br>n   | p75   | max        |
|----------------------|------------|-------|-----------|--------------|-----------|--------------|-------|------------|
| acousticness         | 5161<br>23 | 0.244 | 0.30<br>9 | 0.00<br>0    | 0.00<br>3 | 0.075        | 0.435 | 0.996      |
| danceability         | 5161<br>23 | 0.525 | 0.17<br>3 | 0.04<br>5    | 0.40<br>6 | 0.528        | 0.649 | 0.988      |
| duration_mi<br>n     | 5161<br>23 | 3.964 | 1.61<br>2 | 0.25<br>0    | 3.06<br>6 | 3.720        | 4.523 | 83.25<br>5 |
| energy               | 5161<br>23 | 0.672 | 0.24<br>7 | 2.00<br>e-05 | 0.49<br>5 | 0.717        | 0.887 | 1.000      |
| instrumental<br>ness | 5161<br>23 | 0.109 | 0.24<br>1 | 0.00<br>0    | 0.00<br>0 | 1.96e-<br>04 | 0.034 | 0.998      |
| liveness             | 5161<br>23 | 0.226 | 0.19<br>9 | 0.00<br>7    | 0.10<br>0 | 0.142        | 0.297 | 1.000      |
| log_follower         | 5161       | 12.35 | 2.38      | 0.00         | 10.8      | 12.42        | 14.02 | 19.50      |

|             |      |        |      |      |      |        |        |       |
|-------------|------|--------|------|------|------|--------|--------|-------|
| s           | 23   | 9      | 2    | 0    | 41   | 0      | 5      | 3     |
| loudness    | 5161 | -7.904 | 3.87 | -    | -    | -7.057 | -5.105 | 0.000 |
|             | 23   |        | 8    | 44.8 | 9.95 |        |        |       |
|             |      |        |      | 68   | 2    |        |        |       |
| popularity  | 5161 | 17.57  | 17.1 | 0.00 | 0.00 | 14.00  | 29.00  | 98.00 |
|             | 23   | 0      | 27   | 0    | 0    | 0      | 0      | 0     |
| speechiness | 5161 | 0.085  | 0.09 | 0.02 | 0.03 | 0.050  | 0.092  | 0.966 |
|             | 23   |        | 3    | 2    | 5    |        |        |       |
| tempo       | 5161 | 122.8  | 29.4 | 30.9 | 99.9 | 121.7  | 140.9  | 245.9 |
|             | 23   | 63     | 64   | 46   | 85   | 99     | 78     | 41    |
| valence     | 5161 | 0.464  | 0.25 | 0.00 | 0.25 | 0.446  | 0.660  | 0.998 |
|             | 23   |        | 0    | 0    | 7    |        |        |       |

Для порівняння прогнозової якості моделей дані було розділено на навчальну та валідаційну частини. Через обчислювальну складність непараметричних методів моделі зі сплайнами оцінено на 160000 навчальних спостережень, а якість перевірено на 50000 валідаційних спостережень.

### Аналіз головних компонент

РСА проведено для стандартизованих аудіо-характеристик. Мета цього блоку - зрозуміти, які групи аудіо-змінних рухаються разом, і чи можна стисло описати контрольні змінні кількома компонентами.

Таблиця 3. Пояснена дисперсія PCA

| component | eigenvalue | explained_variance | cumulative_variance |
|-----------|------------|--------------------|---------------------|
|-----------|------------|--------------------|---------------------|

|      |       |       |       |
|------|-------|-------|-------|
| PC1  | 2.577 | 0.258 | 0.258 |
| PC2  | 1.771 | 0.177 | 0.435 |
| PC3  | 1.123 | 0.112 | 0.547 |
| PC4  | 1.016 | 0.102 | 0.649 |
| PC5  | 0.885 | 0.088 | 0.737 |
| PC6  | 0.879 | 0.088 | 0.825 |
| PC7  | 0.808 | 0.081 | 0.906 |
| PC8  | 0.437 | 0.044 | 0.950 |
| PC9  | 0.362 | 0.036 | 0.986 |
| PC10 | 0.142 | 0.014 | 1.000 |

Scree plot





Рисунок 1. Scree plot для PCA аудіо-характеристик

Scree plot показує, яку частку загальної дисперсії аудіо-характеристик пояснює кожна головна компонента. Перші компоненти пояснюють

найбільше, а далі внесок поступово зменшується. Ламана лінія допомагає побачити 'лікоть' графіка: після цієї точки додавання нових компонент дає вже невеликий приріст поясненої дисперсії. У нашому випадку спад не зупиняється після однієї-двох компонент, тому аудіо-характеристики мають багатовимірну структуру.



*Рисунок 2. Кумулятивна пояснена дисперсія*

Графік кумулятивної дисперсії показує сумарну частку дисперсії, яку пояснюють перші  $k$  компонент. Горизонтальна лінія на рівні 80% використовується як практичний орієнтир для вибору кількості компонент.

Таблиця 4. Loadings перших головних компонент

|          |     |     |     |     |     |     |
|----------|-----|-----|-----|-----|-----|-----|
| variable | PC1 | PC2 | PC3 | PC4 | PC5 | PC6 |
|----------|-----|-----|-----|-----|-----|-----|

|                  |        |        |        |        |        |        |
|------------------|--------|--------|--------|--------|--------|--------|
| duration_min     | 0.053  | 0.359  | 0.242  | 0.476  | -0.425 | 0.178  |
| danceability     | -0.107 | -0.569 | 0.200  | 0.332  | -0.201 | -0.096 |
| energy           | 0.586  | -0.047 | 0.031  | 0.044  | 0.060  | 0.022  |
| loudness         | 0.528  | -0.123 | 0.071  | -0.018 | 0.256  | 0.098  |
| speechiness      | 0.134  | -0.163 | -0.581 | 0.245  | -0.032 | -0.670 |
| acousticness     | -0.529 | 0.024  | -0.190 | -0.117 | -0.051 | -0.010 |
| instrumentalness | 0.072  | 0.385  | 0.282  | 0.215  | -0.273 | -0.482 |
| liveness         | 0.130  | 0.133  | -0.652 | 0.230  | -0.312 | 0.475  |
| valence          | 0.017  | -0.578 | 0.124  | 0.025  | -0.428 | 0.145  |
| tempo            | 0.209  | 0.055  | -0.035 | -0.699 | -0.593 | -0.146 |

PCA loadings for the first six components




Рисунок 3. Навантаження змінних на перші компоненти



Loadings показують, які початкові змінні найбільше формують кожну головну компоненту. Великі додатні або від'ємні значення означають сильний внесок змінної у відповідний напрям.




Рисунок 4. PCA biplot: PC1 та PC2




Рисунок 5. PCA biplot: PC1 та PC3

На biplot точки відповідають трекам, спроектованим на площину двох головних компонент. Стрілки показують початкові аудіо-змінні: напрям стрілки показує, у який бік зростає характеристика, а довжина - наскільки добре ця змінна представлена на обраній площині компонент. PC1-PC2 показує основний двовимірний зріз, а PC1-PC3 додає вимір, пов'язаний із мовленнєвістю та живістю запису.

Перші п'ять компонент пояснюють приблизно 73.7% дисперсії аудіо-характеристик, а перші шість - приблизно 82.5%. Отже, аудіо-змінні не зводяться до одного простого виміру.

- PC1: енергійність і гучність проти акустичності.

- PC2: танцювальність і позитивність проти довгих та більш інструментальних треків.
- PC3: мовленнєвість і живість запису

## Непараметрична регресія

У цьому розділі однакова методологія застосовується до трьох різних задач. Для кожної залежної змінної спочатку фіксується змістовна специфікація, потім порівнюються параметрична та гнучка частини моделі, а графіки використовуються для інтерпретації форми зв'язку.

## Модель для *danceability*

У цьому блоці залежною змінною є танцювальність треку. Основний акцент зроблено на тому, чи мають tempo та valence нелінійний зв'язок із *danceability* після контролю інших аудіо-характеристик, року та жанру.

Згідно з вимогами до моделювання, ми застосували гнучкий підхід і розділили набір наших регресорів на дві частини: параметричну та непараметричну.

Лінійна (параметрична) частина: У лінійній частині ми залишили змінні *energy*, *instrumentalness*, *speechiness*, *acousticness*, *year* та *genre*. Їхній вплив на танцювальність ми продовжуємо оцінювати як сталий лінійний зв'язок.

Непараметрична частина: У непараметричну частину моделі ми відправили змінні tempo (темп) та valence (емоційна позитивність). У нашій попередній Лабораторній роботі №3 ми економетрично довели, що ці метрики мають нелінійний вплив на танцювальність. Використання частково лінійної моделі дозволяє оцінити їхній справжній вплив на основі самих даних, уникаючи будь-яких жорстких математичних припущень щодо форми цього зв'язку.

Для перевірки стійкості наших попередніх висновків ми порівняли оцінки коефіцієнтів лінійної частини нової моделі з результатами нашої фінальної OLS-специфікації з Лабораторної роботи №3.


| Змінна<br>(Regressor) | Частково лінійна<br>модель (Лаб. 4) | Класична OLS<br>модель (Лаб. 3) |
|-----------------------|-------------------------------------|---------------------------------|
| energy                | -0.239                              | -0.179                          |
| instrumentalness      | -0.040                              | -0.042                          |
| speechiness           | 0.318                               | 0.114                           |
| acousticness          | -0.108                              | -0.070                          |

|      |        |       |
|------|--------|-------|
| year | 0.0016 | 0.001 |
|------|--------|-------|

Аналізуючи результати, ми бачимо, що ефекти `energy` та `instrumentalness` виявилися стійкими їхні значення в гібридному непараметричному підході практично збіглися з класичним лінійним оцінюванням. Водночас вплив `speechiness` та `acousticness` у гнучкій моделі став ще більш вираженим. Це показує, що коли ми дозволили алгоритму гнучко адаптуватися під нелінійність темпу та настрою, лінійні оцінки для інших акустичних метрик змогли скоригуватися і продемонструвати свою справжню силу.

## Ядрова регресія для tempo та valence

Для первинного аналізу нелінійного впливу темпу (tempo) на танцювальність ми застосували просту ядрову регресію. Щоб оцінити стійкість результатів, ми побудували графіки для двох різних непараметричних оцінок: Надарай-Вотсона (Local-Constant) та локально лінійної (Locally Linear).




Форма зв'язку: Обидві непараметричні оцінки (Nadaraya-Watson та Locally Linear) підтверджують складний нелінійний, параболічний

зв'язок між темпом та танцювальністю. Найвища танцювальність досягається на середніх темпах, тоді як занадто повільні або екстремально швидкі треки є менш танцювальними.

Порівняння оцінок: На графіку видно, що обидві криві поведуться дуже схоже всередині розподілу (де зосереджено найбільше точок), проте на краях оцінка Надараї-Вотсона є більш згладженою, тоді як локально лінійна регресія краще адаптується до трендів на границях вибірки.

Надійність оцінки: Довірчі смуги навколо кривих є найвужчими в діапазоні 120–150 BPM, що свідчить про високу точність оцінки саме в цьому популярному діапазоні. Натомість для значень понад 180 BPM довірчі смуги сильно розширюються через брак даних.



Форма зв'язку: Графік демонструє чіткий, монотонно зростаючий зв'язок між емоційною позитивністю треку (valence) та його танцювальністю. Що радіснішим та позитивнішим є настрій композиції, то вищим є її танцювальний потенціал.

Порівняння оцінок: Як видно з графіка, обидві непараметричні оцінки поведуться практично ідентично всередині розподілу (у діапазоні валентності приблизно від 0.25 до 0.75), де лінії накладаються одна на одну. Однак на краях вибірки проявляється властивість, що оцінка Надарай-Вотсона стає більш «плоскою» і страждає від зміщення на границях. Натомість локально лінійна регресія значно краще




адаптується до крайових значень, продовжуючи вловлювати висхідний тренд для екстремально радісних чи екстремально депресивних пісень.


Надійність оцінки: Навколо обох кривих побудовано довірчі смуги. Вони є максимально вузькими в центрі графіка, що свідчить про високу точність оцінки алгоритму завдяки великій кількості треків із нейтральним та помірно позитивним настроєм у датасеті. На самих краях довірчі смуги закономірно розширюються, оскільки кількість спостережень із такими екстремальними емоційними забарвленнями є значно меншою, що збільшує статистичну невизначеність.

### Часткові ефекти та GAM

Для наочної візуалізації ізольованого нелінійного впливу темпу та емоційної позитивності на танцювальність було побудовано графіки часткових ефектів. Згідно з методологічними вимогами до візуалізації непараметричних моделей, для коректної оцінки ефекту, під час побудови цих графіків усі інші числові контрольні змінні моделі (energy, instrumentality, speechiness, acousticness, year) були штучно зафіксовані на рівні їхньої медіани. Категорійна змінна жанру (genre) була зафіксована на найпопулярнішому значенні (моді) датасету.



Ефект темпу: Як видно з першого графіка, зв'язок між швидкістю відтворення і танцювальністю має форму параболи. Танцювальність стрімко зростає зі збільшенням темпу, досягаючи свого глобального максимуму в зоні ідеального танцювального темпу, вершина параболи знаходиться в районі 112 BPM. При подальшому збільшенні швидкості та переході до екстремально швидких треків показник танцювальності закономірно починає падати, оскільки під таку музику стає фізично складно танцювати.




Другий графік демонструє складний нелінійний вплив емоційної окраси треку на його танцювальний потенціал. Математичний аналіз цієї кривої показує, що її теоретична вершина знаходиться далеко за межами шкали (у точці  $\approx 2.34$ ), тому в межах усіх допустимих значень (від 0 до 1) функція є монотонно зростаючою. Це означає, що позитивніший і веселіший настрій композиції незмінно призводить до підвищення її танцювальності. Однак нелінійність проявляється в тому,

що швидкість цього приросту поступово сповільнюється для надзвичайно позитивних композицій.

Навколо обох оцінених кривих побудовано 95% довірчі смуги, розраховані на основі стандартних похибок. Можна помітити, що ці смуги є максимально вузькими в центрі розподілів (наприклад, у діапазоні 100–130 BPM для темпу), де зосереджена лівова частка пісень датасету. Це свідчить про дуже високу точність оцінки алгоритму в цій зоні. На краях графіків довірчі смуги розширюються через значно меншу кількість доступних спостережень.

Щоб уникнути «прокляття розмірності» при непараметричному оцінюванні великої кількості змінних, ми побудували узагальнену адитивну модель (GAM). Цей метод припускає, що загальний вплив регресорів є сумою їхніх індивідуальних нелінійних ефектів. У специфікації `model_gam` алгоритм самостійно підібрав оптимальну гнучку форму (сплайни `s()`) для всіх безперервних метрик (`tempo`, `valence`, `energy`, `acousticness`, `speechiness`, `instrumentalness`, `year`), а жанр (`genre`) увійшов у модель як лінійний фактор.



Функція `draw()` дозволила візуалізувати часткові ефекти ключових сплайнів. На осі Y відкладено ізольований внесок змінної в танцювальність (центрований навколо нуля):

Ефект темпу: Алгоритм GAM самостійно підтвердив нелінійну, куполоподібну форму зв'язку. Максимальний позитивний вплив на танцювальність дають треки з темпом 110–120 BPM. Надто повільні або екстремально швидкі композиції різко знижують танцювальний потенціал.

Ефект настрою: Тренд є стабільно зростаючим, а саме чим радісніший трек, тим він танцювальніший. Проте GAM виявила плато

на найвищих значеннях позитивності, що свідчить про зменшення маржинального ефекту для надійфорійних пісень.

Статистична надійність: Заштриховані 95% довірчі смуги є найвужчими в центрі розподілу даних (де зосереджено більшість треків). На краях графіків вони закономірно розширюються через брак спостережень.

### **Модель для popularity**

У цьому блоці залежною змінною є popularity. Ключовий регресор інтересу -  $\log(1 + \text{total\_artist\_followers})$ , а аудіо-характеристики, жанр, десятиліття та explicit-контент використовуються як контрольні змінні.

Основна залежна змінна в цьому блоці - popularity. Базовий регресор інтересу -  $\log\_followers\_c$ , тобто центрований  $\log(1 + \text{total\_artist\_followers})$ . Контрольні змінні: explicit, duration\_min,

danceability, energy, loudness, speechiness, acousticness, instrumentality, liveness, valence, tempo, genre, decade.

Оцінено такі моделі:

- лінійна базова модель зі специфікацією ЛРЗ;
- частково лінійна модель:  $s(\log\_followers\_c) + \text{controls}$ ;
- GAM зі сплайнами для ключового регресора та числових аудіо-контролів;
- GAM з PCA-компонентами аудіо-контролів;
- ядрова регресія Надарай-Вотсона та локальна лінійна регресія на  $\log\_followers\_c + PC1 + \dots + PC6$ .

Таблиця 5. Порівняння моделей на валідаційній вибірці

| model                                                   | n_train | n_validation | rmse   | mae    |
|---------------------------------------------------------|---------|--------------|--------|--------|
| Linear baseline<br>from Lab 3<br>specification          | 160000  | 50000        | 15.389 | 12.437 |
| Partially linear:<br>$s(\log\_followers)$<br>+ controls | 160000  | 50000        | 15.366 | 12.406 |
| GAM: smooth<br>numeric<br>controls                      | 160000  | 50000        | 15.340 | 12.373 |
| GAM with PCA<br>audio controls                          | 160000  | 50000        | 15.399 | 12.445 |

RMSE та MAE - це помилки прогнозу на валідаційній вибірці в одиницях шкали popularity, а не пояснена дисперсія. MAE показує

середню абсолютну помилку, а RMSE сильніше штрафує великі помилки. Найнижчу RMSE має GAM з оригінальними аудіо-контролями. Частково лінійна модель також покращує базову лінійну специфікацію з ЛРЗ, хоча покращення невелике. PCA-версія GAM поступається моделі з оригінальними аудіо-змінними, тому PCA не варто використовувати як основну змістовну заміну контролів.

Частково лінійна модель

Таблиця 6. Порівняння лінійної бази та лінійної частини

| term                 | lm_estimate | lm_standard_error | plm_linear_estimate | plm_linear_standard_error |
|----------------------|-------------|-------------------|---------------------|---------------------------|
| log_followers_c      | 2.513       | 0.018             |                     |                           |
| I(log_followers_c^2) | 0.107       | 0.005             |                     |                           |
| explicitExplicit     | 0.868       | 0.119             | 0.821               | 0.119                     |
| duration_min         | -0.138      | 0.025             | -0.119              | 0.025                     |
| danceability         | 7.062       | 0.315             | 7.102               | 0.315                     |
| energy               | -4.147      | 0.348             | -4.069              | 0.348                     |
| loudness             | 0.517       | 0.018             | 0.509               | 0.018                     |
| speechiness          | -2.534      | 0.483             | -2.564              | 0.483                     |



|                  |        |           |        |       |
|------------------|--------|-----------|--------|-------|
|                  |        | 4         |        |       |
| acousticness     | -1.202 | 0.20<br>2 | -1.170 | 0.202 |
| instrumentalness | -0.843 | 0.17<br>5 | -0.971 | 0.175 |
| liveness         | -5.015 | 0.20<br>5 | -4.961 | 0.205 |
| valence          | -3.417 | 0.20<br>2 | -3.393 | 0.202 |
| tempo            | 0.009  | 0.00<br>1 | 0.009  | 0.001 |

Таблиця 7. Гладкий член частково лінійної моделі

| smooth_term        | edf   | Ref.df | F     | p-value |
|--------------------|-------|--------|-------|---------|
| s(log_followers_c) | 9.606 | 10.945 | 1 883 | 0       |

Коефіцієнти контрольних змінних у частково лінійній моделі близькі до коефіцієнтів базової лінійної моделі. Це означає, що перехід від квадратичної апроксимації `log_followers` до гладкої функції `s(log_followers)` не руйнує висновки щодо контрольних аудіо-змінних.


У таблицях гладких членів `edf` означає *effective degrees of freedom*. Якщо `edf` близьке до 1, ефект майже лінійний; якщо `edf` значно більше за 1, форма зв'язку є нелінійною.

GAM зі сплайнами

Таблиця 8. Гладкі члени GAM

| smooth_term         | edf   | Ref.df | F       | p-value  |
|---------------------|-------|--------|---------|----------|
| s(log_followers_c)  | 9.613 | 10.951 | 1 849   | 0.000    |
| s(duration_min)     | 7.734 | 8.423  | 19.173  | 0.000    |
| s(danceability)     | 3.476 | 4.362  | 139.234 | 0.000    |
| s(energy)           | 1.712 | 2.183  | 54.663  | 0.000    |
| s(loudness)         | 5.817 | 6.733  | 124.107 | 0.000    |
| s(speechiness)      | 3.670 | 4.455  | 12.129  | 0.000    |
| s(acousticness)     | 7.503 | 8.424  | 8.062   | 0.000    |
| s(instrumentalness) | 3.646 | 4.473  | 4.642   | 5.88e-04 |
| s(liveness)         | 6.499 | 7.560  | 77.714  | 0.000    |
| s(valence)          | 3.160 | 3.944  | 73.256  | 0.000    |
| s(tempo)            | 5.921 | 6.860  | 24.560  | 0.000    |

Наступні три графіки не є графіками тільки для GAM. Вони показують умовні прогнози для частково лінійної моделі, GAM з оригінальними контролями та, де це доречно, GAM з PCA-контролями. Контролі фіксуються на медіанах або модах.



*Рисунок 5. Умовна залежність popularity від log followers*

На графіку всі аудіо-контролі зафіксовано на медіанах, а категорійні змінні - на модах. Крива показує нелінійне зростання очікуваної популярності зі збільшенням аудиторії артиста.




Рисунок 6. Умовна залежність *popularity* від *explicit*

Оскільки *explicit* є категорійною змінною, графік показує дві умовні прогнозні точки, а не гладку криву. Числові контролі зафіксовано на медіанах, категорійні - на модах.




Рисунок 7. Умовна залежність *popularity* від *danceability*

Графік *danceability* порівнює частково лінійну модель, де *danceability* входить лінійно, з GAM, де *danceability* оцінюється як гладкий член.

### Ядрова регресія

Через прокляття розмірності повну ядрову регресію з усіма аудіо-контролями оцінювати недоцільно. Тому для ядрового блоку аудіо-контролі стиснуто до перших шести PCA-компонент, які разом пояснюють понад 80% дисперсії аудіо-характеристик.

Ядровий графік побудовано окремо для *log\_followers*, бо ядрова специфікація має вигляд  $\log\_followers\_c + PC1 + \dots + PC6$ .

Таблиця 9. Підбір ширини вікна для ядрової регресії

| bandwidth_multi<br>plier | bandwi<br>dth | nw_rm<br>se | local_linear_r<br>mse | nw_m<br>ae | local_linear_<br>mae |
|--------------------------|---------------|-------------|-----------------------|------------|----------------------|
| 0.700                    | 0.315         | 16.934      | 18.752                | 13.35<br>0 | 14.352               |
| 1.000                    | 0.450         | 15.993      | 17.084                | 12.79<br>6 | 13.315               |
| 1.400                    | 0.630         | 15.673      | 16.041                | 12.73<br>7 | 12.711               |
| 1.900                    | 0.855         | 15.677      | 15.655                | 12.88<br>6 | 12.523               |

Kernel regression: Nadaraya-Watson vs local linear

Controls compressed with first 6 audio PCs fixed at zero




Рисунок 6. Надарай-Вотсон та локальна лінійна оцінка

Оцінка Надарай-Вотсона та локальна лінійна оцінка дають близькі, але не ідентичні криві. Обидві підтверджують нелінійний характер зв'язку між популярністю та аудиторією артиста.

### Модель для explicit

У цьому блоці залежна змінна є бінарною: трек або містить explicit-контент, або не містить його. Тому непараметричні ефекти інтерпретуються як зміни умовної ймовірності  $\text{explicit} = 1$ .

### Дослідницьке питання та GAM

У Лабораторній роботі №3 ми досліджували фактори, що впливають на ймовірність наявності нецензурної лексики (explicit) у треках за допомогою параметричних моделей (Logit/Probit). Було доведено, що висока танцювальність (danceability) та енергійність збільшують ймовірність explicit-контенту, а позитивність (valence) — зменшує.


Однак класичні параметричні моделі припускають, що вплив цих ознак на лог-шанси є суворо лінійним. Дослідницьке питання поточної роботи: Чи має вплив акустичних характеристик на ймовірність появи нецензурної лексики нелінійний характер? Для цього ми застосовуємо методи частково лінійної регресії (PLM), узагальнені адитивні моделі (GAM) та аналіз головних компонент (PCA).

## 1. 3. НЕПАРАМЕТРИЧНЕ ОЦІНЮВАННЯ ФУНКЦІЇ РЕГРЕСІЇ

Оскільки залежна змінна є бінарною, ми використовували моделі з логістичною функцією зв'язку (family = binomial).

### 1. 3.1 Узагальнена адитивна модель (GAM)

У повній GAM-моделі непараметричному згладжуванню (через сплайни) піддалися ключові числові регресори: danceability, energy, valence та year.



### Аналіз графіків сплайнів:

Графіки часткових ефектів доводять наявність сильної нелінійності, яку ігнорували моделі з ЛРЗ:



- Вплив **танцювальності** майже відсутній на низьких рівнях, але після позначки 0.6 крива стрімко йде вгору.
- Вплив **енергії** є пологим до 0.8, після чого відбувається різкий стрибок. Це означає, що ризик матів максимальний саме для екстремально "агресивних" треків.
- Вплив **позитивності (valence)** має форму плавної дуги: він позитивний для нейтральних треків, але після 0.5 крива різко падає вниз.

Частково лінійна логістична модель


**Як реалізовано:**

- **Непараметрична частина:**  $s(\text{danceability})$
- **Параметрична частина:** energy, valence, year, genre

Для побудови частково лінійної моделі регресори було розділено на дві групи. У непараметричну частину було включено ключовий фактор — danceability, оскільки розвідковий аналіз та ЛРЗ вказували на його потужну, але потенційно нелінійну дію (ймовірність матів не може зростати нескінченно, очікується ефект плато). У лінійну (параметричну) частину включено контрольні змінні (energy, valence, year) та genre. Жанр є категорійною змінною (індикаторами), тому він математично може входити лише лінійно (подібно до фіксованих ефектів). Можливість непараметричної взаємодії (наприклад, 2D

сплайн  $s(\text{danceability}, \text{energy})$ ) була проігнорована навмисно, щоб уникнути 'прокляття розмірності', зберегти високу швидкість збіжності оцінок та мати змогу ізольовано проінтерпретувати чистий маржинальний вплив ритміки.

Ми ізолювали вплив танцювальності всередині жанру Нір-Нор, зафіксувавши інші змінні на рівні медіани. На графіку умовної ймовірності видно, що шанси наявності матів у репі зростають від ~65% до понад 90% при русі від нетанцювальних до супер-танцювальних композицій, причому цей ріст має характерне плато посередині (0.25 - 0.50).



Для побудови графіків часткових ефектів носій ключового регресора (danceability) було розбито на дрібну рівномірну сітку зі 100 значень на відрізьку [0; 1]. Усі інші регресори були зафіксовані:

1. **Числові контролю (energy, valence, year)** зафіксовано на рівні їхньої **медіани**. Медіана обрана як найбільш стійка до викидів характеристика центру розподілу, що ідеально описує 'типовий' або 'стандартний' музичний трек індустрії.
2. **Категорійний контроль (genre)** зафіксовано на рівні модифікованої моди — **'Hip-Hop'**. Цей вибір аргументований результатами ЛРЗ, де саме цей жанр продемонстрував найвищу базову ймовірність наявності explicit-контенту, що робить його найцікавішим (worst-case scenario) для дослідження впливу танцювальності.

Для демонстрації стійкості (robustness) оцінок ми переходили від базової логістичної моделі (специфікація з ЛРЗ) до частково лінійної (PLM), а потім до повної GAM-моделі зі сплайнами для всіх числових контролів.


| Term | GLM Estimate | PLM Estimate |
|------|--------------|--------------|
|      |              |              |

|                 |                      |                      |
|-----------------|----------------------|----------------------|
| (Intercept)     | -27.875422895431786  | -27.935637069005413  |
| danceability    | 1.0424572845811189   |                      |
| energy          | 1.0253813360068822   | 1.0497712356351092   |
| valence         | -0.4183447093759149  | -0.41043205168749036 |
| loudness        | 0.06373478301328425  | 0.06291638649246134  |
| speechiness     | 4.4935984831422076   | 4.396969776584777    |
| year            | 0.01193659858658727  | 0.01227704862350181  |
| genreClassical  | 0.8020384303221881   | 0.8027369534269195   |
| genreCountry    | 0.9279198907364913   | 0.9468114341036286   |
| genreElectronic | 0.5355186702803364   | 0.5169367039010734   |
| genreFolk       | 0.9922225181656339   | 0.9659029287266709   |
| genreHip-Hop    | 3.3851249157025567   | 3.3244862056625197   |
| genreJazz       | -0.07137566939186105 | -0.07365764188908959 |
| genrePop        | 0.7411190591066259   | 0.733004475322764    |
| genreR&B        | 1.1347303269662605   | 1.103566991597692    |
| genreRock       | 1.1578482457857793   | 1.1318654654037938   |

Згідно з Таблицею порівняння, коефіцієнти параметричної частини PLM залишилися практично ідентичними коефіцієнтам базової моделі з ЛРЗ. Наприклад, логіт-коефіцієнт для індикатора жанру не зазнав значних зсувів. Це доводить, що переведення danceability у непараметричну форму уточнило саму форму зв'язку, але не зруйнувало загальної економетричної структури моделі, підтверджуючи стійкість результатів попередньої лабораторної роботи.


### Ядрова регресія

Для перевірки без припущень про глобальні сплайни ми реалізували оцінку Надарай-Вотсона у 2D-просторі предикторів (danceability та energy). Для візуалізації було зроблено умовний зріз: energy зафіксовано на рівні медіани.



Графік ядрової регресії має значно більш "хвилясту" структуру порівняно зі сплайнами GAM, оскільки ядерна оцінка є локальною і сильно реагує на густину даних у конкретних точках. Ми бачимо локальний пік ймовірності навколо  $\text{danceability} = 0.3$ , після чого йде просідання, і стрімке зростання ближче до 1.0. Розширення синьої довірчої смуги (confidence band) на краях розподілу (біля 0 та 1) наочно демонструє зростання невизначеності через малу кількість спостережень у цих зонах.

Ядрова регресія: Надарая-Вотсон vs Локальна лінійна  
Контролі (energy, valence) зафіксовано на рівні медіани



На Рисунку вище зображено умовну ймовірність того, що трек міститиме нецензурну лексику ( $P(\text{Explicit} = 1)$ ), залежно від його танцювальності. Щоб уникнути "прокляття розмірності", для побудови графіків було зафіксовано два найважливіші числові контролі (energy та valence) на рівні їхніх вибірових медіан.

Аналіз графіка дозволяє зробити два ключові висновки:

- Підтвердження нелінійного тренду:** Обидва непараметричні методи підтверджують висновки, отримані раніше за допомогою GAM. На рівні danceability від 0.0 до 0.5 ймовірність наявності матів є стабільно низькою (близько 15-20%). Однак після подолання позначки 0.5 починається стрімке, нелінійне зростання ризику наявності explicit-контенту.

3. **Методологічна різниця на границях (Boundary Bias):** Графік наочно демонструє класичну економетричну різницю між двома ядерними оцінками на краях розподілу (коли danceability наближається до 1.0):
4. **Оцінка Надарай-Вотсона (червона лінія)** є локально сталою. На правій границі їй не вистачає даних праворуч (адже танцювальності  $> 1.0$  не існує), тому вона усереднює значення лише з даними ліворуч. Це призводить до так званого *граничного зміщення (boundary bias)* — крива штучно "загинається" вниз і згладжує ефект, показуючи ймовірність лише на рівні  $\sim 50\%$ .
5. **Локальна лінійна регресія (синя лінія)** автоматично коригує це граничне зміщення. Оскільки вона локально підганяє пряму (враховує нахил), метод здатен екстраполювати стрімкий тренд до самої границі. Тому синя крива прогнозує значно вищу ймовірність (майже 100%) для екстремально танцювальних треків.

Також варто відзначити суттєве розширення довірчих смуг (confidence bands) на правому краю графіка для обох методів. Це свідчить про високу дисперсію оцінок: у датасеті існує дуже мало треків, які мають екстремальну танцювальність (близько 1.0), але при цьому абсолютно середню, "типову" енергію та валентність.



## Загальні висновки

1. Аналіз головних компонент показав, що аудіо-характеристики треків мають багатовимірну структуру і не зводяться до одного простого показника якості або популярності. Перші компоненти відокремлюють енергійне та гучне звучання від акустичного, танцювальність і позитивність від довших та інструментальніших треків, а також живість і мовленнєвість запису. Це підтверджує, що PCA у цій роботі є не декоративним етапом, а змістовним способом описати приховані музичні виміри та зменшити кількість взаємопов'язаних аудіо-змінних.
2. Для моделі danceability найважливішими нелінійними факторами стали tempo та valence. Темп має куполоподібний ефект: танцювальність зростає до середнього діапазону BPM, але надто повільні або надто швидкі треки оцінюються як менш танцювальні. Valence переважно підсилює danceability, тобто позитивніший настрій композиції пов'язаний із вищим танцювальним потенціалом. Ширші довірчі смуги на краях графіків показують, що висновки там менш стабільні через меншу кількість спостережень.
3. Для моделі popularity головний зв'язок із розміром аудиторії артиста є нелінійним: приріст очікуваної популярності не є однаковим на всіх рівнях log\_followers. На малих значеннях аудиторії прогноз майже не змінюється, у середній частині залежність стає помітнішою, а для великих аудиторій ефект зростає сильніше. Найкращу валідаційну якість у цьому блоці дала GAM з оригінальними аудіо-контролями, тому повна гнучка специфікація краще описує дані, ніж проста лінійна модель або заміна всіх аудіо-змінних PCA-компонентами.

4. Для моделі explicit результати GAM, частково лінійної логістичної моделі та ядрової регресії показують, що вплив danceability, energy і valence на ймовірність explicit-контенту не є суто лінійним. Особливо важливо, що ймовірність explicit змінюється не рівномірно по всій шкалі danceability: на низьких і середніх значеннях ефект слабший, а на вищих рівнях танцювальності крива може зростати значно швидше. Це пояснює, чому параметричні logit/probit моделі з ЛРЗ були корисною базою, але не повністю розкривали форму залежності.
5. Ядрові методи дали важливу локальну перевірку форми зв'язку, бо вони не нав'язують глобальної функціональної форми, як звичайна лінійна регресія. Водночас вони дуже чутливі до розмірності, ширини вікна та густини даних: у центрі розподілу оцінки стабільніші, а на межах зростає дисперсія і можливе граничне зміщення. Тому використання PCA-компонентів або фіксація частини контролів є практичним компромісом, який дозволяє побудувати інтерпретовані графіки без надмірного обчислювального навантаження.
6. Усі отримані результати слід трактувати як описові модельні закономірності, а не як строгі причинно-наслідкові ефекти. У датасеті можуть бути невраховані фактори, які одночасно впливають і на аудіо-характеристики, і на популярність або explicit-контент: бюджет просування, позиції в плейлистах, країна та вік аудиторії, активність лейблу, час після релізу і медійність артиста. Тому моделі добре показують форму залежностей у наявних даних, але не доводять, що зміна однієї аудіо-характеристики сама по собі

причинно змінює популярність, танцювальність або ймовірність explicit-контенту.

### **Використані джерела**

1. Вимоги до лабораторних робіт з дисципліни «Аналіз даних», розділ 4 «Лабораторна робота №4.Непараметрична регресія».
2. Лекційні матеріали курсу «Аналіз даних», лекції 10-11: Аналіз головних компонент, непараметрична регресія.
3. Очищений робочий датасет Spotify Songs (`songs\_clean.rds`) та результати попередніх лабораторних робіт команди №4.
4. R-пакети та інструменти, використані для оцінювання моделей і формування таблиць: tidyverse, fixest, sandwich, lmtest, car, marginaleffects, modelsummary.